

**PREDIKSI JALUR SIKLON TROPIS DI SAMUDRA
HINDIA MENGGUNAKAN MODEL LONG SHORT-
TERM MEMORY (LSTM) UNTUK MITIGASI RISIKO
BENCANA DI SUMATERA BARAT**

SKRIPSI

*Diajukan Untuk Memenuhi Sebagian Persyaratan Mencapai Gelar
Sarjana Komputer*



Oleh

IKHWAN RAMADHAN

22101152630411

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PUTRA INDONESIA “YPTK” PADANG**

PADANG, 2026

LEMBAR PERNYATAAN

Saya yang bertanda tangan di bawah ini:

Nama : Ikhwan Ramadhan

NOBP : 22101152630411

Program Studi : Teknik Informatika

Fakultas : Ilmu Komputer

Menyatakan bahwa:

1. Sesungguhnya skripsi yang saya susun ini merupakan hasil karya tulis saya sendiri. Adapun bahagian-bahagian tertentu dalam skripsi yang saya peroleh dari hasil karya tulis orang lain, telah saya tuliskan sumbernya dengan jelas, sesuai dengan kaidah penulisan ilmiah.
2. Jika dalam pembuatan skripsi baik pembuatan program maupun skripsi secara keseluruhan ternyata terbukti dibuatkan oleh orang lain, maka saya bersedia menerima sanksi akademik, berupa pembatalan skripsi dan mengulang penelitian serta mengajukan judul baru.

Demikianlah surat pernyataan ini saya buat dengan sesungguhnya tanpa ada paksaan dari pihak manapun.

Padang, Agustus 2026

IKHWAN RAMADHAN
22101152630411

LEMBAR PENGESAHAN SKRIPSI

**PREDIKSI JALUR SIKLON TROPIS DI SAMUDRA HINDIA
MENGUNAKAN MODEL LONG SHORT-TERM MEMORY (LSTM)
UNTUK MITIGASI RISIKO BENCANA DI SUMATERA BARAT**

Yang dipersiapkan dan disusun oleh

IKHWAN RAMADHAN
22101152630411

Telah memenuhi syarat untuk dipertahankan didepan dewan penguji

Pada Ujian Komprehensif

Padang, 2026

Pembimbing I

Pembimbing II

Prof. Dr. Yuhandri, S.Kom., M.Kom
NUPTK: 3847751652130182

Devia kartika, S.Kom., M.Kom
NUPTK: 9553769670230243

LEMBAR PENGESAHAN PENGUJI SIDANG SKRIPSI
PREDIKSI JALUR SIKLON TROPIS DI SAMUDRA HINDIA
MENGGUNAKAN MODEL LONG SHORT-TERM MEMORY (LSTM)
UNTUK MITIGASI RISIKO BENCANA DI SUMATERA BARAT

OLEH:

IKHWAN RAMADHAN
22101152630411

PROGRAM STUDI TEKNIK INFORMATIKA

Skripsi ini Telah Dinyatakan LULUS Oleh
Penguji Materi Pada Sidang Skripsi Program Studi Strata 1 Ilmu Komputer
Program Studi Teknik Informatika
Universitas Putra Indonesia “YPTK” Padang
Pada Hari/Tgl: Selasa/ 18 - Agustus - 2026

TIM PENGUJI

1. **Dr. Ir. Gunadi Widi Nurcahyo, M.Sc** : _____
NUPTK : 5646747648130112

1. **Muhammad Afdhal, S.Kom, M.Kom** : _____
NUPTK : 7254762663130183

Padang, 18 – Agustus - 2026

Mengetahui

Dekan Fakultas Ilmu Komputer
Universitas Putra Indonesia YPTK Padang

(Dr. Rini Sovia, S.Kom., M.Kom)
NUPTK: 2737754655230132

LEMBAR PENGESAHAN LULUS SIDANG SKRIPSI

**PREDIKSI JALUR SIKLON TROPIS DI SAMUDRA HINDIA
MENGUNAKAN MODEL LONG SHORT-TERM MEMORY (LSTM)
UNTUK MITIGASI RISIKO BENCANA DI SUMATERA BARAT**

OLEH:

IKHWAN RAMADHAN
22101152630411

PROGRAM STUDI TEKNIK INFORMATIKA

Yang telah dipertahankan didepan Dewan Penguji

Pada tanggal 18 – Agustus -2026

Dan dinyatakan telah lulus

Memenuhi Syarat

Pembimbing I

Pembimbing II

Prof. Dr. Yuhandri, S.Kom., M.Kom
NUPTK: 3847751652130182

Devia kartika, S.Kom., M.Kom
NUPTK: 9553769670230243

Padang, 18 – Agustus - 2026

Mengetahui

Dekan Fakultas Ilmu Komputer

Universitas Putra Indonesia YPTK Padang

(Dr. Rini Sovia, S.Kom., M.Kom)
NUPTK: 2737754655230132

ABSTRACT

**JUDUL SKRIPSI : TROPICAL CYCLONE TRAJECTORY PREDICTION
IN THE INDIAN OCEAN USING A LONG SHORT-
TERM MEMORY (LSTM) MODEL FOR DISASTER
RISK MITIGATION IN WEST SUMATRA**

NAMA : IKHWAN RAMADHAN

NOBP : 22101152630411

FAKULTAS : ILMU KOMPUTER

JURUSAN : TEKNIK INFORMATIKA

PEMBIMBING I : Prof. Dr. Yuhandri, S.Kom., M.Kom

PEMBIMBING II : Devia kartika, S.Kom., M.Kom

Accurate tropical cyclone track prediction plays an important role in hydrometeorological disaster mitigation by providing reliable information on cyclone movement. This research used the International Best Track Archive for Climate Stewardship (IBTrACS) dataset covering the period from 1980 to 2025, which was divided into three scenarios: North Indian Ocean (NI), South Indian Ocean (SI), and a combined dataset (GAB). Track prediction was performed using a Long Short-Term Memory (LSTM) model with sliding window sizes of 8, 16, 24, and 32 timesteps. Model performance was assessed using Mean Absolute Error (MAE), Root Mean Square Error (RMSE), and Haversine Distance. Among the evaluated models, the GAB scenario with an 8-timestep sliding window was selected for deployment in the application, achieving an MAE of 0.127405, an RMSE of 0.144091, and a Mean Haversine Distance of 15.885 km. The findings also reveal that variations in basin characteristics and sliding window size influence prediction performance. Beyond evaluating model accuracy, this research provides a Streamlit-based visualization application that enables prediction results to be presented more intuitively, supporting tropical cyclone monitoring and disaster risk mitigation, particularly in West Sumatra, while offering a foundation for further studies on cyclone track prediction..

Keyword: Tropical cyclone trajectory prediction, Long Short-Term Memory (LSTM), IBTrACS, trajectory forecasting, Streamlit.

ABSTRAK

JUDUL SKRIPSI : PREDIKSI JALUR SIKLON TROPIS DI SAMUDRA HINDIA MENGGUNAKAN MODEL LONG SHORT-TERM MEMORY (LSTM) UNTUK MITIGASI RISIKO BENCANA DI SUMATERA BARAT

NAMA : IKHWAN RAMADHAN

NOBP : 22101152630411

FAKULTAS : ILMU KOMPUTER

JURUSAN : TEKNIK INFORMATIKA


PEMBIMBING I : Prof. Dr. Yuhandri, S.Kom., M.Kom

PEMBIMBING II : Devia kartika, S.Kom., M.Kom

Prediksi lintasan siklon tropis menjadi salah satu tantangan dalam mitigasi bencana hidrometeorologi karena memerlukan estimasi pergerakan yang akurat untuk mendukung pengambilan keputusan. Penelitian ini menggunakan data *International Best Track Archive for Climate Stewardship* (IBTrACS) periode 1980–2025 dengan tiga skenario *dataset*, yaitu *North Indian Ocean* (NI), *South Indian Ocean* (SI), dan Gabungan (GAB). Metode yang digunakan adalah *Long Short-Term Memory* (LSTM) dengan variasi *sliding window* 8, 16, 24, dan 32 *timesteps*, sedangkan evaluasi model dilakukan menggunakan *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *Haversine Distance*. Hasil penelitian menunjukkan bahwa model GAB dengan *sliding window* 8 *timesteps* dipilih sebagai model implementasi pada aplikasi dengan nilai MAE 0,127405, RMSE 0,144091, dan *Mean Haversine Distance* 15,885 km. Hasil penelitian juga menunjukkan bahwa perbedaan karakteristik *basin* dan variasi *sliding window* memengaruhi performa model LSTM dalam memprediksi lintasan siklon tropis. Penelitian ini bertujuan menghasilkan model prediksi yang dapat diimplementasikan pada aplikasi visualisasi berbasis Streamlit sebagai media pendukung mitigasi risiko bencana akibat siklon tropis, khususnya di wilayah Sumatera Barat. Selain itu, penelitian ini diharapkan dapat menyediakan informasi prediksi lintasan yang lebih mudah dipahami, membantu proses pemantauan pergerakan siklon tropis, serta menjadi referensi bagi pengembangan sistem prediksi lintasan siklon tropis pada penelitian selanjutnya.

Kata Kunci: Prediksi lintasan siklon tropis, *Long Short-Term Memory* (LSTM), IBTrACS, *sliding window*, *Haversine Distance*.

KATA PENGANTAR



Puji syukur ke hadirat Allah Swt. atas segala rahmat, karunia, dan hidayah-Nya sehingga penulis dapat menyelesaikan skripsi yang berjudul "**Prediksi Jalur Siklon Tropis di Samudra Hindia Menggunakan Model *Long Short-Term Memory* (LSTM) untuk Mitigasi Risiko Bencana di Sumatera Barat**". Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi Teknik Informatika.

Penyusunan skripsi ini tidak terlepas dari berbagai tantangan dan keterbatasan. Namun, berkat doa, bimbingan, dukungan, serta bantuan dari berbagai pihak, seluruh tahapan penelitian hingga penyusunan laporan dapat diselesaikan dengan baik. Oleh karena itu, pada kesempatan ini penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Bapak **H. Herman Nawas Rahimahullah** selaku Pendiri Yayasan Perguruan Tinggi Komputer (YPTK) Padang yang menaungi Universitas Putra Indonesia YPTK Padang.
2. Ibu **Dr. Hj. Zerni Melmusi, S.E, M.M, Ak, C.A** selaku Ketua Pembina Yayasan Perguruan Tinggi Komputer Padang
3. Ibu **Sitti Rizki Mulyani, S.Pd., MM** selaku ketua Yayasan Perguruan Tinggi Komputer "YPTK" Padang.
4. Bapak **Assoc. Prof. Dr. Muhammad Ridwan, SE., MM** selaku Rektor Universitas Putra Indonesia "YPTK" Padang.

5. Bapak **Prof. Dr. Yuhandri, S.Kom., M.Kom** selaku Wakil Rektor 1 Universitas Putra Indonesia “YPTK” Padang dan selaku Dosen Pembimbing 1 yang telah banyak memberikan pengetahuan dan arahan serta meluangkan waktunya selama penyusunan skripsi ini.
6. Ibu **Dr. Rini Sovia, S.Kom, M.Kom** selaku Dekan Fakultas Ilmu Komputer Universitas Putra Indonesia “YPTK” Padang
7. Bapak **Dr. Eka Praja Wiyata Mandala, S.Kom, M.Kom** selaku Ketua Program Studi Teknik Informatika Fakultas Ilmu Komputer Universitas Putra Indonesia YPTK Padang.
8. Ibu **Devia Kartika, S.Kom., M.Kom** selaku Dosen Pembimbing 2 saya yang telah memberikan bimbingan, pengetahuan dan arahan serta meluangkan waktunya selama penyusunan skripsi ini.
9. Seluruh **Bapak dan Ibu Dosen** yang telah mendidik dan memberikan berbagai disiplin ilmu kepada penulis selama menjadi mahasiswa di Fakultas Ilmu Komputer Universitas Putra Indonesia “YPTK” Padang.
10. **Segenap Karyawan dan Karyawati** di lingkungan Universitas Putra Indonesia “YPTK” Padang yang telah memberikan jasanya dalam penanganan administrasi akademik.
11. **National Oceanic and Atmospheric Administration (NOAA)** melalui *International Best Track Archive for Climate Stewardship (IBTrACS)* yang telah menyediakan data historis siklon tropis sebagai sumber data utama dalam penelitian ini.

Penulis juga menyampaikan rasa hormat dan terima kasih yang sebesar-besarnya kepada kedua orang tua tercinta yang senantiasa memberikan kasih

sayang, doa, dukungan, motivasi, serta kepercayaan kepada penulis dalam setiap proses penyelesaian studi. Berkat doa dan pengorbanan yang telah diberikan, penulis dapat menyelesaikan skripsi ini dengan penuh semangat dan tanggung jawab.

Akhir kata, penulis menyadari bahwa skripsi ini masih memiliki keterbatasan dan jauh dari sempurna. Oleh karena itu, kritik dan saran yang bersifat membangun sangat diharapkan demi penyempurnaan penelitian di masa mendatang. Penulis berharap skripsi ini dapat memberikan manfaat bagi pengembangan ilmu pengetahuan, khususnya pada bidang Data Science, kecerdasan buatan, dan prediksi lintasan siklon tropis, serta menjadi referensi bagi penelitian selanjutnya di Universitas Putra Indonesia "YPTK" Padang maupun bagi para pembaca.

Padang, Agustus 2026

IKHWAN RAMADHAN
22101152630411

DAFTAR ISI

LEMBAR PERNYATAAN	ii
LEMBAR PENGESAHAN SKRIPSI	iii
LEMBAR PENGESAHAN PENGUJI SIDANG SKRIPSI	iv
LEMBAR PENGESAHAN LULUS SIDANG SKRIPSI	v
ABSTRACT	vi
ABSTRAK	vii
KATA PENGANTAR.....	viii
DAFTAR ISI.....	xi
DAFTAR GAMBAR.....	xiv
DAFTAR TABEL	xvi
DAFTAR LAMPIRAN	xvii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	5
1.3 Hipotesis	6
1.4 Batasan Masalah.....	6
1.5 Tujuan Penelitian.....	7
1.6 Manfaat Penelitian.....	8
1.7 Tinjauan Perusahaan.....	9
1.7.1 Sejarah Singkat NOAA.....	9
1.7.2 Struktur Organisasi NOAA.....	10
1.7.3 Visi dan Misi NOAA	12
BAB II LANDASAN TEORI	13
2.1 <i>Artificial Intelligence</i>	13
2.2 Data Sains.....	14
2.3 <i>Machine Learning</i>	14
2.4 <i>Deep Learning</i>	16
2.4.1 Artificial Neural Network (ANN).....	17
2.4.2 Recurrent Neural Network (RNN).....	19
2.4.3 Model <i>Long Short-Term Memory</i> (LSTM).....	20
2.5 Siklon Tropis	28

2.5.1 Definisi dan Klasifikasi	28
2.5.2 Mekanisme Pembentukan dan Pergerakan Siklon.....	31
2.5.3 Karakteristik Jalur Siklon di Samudra Hindia	33
2.5.4 Dampak bagi Sumatera Barat	35
2.6 Prediksi Lintasan Siklon.....	36
2.6.1 Metode Prediksi Konvensional.....	37
2.6.2 Pendekatan <i>Deep Learning</i> untuk Prediksi Lintasan Siklon	40
2.7 Analisis Karakteristik Data Spasial dan Temporal.....	41
2.7.1 <i>Haversine Distance</i> (Jarak Geografis).....	41
2.7.2 Autokorelasi (<i>Autocorrelation Function/ACF</i>)	42
2.7.3 Arah Pergerakan (<i>Bearing</i>).....	43
2.7.4 Indeks Kelengkungan Lintasan (<i>Sinuosity Index</i>)	44
2.8 <i>Feature Engineering</i> Data Deret Waktu.....	45
2.8.1 Normalisasi <i>Z-Score</i> (dan alasan perlakuan terpisah)	46
2.8.2 Enkoding Siklus Musiman (<i>Cyclic Encoding / Sin-Cos Month</i>)	47
2.8.3 Fitur Turunan (<i>Derivative / Delta Features</i>)	48
2.9 Metrik Evaluasi	50
2.9.1 <i>Root Mean Squared Error</i> (RMSE) & <i>Mean Absolute Error</i> (MAE)..	50
2.9.2 <i>Haversine Distance Error</i> (Evaluasi Jarak Geografis).....	52
2.9.3 Koefisien Determinasi (R^2).....	53
2.9.4 Relevansi Metrik dalam Pemodelan Geospasial dan Validasi.....	54
2.10 Penelitian Terdahulu dan Gap Penelitian	55
2.11 Sistem Informasi Prediksi Lintasan Siklon Tropis.....	56
BAB III METODOLOGI PENELITIAN	59
3.1 Kerangka Penelitian	59
3.2 Jadwal Penelitian.....	60
3.3 Tahapan Penelitian	60
3.3.1 Penelitian Pendahuluan.....	61
3.3.2 Pengumpulan Data.....	62
3.3.3 Analisis	65
3.3.4 Perancangan	71
3.3.5 Implementasi.....	74
3.3.6 Pengujian	75
3.3.7 Kesimpulan	76

BAB IV ANALISA DAN PERANCANGAN	77
4.1 Analisa.....	77
4.1.1 Analisis Data.....	77
4.1.2 Analisis Proses.....	94
4.1.3 Analisis Sistem	113
4.2 Perancangan.....	116
4.2.1 Perancangan Model LSTM.....	117
4.2.2 Perancangan Aplikasi	119
BAB V IMPLEMENTASI DAN PENGUJIAN.....	141
5.1 Implementasi	141
5.1.1 Lingkungan Implementasi	141
5.1.2 Batasan Implementasi	144
5.2 Pengujian	145
5.2.1 Pengujian Halaman Beranda.....	145
5.2.2 Pengujian Halaman Dashboard Prediksi.....	146
5.2.3 Pengujian Halaman Prediksi Siklon	148
5.2.4 Pengujian Halaman Data Observasi	150
5.2.5 Pengujian Halaman Evaluasi Akurasi.....	152
5.2.6 Pengujian Halaman Tentang Model	154
BAB VI PENUTUP	156
6.1 Kesimpulan.....	156
6.2 Keterbatasan Sistem	157
6.3 Saran.....	158
DAFTAR PUSTAKA.....	160
LAMPIRAN.....	164

DAFTAR GAMBAR

Gambar 1.1 Struktur Organisasi NOAA	10
Gambar 2.1 Arsitektur Sel <i>Long Short-Term Memory</i> (LSTM)	24
Gambar 2.2 Anatomi siklon tropis	29
Gambar 3.1 Kerangka Penelitian	59
Gambar 3.2 Ringkasan Dataset	63
Gambar 3.3 Peta Wilayah Penelitian	64
Gambar 4.1 Ringkasan Dataset	80
Gambar 4.2 Distribusi Frekuensi <i>Latitude</i> dan <i>Longitude</i>	89
Gambar 4.3 Distribusi <i>WMO_WIND</i> dan <i>WMO_PRES</i>	90
Gambar 4.4 Distribusi Aktivitas Siklon Tropis Periode 1980–2025	91
Gambar 4.5 Proses Pelatihan Pemodelan	106
Gambar 4.6 Pengujian Performa Seluruh Skenario	108
Gambar 4.7 Perbandingan <i>Mean Haversine Distance</i> Seluruh Model	111
Gambar 4.8 Kinerja Model Gabungan (GAB)	112
Gambar 4.9 Diagram Pelatihan Model <i>Long Short-Term Memory</i> (LSTM)	118
Gambar 4.10 <i>Use Case</i> Diagram Prediksi Siklon	120
Gambar 4.11 <i>Activity</i> Diagram Prediksi Siklon	122
Gambar 4.12 Diagram Kelas Aplikasi Prediksi Siklon	123
Gambar 4.13 Sequence Diagram <i>Dashboard</i>	125
Gambar 4.14 Sequence Diagram Prediksi Siklon	126
Gambar 4.15 Sequence Diagram Data Siklon	127
Gambar 4.16 Sequence Diagram Evaluasi Akurasi	128
Gambar 4.17 <i>State Chart</i> Diagram Prediksi Siklon	129
Gambar 4.18 <i>Deployment</i> Diagram Prediksi Siklon	131
Gambar 4.19 Desain Tampilan Halaman Beranda	133
Gambar 4.20 Desain Tampilan Halaman <i>Dashboard</i>	134
Gambar 4.21 Desain Tampilan Halaman Prediksi Siklon	136
Gambar 4.22 Desain Tampilan Halaman Data Siklon	137
Gambar 4.23 Desain Tampilan Halaman Evaluasi	138
Gambar 4.24 Desain Halaman tentang	139
Gambar 5.1 Tampilan Halaman Beranda	145

Gambar 5.2 Halaman Dashboard Prediksi	146
Gambar 5.3 Tampilan Tabel Perbandingan Koordinat	148
Gambar 5.4 Halaman Prediksi Siklon.....	149
Gambar 5.5 Tampilan Cetak Laporan.....	150
Gambar 5.6 Halaman Data Observasi.....	151
Gambar 5.7 Halaman Evaluasi Akurasi	152
Gambar 5.8 Tampilan Tabel Evaluasi Akurasi	153
Gambar 5.9 Halaman Tentang	154

DAFTAR TABEL

Tabel 3.1 Jadwal Penelitian.....	60
Tabel 4.1 Karakteristik Sumber Data Penelitian.....	79
Tabel 4.2 Variabel Penelitian.....	81
Tabel 4.3 Karakteristik Data	82
Tabel 4.4 Karakteristik Umum Dataset Penelitian.....	84
Tabel 4.5 Karakteristik Temporal Dataset	84
Tabel 4.6 Karakteristik Spasial Dataset	85
Tabel 4.7 Uji <i>Kolmogorov-Smirnov</i> Distribusi <i>Bearing</i>	86
Tabel 4.8 Uji <i>Mann-Whitney U</i>	87
Tabel 4.9 Ringkasan Aktivitas Musiman Siklon Tropis	92
Tabel 4.10 Distribusi Data Train, Val, & Test.....	96
Tabel 4.11 Jumlah <i>Missing Value</i> pada Dataset.....	97
Tabel 4.12 Perbandingan Hasil Imputasi <i>Missing Value</i>	98
Tabel 4.13 Struktur Variabel Dataset Setelah Rekayasa Fitur	99
Tabel 4.14 Hasil Standardisasi Data Menggunakan <i>Standard Scaler</i>	101
Tabel 4.15 Pembentukan <i>Sliding Window</i>	102
Tabel 4.16 Konfigurasi Arsitektur Model LSTM	103
Tabel 4.17 Konfigurasi Pelatihan Model	104
Tabel 4.18 Uji Akurasi Model (R^2)	109
Tabel 5.1 Spesifikasi Perangkat Keras yang Digunakan	142
Tabel 5.2 Spesifikasi Perangkat Lunak dan <i>Library</i>	143

DAFTAR LAMPIRAN

CURICULUM VITAE.....	164
KARTU RENCANA STUDI (KRS)	165
BUKTI ACC JUDUL SKRIPSI.....	166
KARTU BIMBINGAN SKRIPSI DOSEN PEMBIMBING 1	167
KARTU BIMBINGAN SKRIPSI DOSEN PEMBIMBING 2	168

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pemanfaatan algoritma *Deep Learning* dalam rumpun ilmu data sains belakangan ini mendominasi ekosistem komputasi, terutama saat dihadapkan pada ekstraksi pola deret waktu (*time series*) yang berciri *non-linear*. Pada riset teknologi informasi yang bersinggungan dengan data spasio-temporal, rancangan rekayasa bertumpu penuh pada kapabilitas mesin dalam memetakan dependensi sekuensial dari koordinat pergerakan suatu objek. Masalahnya, runtunan titik spasial dalam dimensi waktu sering kali memiliki perilaku acak serta fluktuasi nilai yang ekstrem. Kondisi ini memperbesar derajat ketidakpastian hasil prediksi apabila model gagal menangkap memori jangka panjang dari riwayat trajektori fase sebelumnya. Oleh sebab itu, optimalisasi model saraf tiruan yang adaptif dalam mengekstrak representasi fitur spasial kini menjadi tantangan utama yang wajib dipecahkan di ranah komputasi.

Karakteristik data runtun waktu dengan tingkat kompleksitas spasial yang tinggi salah satunya ditemukan pada trajektori fenomena cuaca ekstrem di perairan terbuka. Data historis lintasan siklon tropis yang banyak digunakan dalam penelitian diperoleh dari *International Best Track Archive for Climate Stewardship* (IBTrACS), yaitu basis data yang menyediakan rekaman trajektori siklon tropis dan telah digunakan sebagai sumber data yang kredibel untuk kajian siklon tropis di Samudra Hindia Selatan (Tridaiana & Marzuki, 2023). Unikny, dataset untuk kawasan Samudra Hindia ini menyatukan dua sub-basin aktif dari belahan bumi

yang berbeda, yakni *North Indian* (NI) dan *South Indian* (SI). Penggabungan dua klaster data ini memicu kendala prapemrosesan (*preprocessing*) yang rumit akibat adanya asimetri spasial; gaya Coriolis mengakibatkan arah rotasi geometris badai di sisi utara ekuator bergerak berlawanan arah jarum jam, sedangkan di sisi selatan bergerak searah jarum jam. Jika data gabungan ini diumpankan langsung ke algoritma tanpa perlakuan prapemrosesan yang sesuai, perbedaan karakteristik pola pergerakan antar-basin berpotensi mempersulit model dalam mempelajari representasi pola lintasan secara optimal.

Beberapa peneliti terdahulu telah mencoba mengurai kompleksitas pergerakan spasio-temporal ini menggunakan berbagai pendekatan komputasi yang bervariasi. Evaluasi mengenai efisiensi beberapa arsitektur *Deep Learning* dalam melacak pergerakan trajektori sekuensial pernah dilakukan dengan membandingkan model LSTM, GRU, dan RNN konvensional yang berfokus khusus pada basin Samudra Hindia Utara (Rahman et al., 2025). Eksperimen tersebut membuktikan bahwa performa pemodelan sangat sensitif terhadap tahapan seleksi fitur serta generalisasi data, namun uji coba komputasi mereka belum melibatkan skenario penggabungan lintas basin yang memiliki arah rotasi berlawanan. Di sisi lain, tantangan fisis yang memengaruhi pola pergerakan di wilayah Samudra Hindia dipetakan melalui pemodelan atmosfer global yang menemukan bahwa struktur topografi pegunungan tinggi di pulau Sumatra memicu efek hambatan mekanis yang nyata. Hambatan tersebut membelokkan jalur sekuensial secara tajam hingga membentuk fenomena pusaran ganda di sekitar ekuator. Berangkat dari adanya anomali pembelokan fisis tersebut, pengujian model LSTM kemudian dikembangkan untuk memprediksi parameter dampak dari siklon

tropis yang memasuki wilayah perairan Indonesia (Siswono et al., 2023). Hasil komparasi menunjukkan bahwa arsitektur jaringan saraf yang memiliki gerbang penyimpanan memori terbukti jauh lebih superior dalam menangani fluktuasi data ekstrem di Indonesia dibandingkan metode tren tradisional seperti *Holt-Winters*.

Meskipun model LSTM telah teruji unggul dalam menangani data ekstrem, integrasi dataset gabungan berskala global antara basin NI dan SI dari database NOAA memunculkan celah (*gap*) penelitian baru pada tahapan *preprocessing*. Masalah utamanya terletak pada dilema optimasi ukuran jendela waktu (*lookback window* atau *timesteps*) saat membentuk struktur data *supervised learning* lewat teknik *sliding window*. Pengaturan *timesteps* yang terlalu pendek dapat menyebabkan model kehilangan sebagian informasi temporal dari pergerakan sebelumnya sehingga pola perubahan arah lintasan tidak dapat direpresentasikan secara optimal. Di sisi lain, konfigurasi *timesteps* yang terlampau panjang berisiko membengkakkan dimensi matriks input secara eksponensial, memperlambat waktu komputasi perangkat keras, serta memicu akumulasi galat (*error compounding*) pada prediksi multi-langkah ke depan. Untuk mengevaluasi bagaimana karakteristik data lintasan siklon memengaruhi proses pembelajaran model, penelitian ini juga menguji beberapa konfigurasi *timesteps* sebagai representasi panjang memori temporal yang digunakan dalam pembentukan data runtun waktu.

Selain aspek akurasi model, hasil penelitian prediksi berbasis kecerdasan buatan sering kali hanya disajikan dalam bentuk nilai evaluasi numerik sehingga kurang memberikan gambaran spasial yang mudah dipahami oleh pengguna. Pada konteks prediksi jalur siklon tropis, penyajian hasil dalam bentuk visualisasi lintasan menjadi penting karena dapat membantu interpretasi arah pergerakan

siklon secara lebih intuitif. Oleh karena itu, penelitian ini tidak hanya mengembangkan model *Long Short-Term Memory* (LSTM) untuk memprediksi koordinat lintasan siklon, tetapi juga mengintegrasikan model terbaik ke dalam aplikasi web berbasis dashboard interaktif yang mampu menampilkan hasil prediksi secara visual pada peta digital.

Berdasarkan permasalahan pengolahan data lintasan siklon, karakteristik data gabungan lintas basin, kebutuhan analisis representasi temporal pada data sekuensial, serta pentingnya penyajian hasil prediksi yang mudah diinterpretasikan, penelitian ini dilakukan untuk mengkaji karakteristik data siklon tropis pada basin *North Indian* (NI) dan *South Indian* (SI) serta menganalisis dampaknya terhadap kinerja model *Long Short-Term Memory* (LSTM) dalam mempelajari pola pergerakan lintasan siklon tropis.

Model Long Short-Term Memory (LSTM) dipilih karena memiliki mekanisme memori melalui struktur *gate* yang mampu mempertahankan informasi historis dalam data runtun waktu serta efektif dalam mempelajari ketergantungan temporal jangka panjang pada data sekuensial (Hochreiter & Schmidhuber, 1997; Hao et al., 2024). Melalui pendekatan tersebut, penelitian ini mengevaluasi kemampuan model dalam memprediksi koordinat lintasan siklon tropis di Samudra Hindia berdasarkan pola pergerakan historis yang terekam pada dataset IBTrACS.

Hasil penelitian diharapkan dapat memberikan kontribusi terhadap pengembangan metode prediksi lintasan siklon berbasis *Deep Learning*, khususnya dalam memahami pengaruh heterogenitas karakteristik data antar-basin terhadap proses pembelajaran model. Selain itu, model terbaik yang diperoleh akan diintegrasikan ke dalam dashboard interaktif untuk memvisualisasikan hasil

prediksi lintasan siklon secara spasial. Oleh karena itu, penelitian ini disusun dalam bentuk skripsi dengan judul "**Prediksi Jalur Siklon Tropis di Samudra Hindia Menggunakan Model Long Short-Term Memory (LSTM)**".

1.2 Rumusan Masalah

Penggabungan data koordinat dari dua basin yang memiliki karakteristik lintasan berbeda berpotensi memengaruhi kemampuan model dalam mempelajari pola pergerakan siklon tropis. Selain itu, variasi ukuran *timesteps* pada pembentukan data runtun waktu diperkirakan turut memengaruhi hasil prediksi model. Berdasarkan permasalahan tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana kinerja model *Long Short-Term Memory* (LSTM) dalam memprediksi lintasan siklon tropis menggunakan data IBTrACS pada basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI)?
2. Bagaimana pengaruh perbedaan karakteristik statistik, temporal, dan spasial antara basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI), serta variasi ukuran *timesteps*, terhadap kemampuan model *Long Short-Term Memory* (LSTM) dalam memprediksi lintasan siklon tropis?
3. Bagaimana merancang dan mengimplementasikan antarmuka visualisasi berbasis Python menggunakan framework Streamlit untuk menampilkan hasil prediksi koordinat model *Long Short-Term Memory* (LSTM) dalam bentuk peta digital interaktif?

1.3 Hipotesis

Dugaan awal penelitian ini didasarkan pada asumsi bahwa karakteristik data lintasan siklon tropis dan representasi data runtun waktu memengaruhi kemampuan model *Long Short-Term Memory* (LSTM) dalam mempelajari pola pergerakan siklon. Berdasarkan rumusan masalah yang telah ditetapkan, hipotesis penelitian dirumuskan sebagai berikut.

1. Diharapkan model *Long Short-Term Memory* (LSTM) mampu memprediksi lintasan siklon tropis menggunakan data IBTrACS pada basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI) dengan tingkat akurasi yang baik.
2. Diharapkan perbedaan karakteristik statistik, temporal, dan spasial antara basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI), serta variasi ukuran *timesteps*, memengaruhi kemampuan model *Long Short-Term Memory* (LSTM) dalam mempelajari pola lintasan sehingga menghasilkan perbedaan hasil prediksi koordinat siklon tropis.
3. Diharapkan implementasi model *Long Short-Term Memory* (LSTM) ke dalam antarmuka visualisasi berbasis web menggunakan framework Streamlit mampu menampilkan hasil prediksi koordinat lintasan siklon tropis dalam bentuk peta digital interaktif secara otomatis.

1.4 Batasan Masalah

Penelitian ini dibatasi agar pembahasan tetap terfokus pada tujuan penelitian dan ruang lingkup yang telah ditetapkan. Adapun batasan masalah dalam penelitian ini adalah sebagai berikut.

1. Penelitian menggunakan data lintasan siklon tropis dari dataset IBTrACS yang mencakup basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI)

sebagai data masukan untuk membangun dan mengevaluasi model *Long Short-Term Memory* (LSTM).

2. Analisis dibatasi pada pengaruh perbedaan karakteristik statistik, temporal, dan spasial antara basin NI dan SI, serta variasi ukuran *timesteps* dalam pembentukan data runtun waktu (*sliding window*) terhadap proses pembelajaran model *Long Short-Term Memory* (LSTM).
3. Implementasi sistem dibatasi pada pengembangan antarmuka visualisasi berbasis Python menggunakan framework Streamlit untuk menampilkan hasil prediksi koordinat lintasan siklon tropis dalam bentuk peta digital interaktif.

1.5 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan, penelitian ini bertujuan untuk menganalisis kinerja model *Long Short-Term Memory* (LSTM) dalam memprediksi lintasan siklon tropis, mengkaji pengaruh karakteristik data dan variasi ukuran *timesteps* terhadap kemampuan prediksi model, serta mengimplementasikan hasil prediksi ke dalam aplikasi visualisasi berbasis web. Adapun tujuan penelitian ini adalah sebagai berikut.

1. Menganalisis kinerja model *Long Short-Term Memory* (LSTM) dalam memprediksi lintasan siklon tropis menggunakan data IBTrACS pada basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI).
2. Menganalisis pengaruh perbedaan karakteristik statistik, temporal, dan spasial antara basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI), serta variasi ukuran *timesteps* pada teknik *sliding window*, terhadap

kemampuan model *Long Short-Term Memory* (LSTM) dalam memprediksi lintasan siklon tropis.

3. Merancang dan mengimplementasikan aplikasi visualisasi berbasis Python menggunakan framework Streamlit untuk menampilkan hasil prediksi koordinat lintasan siklon tropis dalam bentuk peta digital interaktif.

1.6 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat yang selaras dengan tujuan dan ruang lingkup penelitian. Adapun manfaat yang diharapkan adalah sebagai berikut.

1. Memberikan informasi mengenai kinerja model *Long Short-Term Memory* (LSTM) dalam memprediksi lintasan siklon tropis menggunakan data IBTrACS pada basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI), sehingga dapat menjadi referensi dalam pengembangan model prediksi lintasan siklon tropis.
2. Memberikan pemahaman mengenai pengaruh perbedaan karakteristik statistik, temporal, dan spasial antara basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI), serta variasi ukuran *timesteps* pada teknik *sliding window*, terhadap kemampuan model *Long Short-Term Memory* (LSTM) dalam mempelajari pola lintasan siklon tropis.
3. Menghasilkan aplikasi visualisasi berbasis Python menggunakan framework Streamlit yang dapat digunakan untuk menampilkan hasil prediksi koordinat lintasan siklon tropis dalam bentuk peta digital interaktif sehingga memudahkan penyajian dan interpretasi hasil prediksi.

1.7 Tinjauan Perusahaan

Gambaran umum instansi dalam penelitian ini diperoleh melalui pengumpulan data menggunakan metode studi literatur, dokumentasi resmi, serta eksplorasi repositori data spasial terbuka. Seluruh informasi yang didapatkan tersebut termasuk ke dalam data sekunder yang valid. Pada bagian ini, penulis akan memaparkan profil instansi yang menjadi objek penyedia data utama penelitian, yang mencakup sejarah singkat instansi, struktur organisasi beserta pembagian tugas dan wewenang, serta visi dan misi instansi.

1.7.1 Sejarah Singkat NOAA


National Oceanic and Atmospheric Administration (NOAA) merupakan lembaga ilmiah dan agen regulasi federal di bawah Departemen Perdagangan Amerika Serikat (*United States Department of Commerce*) yang berfokus pada pemantauan kondisi samudra, cuaca, iklim, dan atmosfer bumi. NOAA secara resmi dibentuk pada tanggal 3 Oktober 1970 oleh Presiden Richard Nixon dengan tujuan untuk menyatukan berbagai fungsi ilmiah kedirgantaraan dan kelautan federal ke dalam satu atap koordinasi. Lembaga ini hadir sebagai solusi global dalam memetakan perubahan lingkungan, mengelola sumber daya pesisir dan laut, serta menyediakan data prediktif cuaca ekstrem demi keselamatan publik internasional.

Salah satu kontribusi krusial NOAA dalam dunia data sains meteorologi adalah penyediaan dataset *International Best Track Archive for Climate Stewardship* (IBTrACS) versi 4r01 yang dikelola oleh divisi arsip iklim globalnya. Data sekuensial historis yang mencakup rekaman koordinat lintasan, tekanan udara minimum, dan kecepatan angin maksimum siklon tropis dari tahun 1980 hingga 2025 inilah yang diekstraksi dan dimanfaatkan sepenuhnya sebagai basis

pemodelan komputasi dalam penelitian skripsi ini.

1.7.2 Struktur Organisasi NOAA

Struktur organisasi ini berfungsi sebagai representasi visual mengenai pembagian peran, wewenang, dan tanggung jawab, serta koordinasi antar-divisi ilmiah di dalam NOAA *Headquarters*. Adanya struktur organisasi memungkinkan integrasi pengelolaan data satelit, riset atmosfer, dan operasional prediksi cuaca berjalan secara efisien. Struktur organisasi NOAA dapat dilihat pada Gambar 1.1.



Gambar 1.1 Struktur Organisasi NOAA

Berdasarkan Gambar 1.1, dapat dijelaskan pembagian tugas dan wewenang dari struktur organisasi tingkat kantor lini (*Line Offices*) yang berkaitan langsung dengan pemrosesan data sains dalam penelitian ini sebagai berikut:

1 *National Environmental Satellite, Data, and Information Service* (NESDIS)

NESDIS bertanggung jawab penuh atas operasional konstelasi satelit

lingkungan milik pemerintah Amerika Serikat serta pengelolaan arsip data geosains terbesar di dunia. Divisi ini memiliki wewenang untuk mengumpulkan, memproses, dan mendistribusikan data mentah satelit iklim global menjadi informasi siap pakai, termasuk memproduksi dataset track siklon historis (IBTrACS) yang menjadi objek data utama dalam penelitian ini.

- 2 *National Weather Service* (NWS) :NWS bertugas menyediakan prakiraan cuaca, kondisi hidrologi, serta peringatan iklim ekstrem global untuk perlindungan jiwa dan harta benda. Divisi ini berwenang melakukan analisis meteorologi taktis, memvalidasi pergerakan siklon tropis secara *real-time*, serta bekerja sama dengan NESDIS dalam menyinkronkan pemodelan data cuaca sekuensial.
- 3 *Oceanic and Atmospheric Research* (OAR) :OAR atau *NOAA Research* bertanggung jawab melaksanakan penelitian ilmiah mutakhir guna memahami sistem bumi secara utuh. Divisi ini memiliki wewenang untuk mengevaluasi model-model kecerdasan buatan dan algoritma prediktif baru sebelum diimplementasikan pada sistem operasional pemantauan cuaca global.
- 4 *Office of Marine and Aviation Operations* (OMAO) :OMAO bertanggung jawab mengoperasikan armada kapal riset dan pesawat terbang pemburu badai (*NOAA Hurricane Hunters*). Divisi ini berwenang mengumpulkan data meteorologi langsung (*in-situ*) dari dalam mata siklon tropis untuk kemudian diserahkan kepada NESDIS sebagai elemen validasi data fisik lapangan.

1.7.3 Visi dan Misi NOAA

Visi didefinisikan sebagai aspirasi atau cita-cita fundamental jangka panjang yang menjadi tujuan utama organisasi dalam skala global. Sementara itu, misi merujuk pada serangkaian tindakan dan strategi operasional yang akan diimplementasikan untuk mewujudkan visi tersebut. Visi dan misi NOAA dalam menjalankan keberlanjutan fungsi riset dan pemantauan lingkungan dijabarkan sebagai berikut:

- 1 Visi NOAA Mewujudkan masyarakat yang tangguh dalam menghadapi perubahan cuaca, air, dan iklim dengan landasan pemahaman ilmiah yang komprehensif terhadap dinamika samudra dan atmosfer.
- 2 Misi NOAA menggambarkan langkah nyata yang dilakukan oleh instansi untuk mencapai visi. Adapun misi yang dijalankan oleh NOAA adalah sebagai berikut:
 - a. Memahami dan memprediksi perubahan pada lingkungan bumi, mulai dari laut dalam hingga ruang angkasa.
 - b. Mengelola, melindungi, dan melestarikan sumber daya pesisir dan laut secara berkelanjutan.
 - c. Menyediakan data spasial dan informasi iklim terbuka yang akurat untuk mendukung riset sains data dan mitigasi kebencanaan global.

BAB II

LANDASAN TEORI

2.1 Artificial Intelligence

Artificial Intelligence (AI) merupakan cabang ilmu komputer yang berfokus pada pengembangan sistem komputasi agar mampu menjalankan tugas yang umumnya memerlukan kecerdasan manusia, seperti mengenali pola, melakukan penalaran, memecahkan masalah, serta mengambil keputusan berdasarkan data yang tersedia (Goh et al., 2021). Kemampuan tersebut diperoleh melalui penerapan berbagai algoritma yang memungkinkan sistem mempelajari hubungan antarvariabel dan menghasilkan prediksi atau keputusan secara otomatis tanpa bergantung pada aturan yang ditentukan secara eksplisit.

Perkembangan AI telah mendorong pemanfaatannya pada berbagai bidang, termasuk kesehatan, transportasi, keuangan, serta ilmu kebumihan. Dalam bidang meteorologi, AI dimanfaatkan untuk mendukung analisis data atmosfer yang memiliki karakteristik kompleks, berdimensi tinggi, dan terus berubah terhadap waktu. Kemampuan tersebut memungkinkan sistem mengidentifikasi pola yang sulit dikenali melalui pendekatan konvensional sehingga meningkatkan kualitas analisis maupun prediksi fenomena cuaca ekstrem (Shi et al., 2025).

Penerapan AI dalam prediksi lintasan siklon tropis terus berkembang seiring meningkatnya ketersediaan data observasi dan kemajuan metode komputasi. Model berbasis AI mampu memanfaatkan data historis untuk mempelajari hubungan spasial dan temporal yang memengaruhi pergerakan siklon, sehingga menghasilkan prediksi yang lebih adaptif terhadap perubahan pola lintasan dibandingkan

pendekatan berbasis aturan fisik semata (Rahman et al., 2024).

AI mencakup berbagai pendekatan komputasi dengan tingkat kompleksitas yang berbeda. Salah satu pendekatan yang berkembang pesat adalah *Machine Learning*, yaitu metode yang memungkinkan sistem membangun model secara otomatis berdasarkan pola yang dipelajari dari data. Pendekatan ini menjadi fondasi bagi pengembangan berbagai metode prediksi modern, termasuk model *Deep Learning* yang digunakan dalam penelitian ini.

2.2 Data Sains

Data sains merupakan bidang interdisipliner yang berfokus pada pengolahan data untuk menghasilkan informasi dan pengetahuan bernilai. Bidang ini mengintegrasikan statistika, ilmu komputer, serta pengetahuan domain guna mendukung proses analisis dan pengambilan keputusan berbasis data (Alvarado & Zhang, 2023). Penerapan data sains mencakup serangkaian tahapan, mulai dari pengumpulan data, prapemrosesan, eksplorasi data, pengembangan model, hingga evaluasi dan interpretasi hasil analisis (Ogu et al., 2026). Pada penelitian ini, pendekatan data sains digunakan untuk mengolah data historis lintasan siklon tropis sebagai dasar pengembangan model prediksi menggunakan *Long Short-Term Memory* (LSTM) (Yeasin et al., 2024).

2.3 Machine Learning

Machine Learning merupakan salah satu cabang dari *Artificial Intelligence* (AI) yang berfokus pada pengembangan algoritma agar sistem mampu mempelajari pola dari data dan meningkatkan kinerjanya melalui pengalaman tanpa memerlukan aturan yang dirancang secara eksplisit untuk setiap permasalahan (Goh et al., 2021). Pendekatan ini memanfaatkan data sebagai sumber utama pembelajaran sehingga

model dapat mengenali hubungan antarvariabel, membentuk representasi pola, kemudian menghasilkan prediksi atau keputusan terhadap data baru.

Berdasarkan proses pembelajarannya, *Machine Learning* secara umum dikelompokkan menjadi tiga pendekatan utama, yaitu *supervised learning*, *unsupervised learning*, dan *reinforcement learning*. *Supervised learning* menggunakan data yang telah memiliki label sebagai acuan selama proses pelatihan sehingga model mempelajari hubungan antara variabel masukan dan keluaran. *Unsupervised learning* bertujuan menemukan pola atau struktur tersembunyi pada data tanpa label, sedangkan *reinforcement learning* mengembangkan kebijakan pengambilan keputusan melalui mekanisme penghargaan (*reward*) dan hukuman (*penalty*) berdasarkan interaksi dengan lingkungan (Ogu et al., 2026).

Dalam bidang meteorologi, pendekatan *Machine Learning* telah banyak dimanfaatkan untuk mendukung berbagai tugas prediksi, seperti prakiraan curah hujan, estimasi kualitas udara, identifikasi cuaca ekstrem, serta prediksi lintasan dan intensitas siklon tropis. Kemampuan model dalam mempelajari hubungan nonlinier dari data observasi memungkinkan peningkatan akurasi prediksi, terutama ketika dihadapkan pada fenomena atmosfer yang memiliki dinamika kompleks dan dipengaruhi oleh banyak faktor (Yeasin et al., 2024; Shi et al., 2025).

Seiring meningkatnya jumlah data dan kompleksitas permasalahan, berbagai metode *Machine Learning* terus berkembang menuju pendekatan yang mampu mempelajari representasi data secara lebih mendalam. Salah satu perkembangan tersebut adalah *Deep Learning*, yaitu pendekatan yang menggunakan jaringan saraf tiruan dengan banyak lapisan (*multi-layer neural networks*) untuk mengekstraksi pola dan karakteristik data secara otomatis.

2.4 Deep Learning

Deep Learning merupakan salah satu pendekatan dalam *Machine Learning* yang memanfaatkan jaringan saraf tiruan (*artificial neural networks*) dengan banyak lapisan tersembunyi (*hidden layers*) untuk mempelajari representasi data secara bertingkat. Berbeda dengan metode *Machine Learning* konvensional yang umumnya memerlukan proses ekstraksi fitur secara manual, *Deep Learning* mampu melakukan pembelajaran fitur secara otomatis langsung dari data mentah. Kemampuan tersebut menjadikan *Deep Learning* efektif dalam menangani permasalahan dengan hubungan nonlinier yang kompleks serta data berdimensi tinggi (Hao et al., 2024).

Perkembangan *Deep Learning* didukung oleh peningkatan kapasitas komputasi, ketersediaan data dalam jumlah besar, serta kemajuan algoritma optimasi yang memungkinkan proses pelatihan model berlangsung lebih efisien. Berbagai arsitektur telah dikembangkan untuk menyesuaikan karakteristik data dan tujuan analisis, seperti *Convolutional Neural Network* (CNN) untuk data citra, *Recurrent Neural Network* (RNN) untuk data sekuensial, serta *Transformer* yang banyak digunakan pada pemodelan bahasa alami dan peramalan deret waktu (Kong et al., 2024).

Dalam bidang meteorologi, *Deep Learning* telah dimanfaatkan untuk berbagai kebutuhan prediksi, antara lain prakiraan cuaca, estimasi kualitas udara, prediksi curah hujan, hingga prediksi lintasan siklon tropis. Kemampuan model dalam mempelajari hubungan spasial dan temporal secara simultan memungkinkan peningkatan akurasi prediksi dibandingkan pendekatan konvensional, terutama ketika dihadapkan pada dinamika atmosfer yang kompleks dan bersifat nonlinier

(Shi et al., 2025; Ogu et al., 2026). Sejumlah penelitian juga menunjukkan bahwa model berbasis *Deep Learning* mampu menghasilkan prediksi lintasan siklon tropis yang lebih adaptif terhadap perubahan pola pergerakan berdasarkan data historis dibandingkan metode statistik maupun model pembelajaran mesin konvensional (Rahman et al., 2025; Awada et al., 2024).

Penelitian ini menerapkan pendekatan *Deep Learning* karena karakteristik data lintasan siklon tropis merupakan data deret waktu yang memiliki ketergantungan temporal antarpengamatan. Hubungan tersebut memerlukan model yang mampu mempertahankan informasi dari langkah waktu sebelumnya sehingga pola pergerakan siklon dapat dipelajari secara lebih efektif. Salah satu arsitektur yang dirancang untuk memenuhi kebutuhan tersebut adalah *Recurrent Neural Network* (RNN), yang kemudian dikembangkan menjadi *Long Short-Term Memory* (LSTM) untuk mengatasi keterbatasan dalam pembelajaran dependensi jangka panjang. Oleh karena itu, pembahasan selanjutnya difokuskan pada arsitektur RNN sebagai dasar pengembangan model LSTM yang digunakan dalam penelitian ini.

2.4.1 Artificial Neural Network (ANN)

Artificial Neural Network (ANN) merupakan arsitektur dasar dalam *Deep Learning* yang dirancang untuk meniru mekanisme pemrosesan informasi pada jaringan saraf biologis. Model ini tersusun atas sekumpulan neuron buatan yang saling terhubung melalui bobot (*weights*) dan bias (*biases*) untuk membentuk hubungan antara data masukan dan keluaran. Selama proses pelatihan, nilai bobot diperbarui secara iteratif menggunakan algoritma optimasi sehingga model mampu mempelajari pola yang terdapat pada data dan akurasi prediksi (Hao et al., 2024).

Secara umum, ANN terdiri atas tiga komponen utama, yaitu *input layer*,

hidden layer, dan *output layer*. *Input layer* berfungsi menerima data masukan, *hidden layer* melakukan proses transformasi dan pembelajaran terhadap pola yang terkandung dalam data, sedangkan *output layer* menghasilkan keluaran sesuai dengan tujuan pemodelan. Banyaknya *hidden layer* dan jumlah neuron pada setiap lapisan memengaruhi kemampuan model dalam merepresentasikan hubungan yang kompleks, terutama pada permasalahan yang memiliki karakteristik nonlinier (Yunita et al., 2025).

Pada setiap neuron, data masukan dikombinasikan melalui proses perkalian dengan bobot, kemudian ditambahkan bias sebelum diteruskan ke fungsi aktivasi. Fungsi aktivasi berperan menghasilkan keluaran nonlinier sehingga jaringan mampu mempelajari hubungan yang tidak dapat direpresentasikan menggunakan model linear. Beberapa fungsi aktivasi yang umum digunakan antara lain *Rectified Linear Unit* (ReLU), *Sigmoid*, dan *Hyperbolic Tangent* (Tanh), dengan pemilihan fungsi bergantung pada karakteristik data dan tujuan pemodelan (Al Selwi et al., 2025).

Meskipun ANN mampu memberikan kinerja yang baik pada berbagai permasalahan klasifikasi maupun regresi, arsitektur ini mengasumsikan setiap data bersifat independen sehingga tidak mempertimbangkan hubungan antarurutan pengamatan. Kondisi tersebut menjadi keterbatasan ketika ANN diterapkan pada data deret waktu yang memiliki ketergantungan temporal, seperti data lintasan siklon tropis. Akibatnya, informasi yang diperoleh pada waktu sebelumnya tidak dapat dimanfaatkan secara optimal untuk memprediksi kondisi pada waktu berikutnya (Kong et al., 2024).

Berkembangnya kebutuhan untuk memodelkan data sekuensial mendorong pengembangan arsitektur jaringan saraf yang mampu mempertahankan informasi dari pengamatan sebelumnya. Salah satu pengembangan tersebut adalah *Recurrent Neural Network* (RNN), yang dirancang untuk memanfaatkan ketergantungan temporal antarwaktu sehingga lebih sesuai digunakan dalam pemodelan data deret waktu. Oleh karena itu, pembahasan selanjutnya difokuskan pada konsep dan mekanisme kerja *Recurrent Neural Network* sebagai dasar pengembangan model *Long Short-Term Memory* (LSTM) yang digunakan dalam penelitian ini.

2.4.2 Recurrent Neural Network (RNN)

Recurrent Neural Network (RNN) merupakan pengembangan dari *Artificial Neural Network* (ANN) yang dirancang untuk memproses data sekuensial dengan memanfaatkan informasi dari pengamatan sebelumnya. Berbeda dengan ANN yang memperlakukan setiap data sebagai masukan yang saling independen, RNN memiliki mekanisme umpan balik (*feedback*) melalui *hidden state* sehingga informasi pada setiap time step dapat diteruskan ke proses berikutnya. Kemampuan tersebut menjadikan RNN sesuai untuk memodelkan data deret waktu yang memiliki ketergantungan temporal, seperti data meteorologi dan lintasan siklon tropis (Hao et al., 2024).

Dalam proses pembelajaran, RNN memanfaatkan data masukan pada waktu saat ini dan informasi dari *hidden state* sebelumnya untuk menghasilkan keluaran. ini memungkinkan model mempelajari hubungan urutan data sehingga pola temporal dapat direpresentasikan lebih baik dibandingkan jaringan saraf konvensional. Oleh karena itu, RNN banyak diterapkan pada berbagai permasalahan prediksi deret waktu, termasuk prediksi lintasan siklon tropis.

Meskipun demikian, RNN memiliki keterbatasan dalam mempelajari ketergantungan jangka panjang akibat permasalahan *vanishing gradient* dan *exploding gradient*. Kondisi tersebut menyebabkan informasi dari pengamatan yang lebih awal sulit dipertahankan ketika urutan data semakin panjang. Untuk mengatasi keterbatasan tersebut, dikembangkan arsitektur *Long Short-Term Memory* (LSTM) yang dilengkapi mekanisme gerbang (*gate mechanism*) dan cell state sehingga mampu mempertahankan informasi penting selama proses pembelajaran (Kong et al., 2024; Yunita et al., 2025).

2.4.3 Model *Long Short-Term Memory* (LSTM)

Long Short-Term Memory (LSTM) merupakan pengembangan dari Recurrent Neural Network (RNN) yang dirancang untuk mengatasi keterbatasan utama RNN konvensional dalam mempelajari ketergantungan jangka panjang pada data sekuensial. Permasalahan tersebut muncul akibat fenomena *vanishing gradient* dan *exploding gradient* yang menyebabkan proses pembelajaran menjadi tidak stabil ketika panjang urutan data semakin besar. Untuk mengatasi kendala tersebut, LSTM memperkenalkan struktur *memory cell* yang dilengkapi dengan tiga mekanisme gerbang adaptif, yaitu *forget gate*, *input gate*, dan *output gate*. Ketiga gerbang ini memungkinkan model menyimpan, memperbarui, maupun menghapus informasi secara selektif sehingga ketergantungan temporal jangka panjang dapat dipertahankan dengan lebih efektif (Kong et al., 2024).

Kemampuan LSTM dalam memodelkan hubungan non-linear serta menangkap ketergantungan temporal menjadikannya salah satu arsitektur yang paling banyak digunakan pada berbagai tugas *time series forecasting*, seperti prakiraan cuaca, konsumsi energi, dan prediksi data keuangan. Berbagai penelitian

komparatif juga menunjukkan bahwa LSTM dan beberapa varian hibridanya, seperti LSTM-GRU dan LSTM-RNN, mampu memberikan akurasi dan stabilitas prediksi yang lebih baik dibandingkan sejumlah arsitektur jaringan saraf lainnya. Meskipun model berbasis *Transformer* dan *Multi Layer Perceptron* (MLP) mulai menunjukkan performa yang sangat kompetitif, LSTM tetap menawarkan keseimbangan yang baik antara akurasi, kompleksitas komputasi, dan kemudahan interpretasi karena memiliki kebutuhan waktu komputasi serta memori yang relatif lebih rendah dengan aliran informasi temporal yang lebih jelas (Yunita et al., 2025).

Perkembangan penelitian selanjutnya menghasilkan berbagai modifikasi arsitektur LSTM untuk meningkatkan efisiensi maupun kemampuan representasi model. Beberapa di antaranya adalah sLSTM yang menggunakan mekanisme *exponential gating* dan *memory mixing* untuk memperbaiki proses pengelolaan memori secara dinamis, serta NOA-LSTM yang menyederhanakan struktur sel sehingga waktu pelatihan dapat dipersingkat tanpa menurunkan akurasi prediksi. Meskipun demikian, arsitektur *stacked LSTM* dua lapis masih menjadi pendekatan yang banyak digunakan karena mampu memberikan keseimbangan antara kompleksitas model, kemampuan generalisasi, dan kemudahan implementasi, khususnya pada pemodelan data spasio-temporal yang kompleks seperti prediksi lintasan siklon tropis. Untuk memahami mekanisme kerja LSTM secara lebih mendasar, subbab berikutnya akan membahas terlebih dahulu arsitektur Recurrent Neural Network (RNN) sebagai dasar pengembangan LSTM beserta keterbatasan yang melatarbelakangi lahirnya arsitektur tersebut (Yadav & Thakkar, 2023; Kong et al., 2024).

2.4.3.1 Arsitektur LSTM

Recurrent Neural Network (RNN) merupakan kelas arsitektur jaringan syaraf tiruan yang dibangun secara spesifik untuk menangani data sekuensial. Tidak seperti jaringan *feedforward* konvensional yang memperlakukan setiap masukan sebagai entitas independen, RNN menyimpan keadaan tersembunyi (*hidden state*) yang terus diperbarui setiap kali elemen sekuens baru masuk. Keadaan tersembunyi ini berperan sebagai memori jangka pendek yang memungkinkan informasi dari langkah waktu sebelumnya memengaruhi pemrosesan pada langkah waktu berikutnya.

Secara formal, pada setiap langkah waktu t , RNN menerima vektor masukan x_t dan keadaan tersembunyi sebelumnya h_{t-1} . Jaringan kemudian memperbarui keadaan tersembunyi melalui transformasi nonlinier yang diparameterisasi bersama di seluruh langkah waktu (*weight sharing*). Proses tersebut dapat dituliskan sebagai:

$$h_t = \sigma (W_{hh} h_{t-1} + W_{xh} x_t + b_h) \quad (2.1)$$

Keterangan :

h_t = Hidden state pada waktu t .

h_{t-1} = Hidden state pada waktu $t-1$.

x_t = Input pada waktu t .

W_{hh} = Bobot dari hidden ke hidden.

W_{xh} = Bobot dari input ke hidden.

b_h = Bias hidden.

σ = Fungsi aktivasi hidden.

dengan $\sigma(\cdot)$ merupakan fungsi aktivasi nonlinier, biasanya tangen hiperbolik (*tanh*) atau fungsi sigmoid. Selanjutnya, keluaran pada langkah waktu t dihitung

dari keadaan tersembunyi h_t melalui transformasi linear dan fungsi aktivasi yang disesuaikan dengan tugas (misalnya identitas untuk regresi):

$$y_t = \phi (W_{hy}h_t + b_y) \quad (2.2)$$

Keterangan :

y_t = Output pada waktu t .

h_t = Hidden state pada waktu t .

W_{hy} = Bobot dari hidden ke output.

b_y = Bias output.


ϕ = Fungsi aktivasi output.

Untuk mengatasi keterbatasan tersebut, dikembangkan arsitektur *Long Short-Term Memory* (LSTM) yang menambahkan *memory cell* sebagai media penyimpanan informasi jangka panjang. Berbeda dengan RNN konvensional, LSTM mengendalikan aliran informasi melalui mekanisme gerbang (*gating mechanism*), sehingga informasi yang masih relevan dapat dipertahankan, sedangkan informasi yang tidak lagi diperlukan dapat diabaikan. Mekanisme ini membuat proses propagasi gradien menjadi lebih stabil selama pelatihan.

Kemampuan tersebut memungkinkan LSTM mempelajari ketergantungan temporal jangka panjang secara lebih efektif dibandingkan RNN konvensional. Oleh karena itu, LSTM menjadi salah satu arsitektur yang banyak diterapkan pada berbagai permasalahan pemodelan data sekuensial, termasuk prediksi lintasan siklon tropis yang memerlukan kemampuan untuk mempertahankan informasi historis sepanjang urutan pengamatan (Al Selwi et al., 2025).

2.4.3.2 Mekanisme Gerbang pada LSTM

Tiga gerbang dalam unit LSTM mengatur aliran informasi masuk, keluar, dan di sepanjang sel memori. Setiap gerbang berupa lapisan sigmoid yang menghasilkan nilai antara 0 dan 1, yang merepresentasikan proporsi informasi yang dilewatkan. Mekanisme ini membuat LSTM mampu memutuskan informasi mana yang dipertahankan, diperbarui, atau dibuang (Hao et al., 2024). Gambar 2.1 memperlihatkan interaksi ketiga gerbang dengan sel memori.



Gambar 2.1 Arsitektur Sel *Long Short-Term Memory* (LSTM)

Sumber : (Venna et al., 2018)

Pada Gambar 2.1, aliran data dimulai dari masukan x_t dan keadaan tersembunyi sebelumnya h_{t-1} serta keadaan sel sebelumnya c_{t-1} . Ketiga komponen ini menjadi masukan bagi tiga gerbang sebagai berikut.

1. Gerbang lupa (forget gate). Gerbang ini menentukan bagian mana dari keadaan sel sebelumnya c_{t-1} yang akan dihapus atau dipertahankan. Operasinya dirumuskan sebagai berikut:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.3)$$

Keterangan:

f_t = Gerbang lupa pada waktu t .

σ : = Fungsi aktivasi sigmoid.

W_f =Bobot gerbang lupa.

$[h_{t-1}, x_t]$ = Konkatensi h_{t-1} dan x_t

b_f =Bias gerbang lupa.

dengan σ fungsi sigmoid, h_{t-1} keadaan tersembunyi sebelumnya, x_t masukan saat ini, serta W_f dan b_f bobot dan bias gerbang lupa. Keluaran f_t dikalikan elemen demi elemen dengan c_{t-1} ; nilai mendekati nol akan menghapus informasi yang tidak relevan.

2. Gerbang masukan (input gate). Gerbang ini mengatur informasi baru yang akan disimpan ke dalam sel memori. Pada Gambar 2.1, bagian ini terdiri dari dua komponen: lapisan sigmoid yang menghasilkan i_t dan lapisan tanh yang menghasilkan kandidat nilai baru $\tilde{c}_t$. Persamaannya adalah:

$$i_t = \sigma (W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.4)$$

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (2.5)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (2.6)$$

Keterangan :

i_t =Input gate pada waktu t .

σ = Fungsi aktivasi sigmoid.

W_i = Bobot input gate.

$[h_{t-1}, x_t]$ = Konkatensi h_{t-1} dan x_t .

b_i =Bias input gate.

$\tilde{c}_t$ = Candidate cell state pada waktu t .

$\tanh$ = Fungsi aktivasi tangen hiperbolik.

W_c = Bobot candidate cell state.

b_c = Bias candidate cell state.

c_t = Cell state pada waktu t .

f_t = Forget gate pada waktu t .

c_{t-1} = Cell state pada waktu sebelumnya.

$\odot$ = Hadamard product (perkalian elemen-bijak).

Vektor i_t (nilai antara 0 dan 1) menentukan seberapa banyak informasi baru yang diterima, sementara $\tilde{c}_t$ adalah kandidat nilai baru. Keadaan sel kemudian diperbarui dengan menggabungkan informasi dari gerbang lupa dan gerbang masukan:

dengan $\odot$ menyatakan perkalian elemen demi elemen (produk Hadamard).

Di dalam gambar, proses ini digambarkan sebagai aliran dari c_{t-1} melewati gerbang lupa dan kemudian ditambahkan dengan hasil kali i_t dan $\tilde{c}_t$ untuk menghasilkan c_t .

3. Gerbang keluaran (*output gate*). Gerbang ini menentukan bagian mana dari keadaan sel c_t yang akan diekspose sebagai keadaan tersembunyi h_t .

Rumusnya adalah:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.7)$$

$$h_t = o_t \odot \tanh(c_t) \quad (2.8)$$

Keterangan:

o_t = Output gate pada waktu t .

σ = Fungsi aktivasi sigmoid.

W_o = Bobot output gate.

$[h_{t-1}, x_t]$ = Konkatenasi h_{t-1} dan x_t .

b_o = Bias output gate.

h_t = Hidden state pada waktu t .

c_t = Cell state pada waktu t .

Tanh = Fungsi aktivasi tangen hiperbolik.

$\odot$ = Hadamard product (perkalian elemen-bijak).

Nilai o_t menyaring informasi dari sel memori yang telah diskalakan dengan fungsi tanh. Pada Gambar 2.1, aliran dari c_t melewati lapisan tanh, lalu dikalikan dengan o_t menghasilkan h_t yang sekaligus menjadi keluaran pada langkah waktu t dan diteruskan ke langkah berikutnya.

Ketiga gerbang tersebut memberikan fleksibilitas bagi LSTM untuk menyimpan informasi relevan dalam jangka panjang, misalnya pola pergerakan siklon yang terbentuk dari beberapa jam sebelumnya tanpa terganggu oleh data yang sudah tidak berkontribusi (Awada et al., 2024; Rahman et al., 2025).

Untuk memprediksi lintasan siklon tropis, penelitian ini menggunakan arsitektur *Long Short-Term Memory* (LSTM) yang dirancang untuk mempelajari hubungan temporal pada data deret waktu. Model menerima data masukan berupa sekuens hasil teknik *sliding window* yang telah melalui tahap *preprocessing*, kemudian mempelajari pola perubahan posisi dan parameter meteorologi untuk menghasilkan prediksi koordinat lintang dan bujur pada waktu berikutnya. Arsitektur model disusun dengan mempertimbangkan keseimbangan antara kemampuan dalam menangkap dependensi jangka panjang dan kompleksitas komputasi sehingga sesuai dengan karakteristik data lintasan siklon tropis.

2.5 Siklon Tropis

Siklon tropis merupakan fenomena atmosfer yang terbentuk di atas perairan tropis hangat akibat interaksi berbagai kondisi oseanografi dan atmosfer. Sistem ini dicirikan oleh sirkulasi angin bertekanan rendah yang berputar mengelilingi pusat siklon serta berpotensi menimbulkan hujan lebat, angin kencang, gelombang tinggi, dan berbagai dampak hidrometeorologi lainnya. Karakteristik pembentukan, pola pergerakan, serta intensitas siklon tropis dipengaruhi oleh kondisi lingkungan di setiap wilayah sehingga perilakunya dapat berbeda antarbasin (World Meteorological Organization, 2025).


Dalam penelitian ini, pemahaman mengenai karakteristik siklon tropis menjadi landasan penting karena berkaitan dengan pola lintasan yang digunakan sebagai data masukan pada model prediksi. Oleh karena itu, pembahasan pada bagian ini mencakup definisi dan klasifikasi siklon tropis, mekanisme pembentukan dan pergerakannya, karakteristik lintasan di Samudra Hindia, serta dampak yang ditimbulkan terhadap wilayah Sumatera Barat.

2.5.1 Definisi dan Klasifikasi

Siklon tropis merupakan sistem tekanan rendah berskala sinoptik yang berinti hangat dan tidak berkaitan dengan front atmosfer. Sistem ini berkembang di atas perairan tropis atau subtropis, ditandai oleh konveksi dalam yang terorganisasi serta sirkulasi angin permukaan tertutup yang mengelilingi pusat tekanan rendah (World Meteorological Organization [WMO], 2025). Energi siklon berasal dari pelepasan panas laten selama proses kondensasi uap air di dalam kolom konvektif, bukan dari kontras suhu horizontal seperti pada siklon ekstratropis. Dalam penelitian ini, definisi tersebut menjadi acuan karena data lintasan yang digunakan berasal dari

International Best Track Archive for Climate Stewardship (IBTrACS), yang mengikuti standar klasifikasi WMO sehingga setiap siklon yang memasuki domain Samudra Hindia timur telah terverifikasi sebagai sistem tropis non-frontal.

Secara morfologi, siklon tropis yang telah matang terdiri atas tiga komponen utama, yaitu mata (*eye*) yang relatif tenang di pusat, dinding mata (*eyewall*) yang menjadi lokasi angin terkuat, serta pita-pita hujan spiral (*spiral rainbands*) yang mengelilingi sistem. Dinamika aliran udara pada ketiga komponen tersebut, meliputi udara turun di mata, konveksi vertikal di dinding mata, dan aliran spiral pada pita hujan, ditunjukkan pada Gambar 2.2. Pemahaman terhadap struktur ini menjadi dasar dalam menentukan variabel masukan yang merepresentasikan karakteristik siklon, khususnya posisi pusat dan kecepatan angin maksimum yang digunakan sebagai data pembelajaran model LSTM.



Gambar 2.2 Anatomi siklon tropis

Sumber: (Wang et al., 2024)

Klasifikasi intensitas siklon tropis bertumpu pada kecepatan angin maksimum berkelanjutan (*maximum sustained wind speed*) yang diukur di dekat permukaan. *World Meteorological Organization* (WMO) mengelompokkan sistem ke dalam tiga jenjang dasar sebagai berikut:

1. depresi tropis (≤ 34 knot),
2. badai tropis (34–64 knot), dan
3. siklon tropis (≥ 65 knot).

Untuk sistem yang mencapai kekuatan hurikan, Skala Angin Hurikan Saffir-Simpson dari *National Oceanic and Atmospheric Administration* (NOAA) memberikan pemeringkatan lebih terperinci dalam lima kategori berdasarkan kecepatan angin berkelanjutan setiap 1 Jam sebagai berikut:

1. Kategori 1 (119–153 km/jam),
2. Kategori 2 (154–177 km/jam),
3. Kategori 3 (178–208 km/jam),
4. Kategori 4 (209–251 km/jam), dan
5. Kategori 5 (>252 km/jam).

Kategori 3 ke atas digolongkan sebagai hurikan mayor karena potensi kerusakan struktural yang berat. Pada wilayah Samudra Hindia, istilah “siklon tropis” dipakai secara resmi, dan ambang intensitas inilah yang menjadi acuan badan meteorologi regional saat menerbitkan peringatan dini. Bagi Sumatera Barat, penguasaan terhadap skala ini menjadi pijakan untuk menerjemahkan perkiraan lintasan menjadi level risiko bencana yang mungkin timbul.

Pengetahuan tentang klasifikasi tidak berhenti pada intensitas statis. Siklus hidup siklon dapat bertransisi menjadi siklon ekstratropis manakala sistem memasuki perairan lebih dingin dan lingkungan baroklin yang kuat. Jalur transisi ekstratropis jalur kompleks yang melibatkan pembentukan inti dingin di troposfer bawah yang berinteraksi dengan inti hangat di troposfer atas, serta jalur yang dipicu frontogenesis akibat interaksi dengan zona baroklin. Temuan mereka menunjukkan

bahwa siklon yang menempuh transisi kompleks cenderung mencapai intensitas pasca-transisi yang lebih tinggi. Fenomena transisi ini juga teramati di Samudra Hindia selatan, di mana sejumlah siklon tropis dapat meluruh menjadi depresi pasca-tropis atau justru menguat kembali saat mendekati perairan barat Sumatera, sehingga menambah ketidakpastian dalam prakiraan jalur, (Evans et al., 2024). Oleh karena itu, kerangka klasifikasi yang dijadikan acuan dalam penelitian ini tidak hanya mencakup status intensitas versi WMO, tetapi juga memperhitungkan perubahan fase yang mungkin terekam di sepanjang lintasan pada basis data IBTrACS .

2.5.2 Mekanisme Pembentukan dan Pergerakan Siklon

Siklogensis tropis merupakan proses bertahap yang diawali oleh gangguan atmosfer berskala kecil sebagai prekursor pembentukan siklon tropis. Gangguan tersebut dapat berkembang menjadi sistem yang semakin terorganisasi hingga akhirnya membentuk siklon tropis apabila didukung oleh kondisi lingkungan yang sesuai. Frekuensi kemunculan gangguan prekursor juga dipengaruhi oleh Madden-Julian Oscillation (MJO) pada skala submusiman. Hal ini menunjukkan bahwa variabilitas siklogensis tidak hanya ditentukan oleh kondisi lingkungan berskala besar, tetapi juga oleh ketersediaan gangguan awal yang dipicu oleh osilasi intramusiman. Bagi wilayah Samudra Hindia timur, informasi ini menjadi penting karena perairan di sebelah barat Sumatra sering berada di bawah pengaruh fase aktif MJO (Emlaw & Kim, 2024).

Terbentuknya siklon tropis memerlukan kombinasi beberapa kondisi lingkungan yang terjadi secara bersamaan, antara lain suhu permukaan laut minimal 26,5°C sebagai sumber fluks panas laten, kelembapan yang tinggi pada troposfer

bawah hingga menengah, atmosfer yang tidak stabil, serta geser angin vertikal yang relatif lemah agar struktur konveksi tetap terjaga. Selain itu, karakteristik lingkungan pembentukan siklon diketahui berbeda pada setiap basin samudra sehingga hasil yang diperoleh pada suatu wilayah tidak selalu dapat digeneralisasikan ke wilayah lainnya. Oleh karena itu, penelitian ini membatasi area kajian pada Samudra Hindia timur agar karakteristik lingkungan yang dipelajari oleh model LSTM tetap sesuai dengan kondisi regional yang menjadi fokus penelitian.

Pergerakan siklon tropis merupakan hasil interaksi berbagai proses atmosfer pada beragam skala spasial dan temporal. Selain dipengaruhi oleh aliran pengarah (*steering flow*) berskala sinoptik dan efek beta (β -drift) yang berasal dari gradien vortisitas planet, lintasan siklon juga dipengaruhi oleh proses pemanasan diabatik, aktivitas konvektif, serta interaksi antara siklon dan lingkungan di sekitarnya. Pengaruh β -drift diketahui semakin besar pada lintang yang lebih tinggi sehingga dapat mengubah arah pergerakan siklon meskipun aliran pengarah relatif lemah. Di sisi lain, pengamatan terhadap siklon di Teluk Bengal menunjukkan bahwa karakteristik konveksi dan sirkulasi atmosfer pada berbagai skala turut memengaruhi perubahan lintasan yang tidak dapat dijelaskan hanya oleh aliran pengarah berskala besar. Kompleksitas tersebut menunjukkan bahwa prediksi lintasan siklon memerlukan model yang mampu mempelajari hubungan nonlinier dan ketergantungan temporal dari berbagai proses yang saling berinteraksi. Atas dasar tersebut, penelitian ini menggunakan arsitektur *Long Short-Term Memory* (LSTM) karena kemampuannya dalam mempertahankan informasi historis sehingga diharapkan mampu merepresentasikan pengaruh aliran pengarah, proses

konvektif, serta variabilitas intra-musiman terhadap perubahan trajektori siklon tropis (Gorja et al., 2024).

2.5.3 Karakteristik Jalur Siklon di Samudra Hindia

Samudra Hindia merupakan salah satu basin siklon tropis yang aktif, membentang dari Laut Arab dan Teluk Bengal di bagian utara hingga Samudra Hindia Selatan. Karakteristik lintasan siklon di kawasan ini tidak bersifat seragam karena dipengaruhi oleh kombinasi mode iklim berskala besar, variasi musiman, serta interaksi antar sistem siklon.

Pengaruh mode iklim terhadap aktivitas siklon telah banyak dilaporkan dalam penelitian terkini. Di Samudra Hindia Selatan, frekuensi kejadian siklon cenderung meningkat selama fase La Niña, ENSO netral, dan Indian Ocean Dipole (IOD) positif. Sebaliknya, siklon yang terbentuk di Laut Arab lebih banyak terjadi pada kondisi ENSO netral atau negatif dengan IOD netral. Selain dipengaruhi oleh variabilitas iklim, pola lintasan siklon juga menunjukkan perbedaan musiman. Pada periode pra-monsoon, siklon di Laut Arab umumnya berkembang di bagian timur basin kemudian bergerak ke arah utara hingga timur laut. Sementara itu, pada periode pasca-monsoon, pusat pembentukan bergeser ke wilayah selatan dengan kecenderungan pergerakan ke arah barat. Pola yang serupa juga dijumpai di Teluk Bengal, meskipun mekanisme pengendalinya berbeda. Pada musim pra-monsoon, lintasan siklon dipengaruhi oleh interaksi antara kondisi klimatologis rata-rata dan anomali submusiman, sedangkan pada musim pasca-monsoon pengaruh kondisi klimatologis menjadi lebih dominan.

Kompleksitas prediksi lintasan siklon semakin meningkat akibat adanya fenomena Efek Fujiwhara, yaitu interaksi antara dua siklon tropis yang berada

dalam jarak berdekatan. Salah satu contoh terjadi pada April 2021 ketika Siklon Tropis Seroja dan Odette saling berinteraksi di Samudra Hindia bagian tenggara. Interaksi tersebut menyebabkan Odette terserap ke dalam sirkulasi Seroja sehingga lintasan kedua sistem mengalami perubahan yang tidak lagi mengikuti pola aliran pengarah tunggal. Fenomena ini menunjukkan bahwa prediksi lintasan siklon tidak selalu dapat dijelaskan hanya berdasarkan kondisi lingkungan atmosfer berskala besar.

Di Samudra Hindia Selatan, siklon umumnya terbentuk pada lintang 5° hingga 15° LS dan bergerak ke arah barat daya atau barat mengikuti aliran timuran tropis sebelum berbelok ke arah tenggara ketika mencapai lintang yang lebih tinggi. Salah satu contoh lintasan ekstrem adalah Siklon Tropis Freddy pada Februari hingga Maret 2023 yang ditetapkan oleh *World Meteorological Organization* (WMO) sebagai siklon tropis dengan durasi hidup terpanjang dalam catatan pengamatan modern. Siklon tersebut menempuh lintasan lebih dari 12.000 km dari perairan utara Australia hingga Afrika bagian tenggara. Lintasan yang sangat panjang tersebut dipengaruhi oleh kombinasi suhu permukaan laut di atas 27°C , konfigurasi Antisiklon Mascarene yang terbelah, serta interaksi dengan Siklon Dingani (Tridaiana & Marzuki, 2023; Guo et al., 2024; WMO, 2025).

Beragam karakteristik lintasan siklon di Samudra Hindia, mulai dari pengaruh mode iklim, variasi musiman, interaksi antar siklon, hingga lintasan ekstrem yang melintasi beberapa wilayah basin, menunjukkan bahwa dinamika pergerakan siklon bersifat kompleks dan nonlinier. Kondisi tersebut menuntut model prediksi yang mampu mempelajari ketergantungan temporal dari data lintasan secara efektif. Oleh

karena itu, penelitian ini menerapkan arsitektur *Long Short-Term Memory* (LSTM) untuk memodelkan trajektori siklon tropis di wilayah Samudra Hindia timur.

2.5.4 Dampak bagi Sumatera Barat

Pesisir Sumatera Barat rentan terhadap efek tidak langsung siklon tropis yang terbentuk di Samudra Hindia timur. Meskipun pusat siklon jarang melintas tepat di atas daratan karena gaya Coriolis yang lemah di sekitar ekuator, pusaran siklonik di perairan barat memicu ketidakstabilan atmosfer, penguatan angin, dan akumulasi curah hujan di atas ambang normal. Siklon tropis di Samudra Hindia Selatan secara konsisten menimbulkan dampak tidak langsung berupa hujan lebat dan gelombang tinggi di pesisir barat Sumatera dan selatan Jawa, sebagaimana tercatat pada siklon Mangga, Cempaka, Dahlia, dan Paddy, (Tridaiana & Marzuki., 2023). Curah hujan ekstrem inilah yang menjadi pemicu langsung bencana hidrometeorologis limpasan permukaan tinggi, luapan sungai, dan tanah longsor, terutama di kabupaten bertopografi curam seperti Padang Pariaman, Agam, dan Pesisir Selatan. Dua gelombang bencana pada Maret dan Mei 2024 yang menelan korban jiwa serta memaksa ribuan penduduk mengungsi turut diatribusikan pada gangguan tropis di Samudra Hindia.

Secara fisik, sirkulasi siklonik kuat di perairan barat Sumatera menarik massa udara lembap menuju daratan dan menciptakan konvergensi di pesisir. Proses ini diperkuat oleh efek orografis Bukit Barisan yang memaksa udara naik, mempercepat kondensasi, dan mengonsentrasikan hujan di lereng barat. Kedua mekanisme tersebut saling memperkuat sehingga pusat siklon yang berjarak ratusan kilometer dari pantai tetap mampu memicu hujan deras. Keparahan bencana bertambah akibat alih fungsi lahan yang menurunkan kapasitas infiltrasi tanah dan

meningkatkan limpasan. Mitigasi risiko memerlukan pendekatan terpadu yang mencakup peningkatan ketepatan prakiraan meteorologis serta pengelolaan tata ruang dan restorasi daerah tangkapan air. Penelitian ini memusatkan perhatian pada aspek pertama, yaitu menyediakan model prediksi jalur siklon untuk memberi waktu lebih panjang bagi otoritas setempat dalam mengaktifkan sistem peringatan dini

2.6 Prediksi Lintasan Siklon

Prediksi lintasan siklon tropis merupakan proses memperkirakan posisi pergerakan siklon pada periode waktu mendatang berdasarkan informasi historis dan kondisi atmosfer yang diamati sebelumnya. Ketepatan prediksi lintasan menjadi aspek penting karena pergerakan siklon dipengaruhi oleh berbagai faktor dinamis yang saling berinteraksi, seperti sirkulasi atmosfer skala besar, kondisi permukaan laut, pola angin lingkungan, serta karakteristik internal siklon itu sendiri. Kompleksitas interaksi tersebut menyebabkan pola pergerakan siklon sering kali bersifat nonlinier dan berbeda antarwilayah pembentukan, sehingga prediksi lintasan menjadi tantangan yang terus dikaji dalam penelitian meteorologi modern (Gorja et al., 2024).

Secara umum, pendekatan prediksi lintasan siklon dapat dibedakan menjadi metode berbasis model fisik atmosfer dan metode berbasis data (*data-driven*). Model fisik memanfaatkan persamaan dinamika atmosfer untuk mensimulasikan evolusi sistem cuaca, sedangkan pendekatan data-driven mempelajari pola historis dari data pengamatan untuk menghasilkan prediksi secara langsung. Perkembangan ketersediaan arsip siklon global seperti IBTrACS serta kemajuan komputasi mendorong meningkatnya penggunaan metode pembelajaran mesin dan deep

learning dalam prediksi lintasan siklon. Berbagai penelitian menunjukkan bahwa model deep learning mampu menangkap hubungan temporal yang kompleks pada data runtun waktu dan menghasilkan performa yang kompetitif dalam prediksi trajektori siklon tropis (Awada et al., 2024; Rahman et al., 2025; Shi et al., 2025).

Dalam konteks penelitian ini, prediksi lintasan siklon dilakukan menggunakan pendekatan deep learning berbasis *Long Short-Term Memory* (LSTM) dengan memanfaatkan data historis siklon tropis dari basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI) yang diperoleh dari dataset IBTrACS. Fokus penelitian tidak hanya pada kemampuan model dalam memprediksi koordinat lintasan, tetapi juga pada analisis karakteristik statistik, spasial, dan temporal kedua basin serta pengaruh variasi ukuran timesteps terhadap proses pembelajaran model. Dengan demikian, prediksi lintasan siklon dalam penelitian ini diposisikan sebagai sarana untuk memahami hubungan antara karakteristik data dan performa model prediksi yang dihasilkan.

2.6.1 Metode Prediksi Konvensional

Selama beberapa dekade, prakiraan operasional lintasan siklon tropis didominasi oleh pendekatan *Numerical Weather Prediction* (NWP), yaitu metode yang menyelesaikan sistem persamaan diferensial parsial untuk merepresentasikan proses fisis di atmosfer. Model global seperti *Global Forecast System* (GFS) maupun model regional seperti *Weather Research and Forecasting* (WRF) menjadi sistem yang banyak digunakan dalam prakiraan cuaca dan siklon tropis, termasuk di kawasan Samudra Hindia. Pendekatan ini mampu menghasilkan simulasi atmosfer dengan resolusi spasial yang tinggi, tetapi memerlukan formulasi fisika yang kompleks serta sumber daya komputasi yang besar. Selain itu, kualitas

prakiraan sangat bergantung pada ketepatan kondisi awal karena kesalahan yang kecil dapat berkembang menjadi penyimpangan yang semakin besar seiring bertambahnya waktu integrasi akibat sifat atmosfer yang kaotik (Weng & Gori, 2026).

Evaluasi terhadap model GFS dan WRF pada kasus Siklon Thane (2011) dan Nilam (2012) di Samudra Hindia menunjukkan bahwa GFS secara konsisten menghasilkan kesalahan lintasan yang lebih rendah dibandingkan WRF. Penurunan kesalahan mencapai 13,9% untuk prakiraan 24 jam, 24% pada 48 jam, dan 31,6% pada 72 jam. Meskipun demikian, kesalahan prediksi masih dapat mencapai sekitar 795,4 km pada horizon prakiraan 72 jam, terutama pada siklon yang mengalami rekurvatur. Besarnya penyimpangan tersebut menunjukkan bahwa prakiraan numerik masih menghadapi tantangan dalam memenuhi kebutuhan sistem peringatan dini yang memerlukan ketelitian spasial tinggi, khususnya di wilayah pesisir yang padat penduduk (Rehman et al., 2025).

Kinerja model numerik juga dipengaruhi oleh konfigurasi skema fisika yang digunakan. Perbedaan pemilihan skema mikrofisika, lapisan batas planet (*planetary boundary layer*), maupun konveksi kumulat dapat menghasilkan variasi lintasan yang cukup besar meskipun menggunakan model yang sama. Temuan tersebut menunjukkan bahwa model beresolusi tinggi masih memiliki ketidakpastian internal yang perlu diperhatikan dalam proses prakiraan lintasan siklon tropis.

Selain pendekatan deterministik, metode ansambel (*ensemble prediction*) dikembangkan untuk menggambarkan tingkat ketidakpastian hasil prakiraan. Meskipun demikian, kemampuan prediksi lintasan pada rentang waktu

submusiman hingga musiman masih memiliki keterbatasan. Analisis terhadap *Subseasonal to Seasonal Reforecast* (S2S) dari *European Centre for Medium-Range Weather Forecasts* (ECMWF) menunjukkan bahwa metode *Average Predictability Time* (APT) mengungkap adanya batas prediktabilitas yang melekat pada prakiraan lintasan siklon, meskipun pemahaman mengenai hubungan antara kerapatan lintasan siklon dan variabilitas intra-musiman terus mengalami perkembangan (Loi et al., 2025).

Keterbatasan lain yang masih dijumpai pada model NWP adalah kemampuannya dalam merepresentasikan pola lintasan yang bersifat nonlinier, terutama ketika siklon mengalami rekurvatur atau berinteraksi dengan sistem lain, seperti pada Efek Fujiwhara. Pada kondisi tersebut, model numerik sering mengalami kesulitan dalam merepresentasikan perubahan arah lintasan secara akurat karena harus menyelesaikan proses fisika atmosfer secara eksplisit pada setiap langkah waktu. Studi terhadap prediksi Topan Khanun tahun 2023 juga menunjukkan bahwa model NWP masih menghadapi tantangan dalam menangkap perubahan lintasan yang terjadi secara tiba-tiba (Shi et al., 2025). Kondisi ini mendorong berkembangnya pendekatan berbasis data (*data-driven*) yang mampu mempelajari hubungan nonlinier dan ketergantungan temporal secara langsung dari data historis. Dalam penelitian ini, LSTM tidak digunakan sebagai pengganti model NWP maupun dibandingkan secara langsung dengan model tersebut, tetapi dieksplorasi sebagai pendekatan alternatif yang memanfaatkan kemampuan pembelajaran pola temporal pada data siklon.

2.6.2 Pendekatan *Deep Learning* untuk Prediksi Lintasan Siklon

Perkembangan teknologi komputasi dan ketersediaan data historis siklon tropis dalam jumlah besar telah mendorong penggunaan pendekatan berbasis kecerdasan buatan (*Artificial Intelligence*) dalam prediksi lintasan siklon. Berbeda dengan pendekatan numerik konvensional yang memanfaatkan persamaan fisika atmosfer secara eksplisit, metode data-driven mempelajari pola hubungan antarvariabel secara langsung dari data historis. Pendekatan ini memungkinkan model untuk mengenali pola spasial dan temporal yang kompleks tanpa harus mendefinisikan seluruh proses fisis yang mengendalikan pergerakan siklon. Berbagai penelitian menunjukkan bahwa metode deep learning mampu menghasilkan performa yang kompetitif dalam prediksi lintasan siklon tropis karena kemampuannya dalam memodelkan hubungan nonlinier pada data runtun waktu (Awada et al., 2024; Hao et al., 2024).

Salah satu arsitektur yang paling banyak digunakan dalam prediksi data runtun waktu adalah *Long Short-Term Memory* (LSTM). Model ini dirancang untuk mengatasi keterbatasan Recurrent Neural Network (RNN) tradisional dalam mempelajari ketergantungan jangka panjang melalui mekanisme memori dan gerbang pengendali informasi. Dalam konteks prediksi lintasan siklon, LSTM telah digunakan untuk mempelajari pola perubahan koordinat berdasarkan riwayat pergerakan sebelumnya dan menunjukkan kemampuan yang baik dalam menangkap dinamika temporal lintasan siklon tropis (Rahman et al., 2025). Oleh karena itu, model LSTM dipilih pada penelitian ini sebagai pendekatan utama untuk mempelajari pola trajektori siklon dari dataset IBTrACS.

Penelitian ini tidak hanya berfokus pada kemampuan model dalam menghasilkan prediksi koordinat, tetapi juga pada karakteristik data yang digunakan dalam proses pembelajaran. Dataset yang berasal dari basin *North Indian Ocean* (NI) dan *South Indian Ocean* (SI) memiliki karakteristik statistik, spasial, dan temporal yang berbeda sehingga berpotensi menghasilkan pola pembelajaran yang berbeda pula pada model LSTM. Selain itu, representasi data runtun waktu melalui teknik sliding window dengan variasi ukuran timesteps turut dievaluasi untuk mengamati bagaimana panjang informasi historis yang diberikan kepada model memengaruhi hasil prediksi lintasan siklon tropis.

2.7 Analisis Karakteristik Data Spasial dan Temporal

Dalam analisis trajektori siklon tropis, pemahaman mengenai karakteristik pergerakan tidak cukup hanya dilihat dari koordinat absolut (lintang dan bujur). Diperlukan ukuran-ukuran kuantitatif yang mampu merepresentasikan jarak antar titik, ketergantungan waktu, arah gerakan, dan kompleksitas geometri lintasan.

2.7.1 Haversine Distance (Jarak Geografis)

Langkah paling mendasar dalam menganalisis trajektori adalah menghitung jarak antara dua titik koordinat geografis. Karena permukaan bumi berbentuk bola (*elipsoid*), jarak terpendek antara dua titik bukanlah garis lurus pada bidang datar, melainkan great-circle distance (jarak lingkaran besar). Penggunaan rumus *Euclidean* (jarak pada bidang datar) akan menghasilkan kesalahan perhitungan yang signifikan, terutama pada jarak jauh.

Untuk mengatasi hal ini, rumus *Haversine* menjadi standar dalam perhitungan jarak spasial. Rumus ini memanfaatkan trigonometri bola untuk menghitung jarak

antara dua titik yang dinyatakan dalam koordinat lintang dan bujur, dengan memperhitungkan kelengkungan bumi. Secara matematis, rumus *Haversine* dirumuskan sebagai berikut:

$$a = \sin^2\left(\frac{\Delta\phi}{2}\right) + \cos\phi_1 \cdot \cos\phi_2 \cdot \sin^2\left(\frac{\Delta\lambda}{2}\right) \quad (2.9)$$

$$c = 2 \cdot \text{atan2}(\sqrt{a}, \sqrt{1-a}) \quad (2.10)$$

$$d = R \cdot c \quad (2.11)$$

Keterangan:

a = Nilai haversine (variabel bantu).

$\Delta\phi$ = Selisih lintang (dalam radian).

$\Delta\lambda$ = Selisih bujur (dalam radian).

ϕ_1 = Lintang titik awal (dalam radian).

ϕ_2 = Lintang titik akhir (dalam radian).

c = Jarak sudut (dalam radian).

atan2 = Fungsi arctangent dua argumen.

d = Jarak geodesik (dalam kilometer).

R = Jari-jari Bumi (rata-rata 6371 km).

Dalam konteks penelitian ini, *Haversine Distance* digunakan untuk menghitung jarak perpindahan siklon antar interval waktu 3 jam, yang kemudian menjadi dasar perhitungan kecepatan gerak siklon (*speed*). untuk mengukur perbedaan panjang lintasan dan kecepatan rata-rata antara siklon di NI dan SI.

2.7.2 Autokorelasi (*Autocorrelation Function/ACF*)

Analisis deret waktu tidak hanya berfokus pada nilai yang diamati pada suatu waktu, tetapi juga pada hubungan antara nilai tersebut dengan pengamatan pada

waktu sebelumnya. Hubungan ini dikenal sebagai autokorelasi (*autocorrelation*), yaitu ukuran yang menunjukkan tingkat korelasi antara suatu deret waktu dengan nilai-nilai tertundanya (*lagged values*). Keberadaan autokorelasi mengindikasikan bahwa suatu deret waktu memiliki ketergantungan temporal, sehingga informasi pada masa lalu masih memberikan pengaruh terhadap kondisi pada waktu berikutnya. Hubungan tersebut umumnya dianalisis menggunakan *Autocorrelation Function* (ACF), yang menggambarkan kekuatan korelasi pada setiap lag.

Selain ACF, *Partial Autocorrelation Function* (PACF) digunakan untuk mengukur korelasi antara dua pengamatan pada lag tertentu setelah pengaruh dari lag yang lebih pendek dihilangkan. Informasi yang diperoleh dari ACF dan PACF banyak dimanfaatkan untuk mengidentifikasi struktur ketergantungan temporal serta membantu menentukan orde model autoregresif, khususnya pada model deret waktu seperti *ARIMA*. Dalam penelitian ini, analisis ACF dimanfaatkan untuk mengevaluasi karakteristik ketergantungan temporal pada data lintasan siklon di Basin Samudra Hindia Utara (NI) dan Samudra Hindia Selatan (SI), sehingga perbedaan pola temporal antar kedua basin dapat dianalisis secara empiris sebagai dasar penyusunan skenario pemodelan (Hassani et al., 2024).

2.7.3 Arah Pergerakan (*Bearing*)

Selain jarak dan korelasi temporal, aspek fundamental lain dalam analisis trajektori siklon adalah arah pergerakan (*bearing* atau *azimuth*). Bearing merepresentasikan sudut kompas dari satu titik ke titik berikutnya, yang diukur searah jarum jam dari arah utara (0°) hingga 360° . Perhitungan bearing melibatkan trigonometri bola yang memanfaatkan fungsi *atan2* untuk mendapatkan sudut yang tepat (Ventura et al., 2024).

Secara matematis, *bearing* (θ) dapat dihitung dengan persamaan berikut:

$$x = \sin(\Delta\lambda) \cdot \cos(\phi_2) \quad (2.12)$$

$$y = \cos(\phi_1) \cdot \sin(\phi_2) - \sin(\phi_1) \cdot \cos(\phi_2) \cdot \cos(\Delta\lambda) \quad (2.13)$$

$$\theta = \text{atan2}(x, y) \times \frac{180}{\pi} \quad (2.14)$$

Keterangan :

ϕ_1 = Lintang titik awal (radian).

ϕ_2 = Lintang titik akhir (radian).

$\Delta\lambda$ = Selisih bujur ($\lambda_2 - \lambda_1$, dalam radian.).

x = Komponen arah Timur-Barat.

y = Komponen arah Utara-Selatan.

θ = Bearing atau arah pergerakan (derajat bernilai 0° hingga 360°)

atan2 = Fungsi untuk menghitung sudut berdasarkan nilai x dan y

π = Konstanta pi (≈ 3.14159) konversi radian ke derajat.

Bearing sangat berguna untuk mengidentifikasi pola pergerakan siklon, seperti arah dominan pergerakan atau rotasi siklonik. Dalam penelitian ini, analisis bearing digunakan untuk membandingkan pola arah pergerakan antara NI dan SI.

2.7.4 Indeks Kelengkungan Lintasan (*Sinuosity Index*)

Indeks Kelengkungan Lintasan (*Sinuosity Index*) digunakan untuk mengukur tingkat kelengkungan atau kompleksitas suatu lintasan dengan membandingkan panjang lintasan aktual terhadap jarak garis lurus antara titik awal dan titik akhir. Nilai indeks yang semakin besar menunjukkan lintasan yang semakin berbelok dan tidak beraturan, sedangkan nilai yang mendekati satu mengindikasikan lintasan yang relatif lurus.

Perkembangan terbaru dalam analisis trajektori memperkenalkan *Normalized Difference Sinuosity Index* (NDSiI), yaitu pengembangan dari indeks sinuosity konvensional yang mengukur kelengkungan lintasan berdasarkan variasi sudut belok maksimum dan minimum sepanjang trajektori. Pendekatan ini mampu merepresentasikan perubahan arah secara lebih rinci dibandingkan metode tradisional yang hanya memanfaatkan posisi awal dan akhir lintasan. Selain menghasilkan ukuran kelengkungan yang lebih representatif, NDSiI juga memungkinkan klasifikasi lintasan menjadi beberapa kategori, seperti lurus, semi-lurus, berbelok, dan sangat berbelok, sehingga memberikan interpretasi yang lebih komprehensif terhadap karakteristik pergerakan siklon.

Pada penelitian ini, konsep tersebut diadaptasi dengan memanfaatkan fitur *turning angle* yang diperoleh dari perubahan nilai *bearing* antar titik pengamatan. Distribusi *turning angle* selanjutnya digunakan untuk menganalisis karakteristik kelengkungan lintasan pada Basin Samudra Hindia Utara (NI) dan Basin Samudra Hindia Selatan (SI), sehingga perbedaan kompleksitas trajektori pada kedua basin dapat dibandingkan secara kuantitatif. Meskipun penelitian ini tidak menghitung nilai NDSiI secara langsung, prinsip pengukuran kelengkungan lintasan yang digunakan tetap mengacu pada konsep perubahan arah sepanjang trajektori (Le & Liou, 2026).

2.8 Feature Engineering Data Deret Waktu

Dalam pemodelan deret waktu menggunakan arsitektur *Long Short-Term Memory* (LSTM), kualitas fitur masukan (*input features*) memegang peranan yang sangat krusial. Data mentah yang terdiri dari koordinat absolut (*latitude, longitude*) dan parameter meteorologi (*WMO_WIND, WMO_PRES*) seringkali belum cukup

untuk menangkap dinamika pergerakan yang kompleks. Oleh karena itu, diperlukan serangkaian teknik rekayasa fitur (*feature engineering*) untuk mentransformasikan data mentah menjadi representasi yang lebih informatif bagi model.

2.8.1 Normalisasi *Z-Score* (dan alasan perlakuan terpisah)

Salah satu langkah paling fundamental dalam *preprocessing* data deret waktu adalah normalisasi atau standarisasi fitur. Dalam konteks *deep learning*, normalisasi bertujuan untuk menyamakan skala antar fitur, mencegah fitur dengan magnitudo absolut yang lebih besar mendominasi proses pembaruan bobot selama propagasi mundur (*backpropagation*). Metode normalisasi yang paling umum dan terbukti adalah *Z-Score Standardization* atau *StandardScaler*. Metode ini mentransformasikan setiap nilai fitur x menjadi nilai Z berdasarkan rata-rata (μ) dan standar deviasi (σ) dari data pelatihan, dengan persamaan:

$$Z = \frac{x - \mu}{\sigma} \quad (2.15)$$

Keterangan:

Z = Skor Z atau nilai standar.

x = Nilai data mentah (observasi).

μ = Rata-rata (mean).

σ = Simpangan baku (standar deviasi).

Penelitian dalam bidang klasifikasi spektroskopi membuktikan bahwa normalisasi *Z-Score* secara konsisten meningkatkan stabilitas dan generalisasi model dibandingkan dengan metode normalisasi lainnya, seperti *Min-Max* atau *Sum of Squares*, karena metode ini secara efektif menangani variabilitas data dan mengarahkan distribusi ke bentuk yang lebih ideal untuk algoritma pembelajaran

mesin, (Villegas-Camacho et al., 2025).

Normalisasi gradien berbasis *Z-Score* (ZNorm) dapat mengakselerasi pelatihan jaringan saraf dalam (*deep neural networks*) dengan mengurangi risiko gradien yang menghilang (*vanishing gradient*) atau meledak (*exploding gradient*). Meskipun ZNorm diterapkan pada gradien, logika dasar yang sama yaitu menstabilkan skala dan distribusi juga berlaku pada normalisasi fitur input. Dengan kata lain, fitur input yang dinormalisasi dengan *Z-Score* memungkinkan optimasi bobot menjadi lebih stabil dan konvergen dengan cepat, (Yun et al. 2024).

2.8.2 Enkoding Siklus Musiman (*Cyclic Encoding / Sin-Cos Month*)

Data deret waktu seringkali mengandung pola yang bersifat siklus atau periodik, seperti musim, hari dalam minggu, atau jam dalam sehari. Dalam konteks penelitian ini, aktivitas siklon tropis di Samudra Hindia sangat dipengaruhi oleh musim. Namun, merepresentasikan bulan sebagai angka integer (1 sampai 12) menimbulkan masalah: secara matematis, jarak antara bulan Desember (12) dan Januari (1) sangat jauh, padahal secara fisis keduanya berurutan.

Untuk mengatasi hal ini, digunakan teknik enkoding siklus (*cyclic encoding*), yang memetakan variabel siklik ke dalam ruang dua dimensi menggunakan transformasi sinus dan kosinus. Pendekatan ini memastikan kontinuitas siklus tetap terjaga, karena nilai bulan 12 dan bulan 1 akan direpresentasikan sebagai titik yang berdekatan pada lingkaran satuan (*unit circle*). Transformasi ini dirumuskan sebagai berikut (Luangmaneerote & Thasana, 2025):

$$Month_{sin} = \sin\left(\frac{2\pi \cdot \text{Month}}{12}\right) \quad (2.16)$$

$$Month_{cos} = \cos\left(\frac{2\pi \cdot \text{Month}}{12}\right) \quad (2.17)$$

Keterangan

$Month_{sin}$ = Nilai transformasi sinus bulan (fitur siklik).

$Month_{cos}$ = Nilai transformasi kosinus bulan (fitur siklik).

$Month$ = Nilai urutan bulan (misal 1 untuk Januari, 12 untuk Desember).

π : = Konstanta pi.

Sin = Fungsi trigonometri sinus.

cos = Fungsi trigonometri kosinus.

Peramalan polusi udara di Beijing menunjukkan bahwa penggunaan encoding siklus secara signifikan meningkatkan akurasi prediksi model *Deep Learning*, karena memungkinkan model untuk menangkap pola diurnal dan musiman secara lebih efektif. dalam peramalan ketinggian air waduk, di mana penerapan encoding siklus terbukti meningkatkan kinerja model non-linear seperti *Random Forest* dan *Artificial Neural Network* hingga mengurangi metrik *error* secara signifikan, (Luangmaneeerote & Thasana 2025; Alsabagh et al., 2025).

2.8.3 Fitur Turunan (*Derivative / Delta Features*)

Analisis trajektori tidak hanya mempertimbangkan posisi absolut suatu objek, tetapi juga dinamika pergerakannya dari waktu ke waktu. Oleh karena itu, penelitian ini membentuk sejumlah fitur turunan (*derivative features*) untuk membantu model LSTM mempelajari perubahan koordinat antar langkah waktu. Fitur-fitur tersebut merepresentasikan perubahan posisi yang secara fisis berkaitan dengan perpindahan, kecepatan, maupun arah pergerakan.

Fitur turunan yang digunakan meliputi Δlat dan Δlon , yaitu selisih koordinat lintang dan bujur antara waktu t dan $t - 1$. Kedua fitur tersebut merepresentasikan vektor perpindahan siklon dalam interval pengamatan tiga jam.

Selain itu, dihitung pula fitur *speed_kmh* untuk menggambarkan kecepatan perpindahan siklon dalam satuan kilometer per jam.

Perhitungan kecepatan tidak dilakukan menggunakan jarak Euclidean karena pendekatan tersebut mengabaikan kelengkungan permukaan bumi. Sebagai gantinya, penelitian ini menggunakan rumus Haversine untuk menghitung jarak geodesik antara dua titik koordinat geografis. Rumus tersebut memanfaatkan prinsip trigonometri bola sehingga menghasilkan estimasi jarak yang lebih akurat pada permukaan bumi. Setelah jarak antar titik (d) diperoleh dalam satuan kilometer, nilai kecepatan dihitung dengan membagi jarak tersebut terhadap selang waktu pengamatan selama tiga jam.

Dalam prediksi lintasan siklon tropis, penggunaan fitur turunan berperan penting karena model tidak hanya mempelajari posisi geografis, tetapi juga pola perubahan gerakan yang terjadi dari waktu ke waktu. Informasi mengenai perpindahan, kecepatan, dan arah pergerakan memberikan representasi temporal yang lebih kaya sehingga model dapat mempelajari karakteristik pergerakan berbagai siklon secara lebih efektif, baik pada Basin Samudra Hindia Utara (NI) maupun Samudra Hindia Selatan (SI). Pendekatan serupa juga telah diterapkan pada berbagai penelitian berbasis deret waktu, di mana fitur turunan temporal terbukti mampu meningkatkan kemampuan model dalam mengenali perubahan pola yang mendahului suatu peristiwa penting. Temuan tersebut mendukung penggunaan fitur turunan pada penelitian ini karena perubahan kecepatan maupun arah pergerakan dapat menjadi indikator awal terjadinya perubahan lintasan siklon (Goh et al., 2021).

2.9 Metrik Evaluasi

Dalam tugas prediksi trajektori siklon tropis, evaluasi akurasi model tidak cukup hanya dengan mengukur selisih nilai koordinat secara sederhana. Karena koordinat lintang dan bujur merepresentasikan posisi pada permukaan bumi yang berbentuk bola (*sphere*), pengukuran jarak antara titik aktual dan prediksi harus mempertimbangkan kelengkungan geografis. Oleh karena itu, penelitian ini mengadopsi tiga metrik evaluasi utama: *Root Mean Squared Error* (RMSE), *Mean Absolute Error* (MAE), dan *Haversine Distance Error*, dengan seluruh metrik dikonversi ke dalam satuan kilometer untuk interpretasi fisis yang lebih relevan dengan mitigasi bencana.

2.9.1 *Root Mean Squared Error* (RMSE) & *Mean Absolute Error* (MAE)

Root Mean Squared Error (RMSE) dan *Mean Absolute Error* (MAE) adalah dua metrik paling umum dalam peramalan deret waktu dan regresi. MAE mengukur rata-rata selisih absolut antara nilai aktual dan prediksi, sehingga memberikan gambaran yang seimbang terhadap seluruh galat tanpa membedakan besaran deviasi. Secara matematis, MAE dirumuskan sebagai:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.18)$$

Keterangan :

MAE =Mean Absolute Error.

n =Jumlah total data.

y_i =Nilai aktual/observasi ke-i.

$\hat{y}_i$ =Nilai prediksi ke-i.

Σ =Notasi penjumlahan.

$|y_i - \hat{y}_i|$ =Nilai absolut (selisih).

Sementara itu, RMSE mengukur akar rata-rata kuadrat selisih, yang memberikan penalti lebih besar terhadap galat bernilai tinggi. Sifat kuadrat pada RMSE membuatnya sangat sensitif terhadap *outlier*, sehingga sangat berguna untuk mendeteksi prediksi yang melenceng jauh dari lintasan aktual. Persamaan RMSE adalah:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.19)$$

Keterangan :

RMSE = Root Mean Square Error.

n = Jumlah total data.

y_i = Nilai aktual/data observasi ke-i.

$\hat{y}_i$ = Nilai prediksi ke-i.

Σ = Notasi penjumlahan.

Di mana n adalah jumlah titik pengamatan, y_i merupakan nilai aktual, dan $\hat{y}_i$ merupakan nilai prediksi. Meskipun MAE dan RMSE banyak digunakan untuk mengevaluasi akurasi model prediksi, kedua metrik tersebut memiliki keterbatasan apabila diterapkan secara langsung pada data koordinat geografis dalam satuan derajat. Hal ini disebabkan karena koordinat lintang dan bujur berada pada permukaan bumi yang berbentuk mendekati elipsoid, sehingga jarak antar titik tidak dapat direpresentasikan secara akurat menggunakan pendekatan Euclidean pada bidang datar. Penggunaan jarak Euclidean pada koordinat geografis dapat menghasilkan penyimpangan yang semakin besar seiring bertambahnya jarak antar

titik. Pada beberapa kondisi, selisih antara jarak Euclidean dan jarak sebenarnya di permukaan bumi dapat mencapai sekitar 15 hingga 16 km, sehingga berpotensi memengaruhi interpretasi terhadap tingkat akurasi model prediksi, (Wagner et al. 2024).

2.9.2 Haversine Distance Error (Evaluasi Jarak Geografis)

Untuk mengatasi keterbatasan pendekatan *Euclidean*, digunakan rumus *Haversine* yang merupakan standar dalam navigasi untuk menghitung jarak lingkaran besar (*great-circle distance*) antara dua titik pada permukaan bola. Rumus ini memanfaatkan trigonometri bola untuk menghasilkan jarak geodesik yang akurat dalam satuan kilometer.

Secara matematis, jarak *Haversine* antara dua titik koordinat (ϕ_1, λ_1) dan (ϕ_2, λ_2) dihitung dengan persamaan:

$$a = \sin^2\left(\frac{\Delta\phi}{2}\right) + \cos(\phi_1)\cos(\phi_2)\sin^2\left(\frac{\Delta\lambda}{2}\right) \quad (2.20)$$

$$c = 2 \cdot \text{atan2}(\sqrt{a}, \sqrt{1-a}) \quad (2.21)$$

$$d = R \cdot c \quad (2.22)$$

Keterangan:

a = Nilai haversine (variabel bantu perhitungan sudut).

c = Jarak sudut antara kedua titik (dalam radian).

ϕ_1, ϕ_2 = Lintang titik 1 dan 2 (dalam radian).

$\Delta\phi$ = Selisih lintang (dalam radian).

$\Delta\lambda$ = Selisih bujur (dalam radian).

atan2 = Fungsi arctangent dua argumen.

$\sqrt{}$ = Fungsi akar kuadrat.

R = Jari-jari bumi (rata-rata 6371 km).

d = Jarak antara kedua titik (dalam kilometer).

Model *deep learning* untuk prediksi trajektori siklon umumnya dilatih menggunakan fungsi kerugian seperti *Mean Squared Error* (MSE) atau *Mean Absolute Error* (MAE). Namun, kedua fungsi tersebut secara implisit mengasumsikan bahwa data berada pada ruang Euclidean datar, sehingga belum sepenuhnya merepresentasikan karakteristik koordinat geografis yang mengikuti geometri permukaan bumi. Akibatnya, pengukuran galat spasial berpotensi mengalami distorsi, terutama ketika jarak antar titik semakin besar. Oleh karena itu, evaluasi akurasi prediksi lintasan lebih tepat dilakukan menggunakan Haversine Distance karena mampu menghitung jarak geodesik antar koordinat di permukaan bumi secara lebih representative (Rahman et al., 2025).

Pada penelitian ini, nilai RMSE dan MAE tidak dihitung berdasarkan selisih koordinat lintang dan bujur dalam satuan derajat, melainkan menggunakan jarak Haversine dalam satuan kilometer antara posisi aktual dan posisi hasil prediksi. Pendekatan ini menghasilkan interpretasi metrik yang lebih mudah dipahami karena nilai galat secara langsung menunjukkan besarnya penyimpangan posisi prediksi terhadap lintasan aktual di permukaan bumi.

2.9.3 Koefisien Determinasi (R^2)

Selain metrik *error absolut*, penelitian ini juga menggunakan Koefisien Determinasi (R^2) untuk mengukur seberapa baik model menjelaskan variansi data. R^2 dihitung berdasarkan persamaan:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2.23)$$

Keterangan :

R^2 = Koefisien determinasi (R-squared).

n = Jumlah total data.

y_i = Nilai aktual/observasi ke-i.

$\hat{y}_i$ = Nilai prediksi ke-i.

$\bar{y}$ = Rata-rata nilai aktual seluruh data.

Σ = Notasi penjumlahan.

Di mana $\bar{y}$ adalah rata-rata dari nilai aktual. Nilai R^2 mendekati 1 mengindikasikan bahwa model sangat baik dalam menangkap pola pergerakan, sedangkan nilai mendekati 0 atau negatif menunjukkan model gagal mengikuti dinamika data. Meskipun R^2 tidak secara langsung mengukur jarak spasial, metrik ini memberikan gambaran tentang kualitas *fitting* model terhadap keseluruhan lintasan.

2.9.4 Relevansi Metrik dalam Pemodelan Geospasial dan Validasi

Dalam pemodelan geospasial yang melibatkan data lingkungan, salah satu tantangan utama yang sering diabaikan adalah autokorelasi spasial (*Spatial Autocorrelation* / SAC). ketergantungan spasial antara titik pengamatan dapat menyebabkan validasi model secara *random* menghasilkan perkiraan performa yang terlalu optimis (*overconfident*). Jika data latih dan data uji saling berdekatan secara geografis, model dapat mempelajari pola spasial lokal yang tidak mewakili generalisasi global (Koldasbayeva et al., 2024).

Untuk mengantisipasi hal ini, penelitian ini menerapkan strategi validasi yang ketat dengan melakukan pemisahan data berdasarkan fenomena siklon utuh (split per SID), bukan pemisahan acak per baris data. Dengan demikian, autokorelasi

spasial dapat diminimalisir, dan metrik evaluasi (RMSE, MAE, dan *Haversine Error*) yang dihasilkan benar-benar mencerminkan kemampuan model dalam memprediksi siklon di wilayah yang berbeda secara geografis, bukan sekadar memori lokal dari data pelatihan.

2.10 Penelitian Terdahulu dan Gap Penelitian

Penerapan metode deep learning, khususnya *Long Short-Term Memory* (LSTM), dalam prediksi lintasan siklon tropis telah banyak digunakan dalam beberapa tahun terakhir. Meskipun menunjukkan performa yang baik, sejumlah penelitian masih memiliki keterbatasan terkait cakupan data, wilayah kajian, serta belum mempertimbangkan perbedaan karakteristik antar basin secara eksplisit.

Model LSTM, GRU, dan RNN pada data siklon Samudra Hindia Utara (NI). Hasil penelitian menunjukkan bahwa LSTM memberikan performa terbaik dengan nilai error lebih rendah dibandingkan model lainnya. Namun, penelitian tersebut hanya menggunakan data dari satu basin sehingga belum mengkaji pengaruh perbedaan karakteristik data antar wilayah (Rahman et al., 2025).

Perbandingan arsitektur *deep learning* pada data siklon di Pasifik Barat Laut. Hasil penelitian menunjukkan bahwa model berbasis LSTM dan variannya memiliki performa lebih baik dibandingkan RNN konvensional. Namun, penelitian ini juga masih terbatas pada satu wilayah dan belum mempertimbangkan perbedaan distribusi data lintas basin (Awada et al., 2024).

Dynamic Time Warping (DTW) untuk meningkatkan akurasi prediksi lintasan siklon dengan memanfaatkan kemiripan lintasan historis. Meskipun pendekatan ini meningkatkan performa prediksi jangka menengah, penelitian tersebut masih bergantung pada kesamaan historis tanpa menganalisis perbedaan

karakteristik data.

Karakteristik siklon di Samudra Hindia Selatan (SI) memiliki pola statistik yang berbeda dibandingkan wilayah lainnya, terutama dalam hal intensitas dan durasi siklon. Temuan ini mengindikasikan adanya perbedaan distribusi data yang signifikan antar basin yang dapat memengaruhi proses pemodelan., (Tridaiana & Marzuki., 2023).

Berdasarkan penelitian-penelitian tersebut, terdapat beberapa gap penelitian yang dapat diidentifikasi. Pertama, belum banyak penelitian yang secara eksplisit menganalisis perbedaan karakteristik spasial dan temporal antara *North Indian Ocean* (NI) dan *South Indian Ocean* (SI) dalam konteks prediksi lintasan siklon. Kedua, masih terbatas penelitian yang menguji pengaruh perbedaan distribusi data antar basin terhadap performa model *deep learning*. Ketiga, belum terdapat kajian yang membandingkan skenario pelatihan data gabungan (NI+SI) dan data terpisah dalam konteks prediksi lintasan siklon menggunakan data IBTrACS dengan resolusi temporal 3 jam.

Dengan demikian, penelitian ini diarahkan untuk mengisi gap tersebut dengan fokus pada analisis karakteristik data NI dan SI serta pengaruhnya terhadap kinerja model *Long Short-Term Memory* (LSTM) dalam prediksi lintasan siklon tropis.

2.11 Sistem Informasi Prediksi Lintasan Siklon Tropis

Sistem peringatan dini (*Early Warning System/EWS*) merupakan kerangka konseptual dalam pengelolaan informasi bencana hidrometeorologi yang mencakup proses pemantauan, analisis data, dan penyampaian informasi berbasis prediksi. Dalam penelitian ini, fokus tidak diarahkan pada pembangunan sistem peringatan

dini secara menyeluruh, melainkan pada pengembangan model prediksi lintasan siklon tropis berbasis *Long Short-Term Memory* (LSTM) sebagai komponen analitik untuk menghasilkan informasi spasio-temporal.

Secara konseptual, model prediksi berbasis LSTM berperan dalam menghasilkan estimasi lintasan siklon berdasarkan data historis runtun waktu. Kemampuan LSTM dalam menangkap ketergantungan temporal jangka panjang menjadikannya relevan untuk pemodelan trajektori atmosfer yang bersifat dinamis. Output model berupa koordinat lintasan pada waktu mendatang dapat dimanfaatkan sebagai representasi informasi spasial yang bersifat prediktif (Awada et al., 2024). Dalam konteks penyajian informasi, hasil prediksi lintasan siklon tropis dapat dimanfaatkan sebagai dasar visualisasi spasial untuk memahami pola pergerakan sistem atmosfer secara lebih intuitif. Representasi tersebut membantu pengguna mengamati hubungan antara dimensi waktu dan posisi geografis secara bersamaan, sehingga perubahan arah maupun kecenderungan lintasan dapat diinterpretasikan dengan lebih mudah. Oleh karena itu, penelitian ini menyajikan hasil prediksi dalam bentuk visualisasi interaktif berbasis web yang mengintegrasikan data spasial dengan informasi hasil prediksi model.

Penggunaan sistem informasi berbasis web juga memberikan kemudahan dalam penyajian hasil analisis karena informasi dapat diakses melalui antarmuka yang interaktif tanpa memerlukan perangkat lunak khusus. Selain menampilkan lintasan aktual dan hasil prediksi pada peta digital, sistem yang dikembangkan menyajikan informasi pendukung berupa koordinat prediksi dan metrik evaluasi model. Penyajian informasi dalam bentuk visual ini diharapkan dapat mempermudah proses analisis terhadap karakteristik pergerakan siklon tropis

sekaligus mendukung interpretasi hasil prediksi secara lebih komprehensif.


Dengan demikian, penelitian ini tidak berfokus pada implementasi sistem peringatan dini maupun mekanisme mitigasi risiko secara operasional, melainkan pada pengembangan model prediksi lintasan siklon tropis serta penyajian hasilnya dalam bentuk informasi spasial yang dapat dianalisis lebih lanjut. Pendekatan ini diharapkan dapat memperkuat pemahaman terhadap dinamika lintasan siklon tropis melalui pendekatan *data-driven* dan *time series forecasting*, sekaligus menjadi dasar bagi pengembangan sistem pendukung pengambilan keputusan pada penelitian selanjutnya.

BAB III

METODOLOGI PENELITIAN

3.1 Kerangka Penelitian

Kerangka penelitian merupakan gambaran umum mengenai tahapan yang dilakukan dalam penelitian, mulai dari tahap awal hingga diperoleh hasil penelitian. Kerangka ini disusun sebagai pedoman agar setiap tahapan penelitian dapat dilaksanakan secara sistematis, terarah, dan saling berkaitan. Selain itu, kerangka penelitian membantu menunjukkan hubungan antarproses sehingga tujuan penelitian dapat dicapai sesuai dengan rancangan yang telah ditetapkan.



Gambar 3.1 Kerangka Penelitian

Pada Gambar 3.1 penelitian ini, kerangka penelitian mencakup tahapan penelitian pendahuluan, pengumpulan data, analisis, perancangan, implementasi, pengujian, hingga penarikan kesimpulan. Setiap tahapan memiliki peran yang

saling mendukung dalam proses pengembangan model prediksi lintasan siklon tropis menggunakan metode *Long Short-Term Memory* (LSTM) serta implementasinya ke dalam aplikasi berbasis Python.

3.2 Jadwal Penelitian

Jadwal penelitian disusun sebagai acuan dalam pelaksanaan setiap tahapan penelitian agar kegiatan dapat berlangsung secara sistematis dan sesuai dengan rencana. Seluruh rangkaian penelitian dilaksanakan mulai bulan Maret 2026 hingga Juli 2026. Kegiatan penelitian meliputi identifikasi masalah, pengumpulan data, analisis, perancangan, implementasi, serta penyusunan laporan penelitian. Rincian jadwal pelaksanaan penelitian disajikan pada Tabel 3.1.

Tabel 3.1 Jadwal Penelitian

No	Kegiatan	2026																			
		Maret				April				Mei				Juni				Juli			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
1	Identifikasi Masalah																				
2	Pengumpulan Data																				
3	Analisa																				
4	Perancangan																				
5	Implementasi																				
6	Menyusun laporan																				

3.3 Tahapan Penelitian

Tahapan penelitian merupakan rangkaian proses yang dilakukan secara sistematis untuk mencapai tujuan penelitian yang telah ditetapkan. Setiap tahapan

disusun secara berurutan mulai dari penelitian pendahuluan hingga kesimpulan, sehingga seluruh proses penelitian dapat dilaksanakan secara terarah, terstruktur, dan saling berkaitan. Penyusunan tahapan penelitian juga bertujuan untuk memastikan bahwa setiap kegiatan yang dilakukan mendukung proses pengembangan model prediksi lintasan siklon tropis menggunakan *Long Short-Term Memory* (LSTM) serta implementasinya pada prototipe dashboard berbasis Streamlit. Adapun tahapan penelitian dalam penelitian ini meliputi penelitian pendahuluan, pengumpulan data, analisis, perancangan, implementasi, pengujian, dan kesimpulan.

3.3.1 Penelitian Pendahuluan

Penelitian pendahuluan dilakukan untuk memahami permasalahan prediksi lintasan siklon tropis sekaligus menentukan pendekatan yang digunakan dalam penelitian. Tahap ini diawali dengan mengidentifikasi karakteristik data historis siklon pada wilayah *North Indian Ocean* (NI) dan *South Indian Ocean* (SI), serta mengkaji penerapan metode *deep learning* untuk mempelajari pola pergerakan siklon berbasis *time series*.

Kajian literatur dilakukan terhadap penelitian yang membahas prediksi lintasan siklon tropis menggunakan algoritma Long Short-Term Memory (LSTM). Hasil kajian menunjukkan bahwa LSTM banyak digunakan untuk prediksi *time series* karena mampu mempelajari hubungan temporal dari data historis dan memberikan hasil yang baik dibandingkan beberapa metode *recurrent neural network*.

Meskipun demikian, sebagian besar penelitian masih menggunakan data dari satu wilayah perairan. Penelitian pada *North Indian Ocean* umumnya hanya

memanfaatkan data dari wilayah tersebut, sedangkan penelitian pada *South Indian Ocean* lebih banyak membahas karakteristik siklon. Penelitian yang menggabungkan data dari kedua wilayah dalam satu model prediksi juga masih terbatas.

Berdasarkan hasil kajian tersebut, penelitian ini menggunakan tiga konfigurasi *dataset*, yaitu *North Indian Ocean* (NI), *South Indian Ocean* (SI), dan gabungan keduanya (GAB). Selain itu, penelitian ini menguji pengaruh variasi panjang *sliding window* terhadap kemampuan model dalam mempelajari pola pergerakan siklon tropis. Hasil penelitian pendahuluan menjadi dasar dalam penyusunan metode dan tahapan penelitian.

3.3.2 Pengumpulan Data

Tahap pengumpulan data dilakukan untuk memperoleh data yang akan digunakan selama proses penelitian. Pada tahap ini ditentukan sumber data yang digunakan, cakupan wilayah penelitian, serta metode penelitian yang menjadi dasar dalam memperoleh dan mengelola data sesuai dengan kebutuhan penelitian. Penentuan ketiga aspek tersebut bertujuan agar data yang digunakan memiliki kesesuaian dengan tujuan penelitian serta dapat mendukung proses analisis, perancangan, implementasi, dan pengujian model prediksi lintasan siklon tropis. Adapun tahapan pengumpulan data dalam penelitian ini meliputi sumber data, wilayah penelitian, dan metode penelitian.

3.3.2.1 Sumber Data

Sumber data dalam penelitian ini berasal dari *International Best Track Archive for Climate Stewardship* (IBTrACS) versi 4r01 yang dipublikasikan oleh *National Oceanic and Atmospheric Administration* (NOAA) melalui *National*

Centers for Environmental Information (NCEI). IBTrACS merupakan basis data siklon tropis global yang mengintegrasikan data *best track* dari berbagai pusat meteorologi yang diakui oleh *World Meteorological Organization* (WMO), sehingga menyediakan data dengan format yang seragam untuk kebutuhan penelitian.

Penelitian ini menggunakan data historis siklon tropis pada wilayah *North Indian Ocean* (NI) dan *South Indian Ocean* (SI) dengan periode pengamatan tahun 1980 hingga 2025. Sebelum digunakan, dilakukan identifikasi untuk mengetahui cakupan data, jumlah rekaman, dan struktur atribut yang tersedia. Ringkasan data beserta lima baris pertama ditunjukkan pada Gambar 3.2.

```
Memuat data dari cache: /content/drive/MyDrive/Skripsi/dataset/ibtracs.NI.1980-2025.csv
Memuat data dari cache: /content/drive/MyDrive/Skripsi/dataset/ibtracs.SI.1980-2025.csv

Data NI (1980-2025) : 17801 baris
Data SI (1980-2025) : 68668 baris
Data Gabungan      : 86469 baris
Total kolom        : 174
```

🔍 Lima baris pertama data gabungan:

	SID	SEASON	NUMBER	BASIN	SUBBASIN	NAME	ISO_TIME	NATURE	LAT	LON	WMO_WIND	WMO_PRES	WMO_AGENCY	TRACK_TYPE	DIST2LAND	LANDFALL
0	1980284N09092	1980	84	NI	BB	UNNAMED 1980-10-10 06:00:00	TS	8.8	92.3					main	480	466
1	1980284N09092	1980	84	NI	BB	UNNAMED 1980-10-10 09:00:00	TS	8.8	92.6					main	459	454
2	1980284N09092	1980	84	NI	BB	UNNAMED 1980-10-10 12:00:00	TS	8.9	92.8					main	454	448
3	1980284N09092	1980	84	NI	BB	UNNAMED 1980-10-10 15:00:00	TS	9.0	93.0					main	451	445
4	1980284N09092	1980	84	NI	BB	UNNAMED 1980-10-10 18:00:00	TS	9.1	93.2					main	449	444

Gambar 3.2 Ringkasan Dataset


Berdasarkan Gambar 3.2, data pada wilayah *North Indian Ocean* terdiri atas 17.801 observasi, sedangkan wilayah *South Indian Ocean* terdiri atas 68.668 observasi. Penggabungan kedua wilayah menghasilkan 86.469 observasi dengan 174 atribut. Lima baris pertama pada dataset memperlihatkan struktur data yang memuat identitas siklon, waktu pengamatan, wilayah pembentukan, koordinat geografis, serta parameter meteorologi.

Meskipun IBTrACS menyediakan 174 atribut, penelitian ini hanya menggunakan lima atribut, yaitu *ISO_TIME*, *LAT*, *LON*, *WMO_WIND*, dan *WMO_PRES*. Kelima atribut tersebut dipilih karena mewakili informasi waktu pengamatan, posisi geografis, kecepatan angin maksimum, dan tekanan udara yang

diperlukan dalam pengembangan model Long Short-Term Memory (LSTM). Selanjutnya, atribut tersebut digunakan pada tahap analisis data, *preprocessing*, *feature engineering*, pelatihan model, dan evaluasi.

3.3.2.2 Wilayah Penelitian

Wilayah penelitian mencakup kawasan Samudra Hindia yang terdiri atas dua wilayah pembentukan siklon tropis, yaitu *North Indian Ocean* (NI) dan *South Indian Ocean* (SI). Kedua wilayah tersebut dipilih karena memiliki karakteristik atmosfer dan dinamika siklon tropis yang berbeda, terutama sebagai akibat dari pengaruh letak geografis, sirkulasi atmosfer, serta gaya Coriolis pada belahan bumi utara dan belahan bumi selatan. Perbedaan karakteristik tersebut menjadi salah satu fokus penelitian untuk mengetahui pengaruh penggunaan data dari masing-masing *basin* maupun data gabungan terhadap kinerja model *Long Short-Term Memory* (LSTM).



Gambar 3.3 Peta Wilayah Penelitian

Penelitian ini menggunakan seluruh data historis siklon tropis yang tercatat pada *basin* NI dan SI dalam dataset IBTrACS selama periode 1980 hingga 2025

tanpa melakukan pembatasan berdasarkan wilayah administratif maupun lintang dan bujur tertentu. Dengan demikian, setiap lintasan siklon dianalisis secara utuh sesuai dengan data yang tersedia pada masing-masing *basin*. Pendekatan ini bertujuan agar model dapat mempelajari pola pergerakan siklon tropis berdasarkan karakteristik alami setiap wilayah, sehingga hasil evaluasi yang diperoleh mencerminkan pengaruh konfigurasi dataset yang digunakan.

3.3.3 Analisis

Tahap analisis dilakukan untuk memperoleh pemahaman terhadap data yang digunakan, alur proses penelitian, serta kebutuhan sistem yang akan dikembangkan. Hasil analisis menjadi dasar dalam menentukan proses pengolahan data, perancangan model, dan pengembangan prototipe dashboard sehingga setiap tahapan penelitian dapat dilaksanakan secara terarah dan sesuai dengan tujuan penelitian. Pada penelitian ini, tahap analisis terdiri atas analisis data, analisis proses, dan analisis sistem yang saling berkaitan dalam mendukung pengembangan model prediksi lintasan siklon tropis menggunakan *Long Short-Term Memory* (LSTM) serta implementasinya pada dashboard berbasis Streamlit.

3.3.3.1 Analisis Data

Analisis data dilakukan untuk memahami karakteristik dataset yang akan digunakan sebelum memasuki tahap pengolahan dan pemodelan. Tahap ini bertujuan untuk mengidentifikasi struktur data, jenis atribut, kualitas data, serta hubungan antarvariabel sehingga dapat ditentukan proses pengolahan yang sesuai dengan kebutuhan penelitian. Analisis data juga menjadi dasar dalam menentukan atribut yang digunakan sebagai masukan model prediksi serta atribut yang tidak digunakan dalam proses penelitian.

Pada penelitian ini, analisis dilakukan terhadap dataset IBTrACS versi 4r01 yang mencakup data siklon tropis pada wilayah *North Indian Ocean* (NI) dan *South Indian Ocean* (SI). Dataset dianalisis untuk mengetahui karakteristik setiap atribut, tipe data, kelengkapan data, serta kesesuaian informasi yang tersedia dengan tujuan penelitian. Berdasarkan hasil analisis, penelitian ini menggunakan lima atribut utama sebagai variabel masukan (*input*) model sebagai berikut:

1. ISO_TIME : yaitu waktu pengamatan setiap posisi siklon tropis.
2. LAT (Latitude) : yaitu koordinat lintang yang menunjukkan posisi siklon pada arah utara atau selatan terhadap garis khatulistiwa.
3. LON (Longitude) : yaitu koordinat bujur yang menunjukkan posisi siklon pada arah timur atau barat terhadap Meridian Utama.
4. WMO_WIND : yaitu kecepatan angin maksimum berkelanjutan (*maximum sustained wind*) yang dilaporkan berdasarkan standar *World Meteorological Organization* (WMO).
5. WMO_PRES : yaitu tekanan udara minimum pada pusat siklon berdasarkan standar *World Meteorological Organization* (WMO).

Selain pemilihan atribut, tahap analisis data juga dilakukan untuk mengidentifikasi kondisi data yang memerlukan penanganan lebih lanjut, seperti keberadaan *missing value*, nilai yang tidak valid, maupun perbedaan format data. Hasil analisis tersebut menjadi dasar dalam penyusunan tahapan prapemrosesan (*preprocessing*) yang akan dilakukan sebelum data digunakan pada proses pembentukan fitur, pelatihan model, dan evaluasi. Dengan demikian, data yang

digunakan dalam penelitian telah memenuhi kebutuhan pemodelan serta mampu merepresentasikan karakteristik lintasan siklon tropis secara lebih baik.

3.3.3.2 Analisis Proses

Analisis proses dilakukan untuk menyusun tahapan penelitian yang digunakan dalam pengembangan model prediksi lintasan siklon tropis. Tahapan ini menjadi acuan pelaksanaan penelitian, mulai dari pengolahan data hingga implementasi model ke dalam aplikasi berbasis Streamlit. Adapun tahapan penelitian yang dilakukan adalah sebagai berikut.

1. Pengumpulan Data

Data historis siklon tropis diperoleh dari *International Best Track Archive for Climate Stewardship* (IBTrACS) versi 4r01 yang mencakup wilayah *North Indian Ocean* (NI) dan *South Indian Ocean* (SI) periode 1980 hingga 2025. Data tersebut menjadi sumber utama dalam penelitian.

2. Persiapan Data Awal

Pada tahap ini dilakukan pemilihan atribut yang digunakan, penyesuaian tipe data, serta pembersihan nilai yang tidak sesuai agar struktur data siap diproses pada tahapan berikutnya.

3. Pembagian *Dataset*

Dataset dibagi menjadi data latih (*training set*), data validasi (*validation set*), dan data uji (*testing set*) berdasarkan identitas siklon (*Storm Identifier* atau SID). Pembagian ini memastikan seluruh observasi dari satu siklon berada pada subset yang sama sehingga mencegah terjadinya *data leakage*.

4. Penanganan *Missing Value*

Penanganan *missing value* dilakukan secara terpisah pada data latih, data

validasi, dan data uji setelah proses pembagian *dataset*. Pendekatan ini bertujuan menjaga independensi setiap subset sehingga informasi dari data validasi maupun data uji tidak memengaruhi proses pembelajaran model.

5. *Feature Engineering*

Tahap ini membentuk fitur turunan berdasarkan hubungan antarobservasi untuk merepresentasikan karakteristik pergerakan siklon tropis secara lebih baik. Fitur yang dihasilkan digunakan sebagai masukan model pada proses pelatihan.

6. Normalisasi Data

Seluruh variabel numerik dinormalisasi agar memiliki rentang nilai yang seragam. Proses ini membantu meningkatkan stabilitas dan efektivitas pelatihan model.

7. Pembentukan Data Deret Waktu (*Sliding Window*)

Data yang telah dinormalisasi disusun menjadi data *time series* menggunakan teknik *sliding window*. Beberapa variasi panjang *timesteps* digunakan untuk mengevaluasi pengaruh panjang urutan data terhadap performa model.

8. Pelatihan Model *Long Short-Term Memory* (LSTM)

Model dilatih menggunakan data latih dan dievaluasi menggunakan data validasi untuk memperoleh model dengan performa terbaik dalam memprediksi koordinat lintang dan bujur.

9. Evaluasi Model

Model terbaik diuji menggunakan data uji dengan metrik *Root Mean Squared Error* (RMSE), *Mean Absolute Error* (MAE), *Coefficient of*

Determination (R^2), dan *Haversine Distance Error*. Hasil evaluasi digunakan untuk membandingkan setiap skenario eksperimen dan menentukan model terbaik.

10. Implementasi Aplikasi

Model terbaik diintegrasikan ke dalam aplikasi berbasis Streamlit yang menyediakan visualisasi lintasan siklon, data historis, hasil prediksi, dan informasi evaluasi model dalam satu sistem.

Kesepuluh tahapan tersebut membentuk alur penelitian yang saling berkaitan, mulai dari pengumpulan data hingga implementasi aplikasi. Setiap tahapan dirancang untuk mendukung proses pengembangan model prediksi lintasan siklon tropis secara sistematis sehingga hasil yang diperoleh sesuai dengan tujuan penelitian.

3.3.3.3 Analisis Sistem

Analisis sistem dilakukan untuk mengidentifikasi kebutuhan aplikasi yang akan dikembangkan sebagai media visualisasi hasil prediksi lintasan siklon tropis. Tahap ini bertujuan menentukan komponen utama sistem, alur interaksi, serta informasi yang disajikan kepada pengguna. Hasil analisis menjadi dasar dalam perancangan aplikasi berbasis Streamlit.

Aplikasi yang dikembangkan mengintegrasikan model *Long Short-Term Memory* (LSTM) yang telah melalui proses pelatihan dengan antarmuka berbasis web. Pengguna dapat memilih data siklon yang tersedia, menjalankan proses prediksi, kemudian melihat hasil prediksi bersama lintasan aktual pada peta interaktif. Selain itu, aplikasi juga menyajikan data observasi dan informasi evaluasi model sebagai pendukung analisis. Komponen utama sistem terdiri atas

beberapa bagian sebagai berikut.

1. Data Historis Siklon

Komponen ini menyediakan data historis siklon tropis yang berasal dari dataset IBTrACS. Data digunakan sebagai sumber informasi pada proses prediksi serta ditampilkan pada halaman data siklon.

2. Model *Long Short-Term Memory* (LSTM)

Model LSTM berfungsi menghasilkan prediksi koordinat lintang dan bujur berdasarkan data masukan. Model yang digunakan merupakan model terbaik hasil proses pelatihan dan evaluasi.

3. Modul Prediksi

Modul ini menghubungkan data masukan dengan model LSTM untuk menghasilkan prediksi posisi siklon pada waktu berikutnya. Hasil prediksi kemudian diteruskan ke proses visualisasi.

4. Dashboard Streamlit

Dashboard berfungsi sebagai antarmuka pengguna (*user interface*) yang menyajikan visualisasi lintasan aktual dan hasil prediksi pada peta interaktif. Selain itu, juga menampilkan data observasi dan informasi evaluasi model sehingga hasil prediksi dapat dipahami dengan lebih mudah.

Keempat komponen tersebut saling terintegrasi sehingga membentuk alur kerja aplikasi, mulai dari pemilihan data, proses prediksi menggunakan model LSTM, hingga penyajian hasil melalui *dashboard* berbasis Streamlit. Hasil analisis sistem ini menjadi acuan dalam penyusunan rancangan aplikasi pada tahap berikutnya.

3.3.4 Perancangan

Tahap perancangan dilakukan sebagai tindak lanjut dari hasil analisis data, analisis proses, dan analisis sistem yang telah dilakukan pada tahap sebelumnya. Tahap ini bertujuan untuk menyusun rancangan solusi yang akan diterapkan dalam penelitian, baik dari sisi pengembangan model prediksi maupun pengembangan aplikasi. Perancangan menjadi pedoman dalam proses implementasi sehingga setiap komponen dapat dikembangkan secara sistematis, saling terintegrasi, dan sesuai dengan kebutuhan penelitian.

Pada penelitian ini, perancangan difokuskan pada dua aspek utama, yaitu perancangan model prediksi menggunakan algoritma *Long Short-Term Memory* (LSTM) dan perancangan aplikasi berbasis Streamlit. Perancangan model dilakukan untuk menentukan alur pengolahan data, pembentukan data masukan, arsitektur model, serta mekanisme pelatihan dan evaluasi yang digunakan dalam menghasilkan prediksi lintasan siklon tropis. Perancangan aplikasi dilakukan untuk merancang struktur sistem, alur interaksi pengguna, serta penyajian informasi hasil prediksi melalui antarmuka berbasis web sehingga aplikasi dapat digunakan secara interaktif dan mudah dipahami.

Aplikasi yang dikembangkan terdiri atas enam halaman utama, yaitu Beranda, Dashboard, Prediksi Siklon, Data Siklon, Evaluasi Model, dan Tentang. Masing-masing halaman dirancang untuk mendukung fungsi yang berbeda, mulai dari penyampaian informasi penelitian, visualisasi hasil prediksi, penyajian data observasi, evaluasi performa model, hingga penyediaan informasi mengenai aplikasi dan penelitian. Dengan pembagian tersebut, aplikasi diharapkan mampu menyajikan informasi secara terstruktur dan memberikan kemudahan bagi

pengguna dalam mengakses setiap fitur yang tersedia.

3.3.4.1 Perancangan Model *Long Short-Term Memory* (LSTM)

Perancangan model *Long Short-Term Memory* (LSTM) dilakukan sebagai dasar dalam pengembangan model prediksi lintasan siklon tropis. Tahap ini bertujuan untuk menyusun rancangan proses pemodelan yang akan digunakan mulai dari pengolahan data, pembentukan data masukan, proses pelatihan model, hingga evaluasi hasil prediksi. Perancangan tersebut menjadi acuan dalam proses implementasi agar model yang dikembangkan sesuai dengan tujuan penelitian.

Model yang digunakan dalam penelitian ini memanfaatkan algoritma *Long Short-Term Memory* (LSTM) karena memiliki kemampuan dalam mempelajari pola data deret waktu (*time series*). Data historis siklon tropis yang telah melalui tahapan pengolahan selanjutnya digunakan sebagai masukan bagi model untuk mempelajari hubungan antarurutan data sehingga mampu menghasilkan prediksi koordinat lintang dan bujur pada waktu berikutnya.

Perancangan model mencakup tahapan prapemrosesan data (*preprocessing*), pembentukan fitur (*feature engineering*), pembentukan data deret waktu (*sliding window*), pelatihan model, evaluasi model, serta pemilihan model terbaik yang akan digunakan pada aplikasi prediksi lintasan siklon tropis berbasis Streamlit. Setiap tahapan tersebut disusun secara sistematis agar proses pengembangan model berlangsung terstruktur dan menghasilkan model yang sesuai dengan kebutuhan penelitian.

3.3.4.2 Perancangan Aplikasi

Perancangan aplikasi dilakukan sebagai tahap penyusunan rancangan sistem yang akan mengimplementasikan model prediksi lintasan siklon tropis ke dalam aplikasi berbasis *web*. Tahap ini bertujuan untuk menentukan struktur aplikasi, alur navigasi, serta fungsi pada setiap halaman sehingga seluruh komponen sistem dapat saling terintegrasi. Aplikasi dikembangkan menggunakan Streamlit karena mampu mengintegrasikan model *machine learning* dengan antarmuka *web* secara sederhana, interaktif, dan mudah digunakan. Perancangan aplikasi pada penelitian ini terdiri atas enam halaman utama yang saling terhubung, yaitu sebagai berikut.

1. Beranda (Home)

Halaman beranda dirancang sebagai halaman utama yang memberikan informasi umum mengenai aplikasi dan penelitian. Halaman ini berfungsi sebagai pintu masuk bagi pengguna sebelum mengakses fitur-fitur yang tersedia.

2. *Dashboard*

Halaman *dashboard* dirancang untuk menyajikan ringkasan informasi penelitian serta visualisasi utama yang berkaitan dengan prediksi lintasan siklon tropis. Halaman ini memberikan gambaran umum mengenai data dan hasil prediksi secara ringkas.

3. Prediksi Siklon

Halaman prediksi siklon dirancang sebagai fitur utama aplikasi yang digunakan untuk melakukan prediksi lintasan siklon tropis menggunakan model *Long Short-Term Memory* (LSTM). Hasil prediksi ditampilkan dalam bentuk informasi koordinat dan visualisasi lintasan peta interaktif.

4. Data Siklon

Halaman data siklon dirancang untuk menampilkan data historis siklon tropis yang digunakan dalam penelitian. Halaman ini memudahkan pengguna dalam melihat informasi setiap siklon beserta atribut yang tersedia pada dataset.

5. Evaluasi Model

Halaman evaluasi model dirancang untuk menyajikan hasil pengujian performa model menggunakan metrik evaluasi yang telah ditentukan. Halaman ini memberikan informasi mengenai tingkat akurasi model sehingga pengguna dapat memahami kualitas prediksi yang dihasilkan.

6. Tentang

Halaman tentang dirancang untuk menyajikan informasi mengenai aplikasi, penelitian, metode yang digunakan, serta pengembang aplikasi. Halaman ini memberikan gambaran umum mengenai tujuan dan ruang lingkup sistem yang dikembangkan.

Berdasarkan rancangan tersebut, aplikasi dibangun sebagai satu kesatuan sistem yang mengintegrasikan model prediksi, data siklon tropis, proses visualisasi, dan penyajian informasi ke dalam enam halaman yang saling terhubung. Perancangan ini menjadi dasar dalam proses implementasi aplikasi sehingga setiap fitur dapat dikembangkan sesuai dengan fungsi dan kebutuhan penelitian.

3.3.5 Implementasi

Implementasi merupakan tahap penerapan hasil perancangan ke dalam aplikasi yang dapat dijalankan. Tahap ini bertujuan untuk merealisasikan rancangan antarmuka dan fungsionalitas sistem sehingga aplikasi berbasis *Streamlit* dapat

beroperasi sesuai dengan kebutuhan penelitian.

Tahap implementasi difokuskan pada pengembangan aplikasi berbasis *Streamlit* yang mengintegrasikan seluruh komponen sistem ke dalam satu kesatuan. Implementasi meliputi pengembangan setiap halaman aplikasi, pengelolaan data, visualisasi lintasan siklon tropis pada peta interaktif, serta penyajian informasi yang diperlukan pengguna. Seluruh komponen tersebut dikembangkan berdasarkan hasil analisis dan perancangan yang telah dilakukan pada tahap sebelumnya.

Melalui tahap implementasi, rancangan aplikasi diwujudkan menjadi sebuah sistem yang dapat digunakan untuk menampilkan informasi data siklon tropis, melakukan visualisasi lintasan, serta menyajikan hasil prediksi secara interaktif. Dengan demikian, aplikasi berfungsi sebagai media visualisasi yang memudahkan pengguna dalam mengakses dan memahami informasi yang dihasilkan oleh *system*.

3.3.6 Pengujian

Pengujian merupakan tahapan akhir dalam metodologi penelitian yang bertujuan untuk memastikan bahwa aplikasi prediksi lintasan siklon tropis telah dibangun sesuai dengan kebutuhan fungsional dan rancangan sistem yang telah ditetapkan. Pada tahap ini dilakukan verifikasi terhadap setiap fitur aplikasi untuk memastikan bahwa seluruh proses, mulai dari penerimaan masukan (*input*), pengolahan data, proses prediksi, hingga penyajian keluaran (*output*), dapat berjalan dengan benar sehingga aplikasi siap digunakan oleh pengguna.

Metode pengujian yang diterapkan dalam penelitian ini adalah *Black Box Testing*, yaitu metode pengujian yang berfokus pada aspek fungsional sistem tanpa memperhatikan struktur internal maupun kode program. Pengujian dilakukan

dengan memberikan berbagai skenario masukan pada setiap fitur aplikasi, kemudian mengevaluasi apakah keluaran yang dihasilkan telah sesuai dengan spesifikasi kebutuhan sistem.

Pengujian mencakup seluruh halaman dan fitur utama aplikasi, yaitu Beranda, *Dashboard*, Prediksi Siklon, Data Siklon, Evaluasi Model, dan Tentang. Selain itu, pengujian juga dilakukan terhadap proses pemuatan model (*model loading*), pengolahan data masukan, proses prediksi lintasan siklon menggunakan model *Long Short-Term Memory* (LSTM), visualisasi hasil prediksi pada peta interaktif, serta penyajian informasi evaluasi model. Hasil pengujian digunakan untuk memastikan bahwa seluruh komponen aplikasi telah terintegrasi dengan baik, berfungsi sesuai dengan spesifikasi, serta mampu mendukung proses prediksi lintasan siklon tropis secara optimal.

3.3.7 Kesimpulan

Metodologi penelitian yang digunakan pada penelitian ini disusun sebagai kerangka kerja untuk mendukung proses pengembangan model prediksi lintasan siklon tropis menggunakan algoritma *Long Short-Term Memory* (LSTM) serta pengembangan aplikasi berbasis Streamlit. Metodologi tersebut mencakup tahapan penelitian pendahuluan, pengumpulan data, analisis, perancangan, implementasi, dan pengujian yang saling berkaitan dalam mencapai tujuan penelitian.

Penyusunan tahapan penelitian secara sistematis memberikan dasar yang jelas bagi pelaksanaan setiap proses, mulai dari pengolahan data hingga evaluasi model dan aplikasi. Dengan metodologi yang terstruktur, setiap tahapan penelitian dapat dilaksanakan secara konsisten sehingga proses pengembangan model dan aplikasi memiliki alur kerja yang jelas serta sesuai dengan tujuan penelitian.

BAB IV

ANALISA DAN PERANCANGAN

4.1 Analisa

Analisa merupakan tahapan yang dilakukan untuk memperoleh pemahaman secara menyeluruh terhadap objek penelitian sebagai dasar dalam proses perancangan model dan aplikasi. Tahapan ini bertujuan mengidentifikasi kondisi data, proses pengolahan data, serta kebutuhan sistem sehingga rancangan yang dihasilkan sesuai dengan karakteristik permasalahan yang akan diselesaikan.

Dalam penelitian ini, analisa dilakukan secara bertahap terhadap data yang digunakan, proses pengolahan data hingga siap digunakan oleh model, serta kebutuhan sistem yang mendukung proses prediksi lintasan siklon tropis. Setiap hasil analisa memberikan informasi yang diperlukan dalam menentukan rancangan model *Long Short-Term Memory* (LSTM) maupun rancangan aplikasi yang akan dibangun.

4.1.1 Analisis Data

Analisa data merupakan tahapan untuk memahami karakteristik dataset yang digunakan sebagai dasar dalam pengembangan model prediksi lintasan siklon tropis. Melalui proses ini, dilakukan identifikasi terhadap kualitas, cakupan, serta karakteristik data sehingga informasi yang diperoleh dapat digunakan untuk menentukan metode pengolahan data dan perancangan model yang sesuai. Analisa data juga bertujuan untuk memastikan bahwa data yang digunakan mampu merepresentasikan kondisi pergerakan siklon tropis serta memenuhi kebutuhan dalam proses pembelajaran model.

Pada penelitian ini, analisa data dilakukan terhadap dataset siklon tropis yang meliputi sumber data, variabel penelitian, wilayah kajian, karakteristik dataset, serta berbagai analisis statistik untuk memperoleh gambaran mengenai distribusi dan pola data. Selain itu, dilakukan analisis terhadap karakteristik musiman dan keberadaan *outlier* sebagai bagian dari identifikasi kondisi data sebelum memasuki tahap pengolahan lebih lanjut. Hasil dari keseluruhan analisa tersebut menjadi dasar dalam menentukan tahapan pengolahan data yang diperlukan sebelum proses pembentukan model dilakukan.

4.1.1.1 Sumber Data

Penelitian ini menggunakan data historis siklon tropis yang bersumber dari *International Best Track Archive for Climate Stewardship* (IBTrACS) Version 04r01 yang dipublikasikan oleh *National Oceanic and Atmospheric Administration* (NOAA). IBTrACS merupakan basis data global yang mengintegrasikan data lintasan siklon tropis dari berbagai *Regional Specialized Meteorological Centre* (RSMC) dan *Tropical Cyclone Warning Center* (TCWC), sehingga menyediakan informasi historis yang lengkap dan telah terstandarisasi untuk keperluan penelitian maupun analisis meteorologi.

Dataset yang digunakan mencakup data pengamatan siklon tropis pada periode tahun 1980 hingga 2025 dengan wilayah penelitian yang difokuskan pada *North Indian Ocean* (NI) dan *South Indian Ocean* (SI). Selain digunakan secara terpisah berdasarkan masing-masing basin, kedua dataset tersebut juga digabungkan menjadi satu dataset (GAB) untuk membandingkan pengaruh cakupan data terhadap performa model prediksi lintasan siklon tropis.

Tabel 4.1 Karakteristik Sumber Data Penelitian

Komponen	Keterangan
Nama Dataset	International Best Track Archive for Climate Stewardship (IBTrACS)
Versi Dataset	Version 04r01
Penyedia Data	National Oceanic and Atmospheric Administration (NOAA)
Organisasi Penyusun	World Meteorological Organization (WMO) melalui integrasi data berbagai RSMC dan TCWC
Format Data	Comma Separated Values (CSV)
Periode Pengamatan	1980–2025
Wilayah Penelitian	North Indian Ocean (NI) dan South Indian Ocean (SI)
Skenario Dataset	NI, SI, dan Gabungan (GAB)
Jumlah Data NI	17.801 observasi
Jumlah Data SI	68.668 observasi
Jumlah Data Gabungan	86.469 observasi
Jumlah Atribut Awal	174 atribut
Interval Pengamatan	3 jam (berdasarkan waktu observasi pada IBTrACS)
Parameter Utama	Identitas siklon, waktu observasi, posisi geografis, kecepatan angin, tekanan udara

Berdasarkan Tabel 4.1, dataset penelitian menggunakan data historis siklon tropis IBTrACS Version 04r01 dengan periode pengamatan tahun 1980–2025 yang mencakup wilayah *North Indian Ocean* dan *South Indian Ocean*. Data tersebut disusun dalam tiga skenario penelitian, yaitu dataset *North Indian* (NI), *South Indian* (SI), dan Gabungan (GAB). Sebelum digunakan pada tahap pengolahan data, dataset masih berada dalam bentuk data mentah (*raw dataset*) yang terdiri atas 174 atribut, sehingga diperlukan proses identifikasi terhadap struktur dan informasi yang terkandung di dalamnya.

	SID	SEASON	BASIN	ISO_TIME	LAT	LON	WMO_WIND	WMO_PRES	WMO_AGENCY	TRACK_TYPE
0	1980284N09092	1980	NI	1980-10-10 06:00:00	8.8	92.3				main
1	1980284N09092	1980	NI	1980-10-10 09:00:00	8.8	92.6				main
2	1980284N09092	1980	NI	1980-10-10 12:00:00	8.9	92.8				main
3	1980284N09092	1980	NI	1980-10-10 15:00:00	9.0	93.0				main
4	1980284N09092	1980	NI	1980-10-10 18:00:00	9.1	93.2				main

... 86,463 baris lainnya disembunyikan ...

Ringkasan: 86,469 observasi, 10 kolom utama.

Gambar 4.1 Ringkasan Dataset

Berdasarkan Gambar 4.1, dataset penelitian terdiri atas 17.801 data pada wilayah North Indian Ocean dan 68.668 data pada wilayah South Indian Ocean, sehingga menghasilkan 86.469 data pada dataset gabungan dengan 174 atribut. Ringkasan tersebut memberikan gambaran mengenai cakupan dataset yang digunakan dalam penelitian. Setiap baris data merepresentasikan satu observasi siklon tropis pada waktu tertentu yang memuat informasi identitas siklon (*SID*), musim kejadian (*SEASON*), wilayah perairan (*BASIN*), waktu pengamatan (*ISO_TIME*), posisi geografis berupa lintang (*LAT*) dan bujur (*LON*), serta parameter meteorologi seperti kecepatan angin maksimum (*WMO_WIND*), tekanan udara minimum (*WMO_PRES*), lembaga penyedia data (*WMO_AGENCY*), dan jenis lintasan (*TRACK_TYPE*). Informasi tersebut menunjukkan bahwa dataset IBTrACS menyediakan data historis yang lengkap untuk mendukung proses analisis dan pengembangan model prediksi lintasan siklon tropis.

4.1.1.2 Variabel Penelitian

Variabel penelitian merupakan atribut yang dipilih dari dataset *International Best Track Archive for Climate Stewardship (IBTrACS)* sesuai dengan kebutuhan pengembangan model prediksi lintasan siklon tropis. Proses pemilihan variabel

dilakukan dengan mempertimbangkan keterkaitan setiap atribut terhadap tujuan penelitian, sehingga hanya atribut yang memiliki informasi spasial, temporal, dan meteorologi yang digunakan dalam proses pengolahan data.

Variabel yang digunakan terdiri atas waktu pengamatan, posisi geografis siklon, serta parameter meteorologi yang menggambarkan kondisi fisik siklon selama masa pengamatan. Posisi geografis yang direpresentasikan oleh koordinat lintang dan bujur menjadi informasi utama dalam pembentukan lintasan siklon, sedangkan kecepatan angin dan tekanan udara digunakan sebagai variabel pendukung untuk memberikan informasi mengenai karakteristik intensitas siklon pada setiap waktu pengamatan.

Tabel 4.2 Variabel Penelitian

Nama Variabel	Tipe Data	Satuan	Keterangan
<i>ISO_TIME</i>	<i>DateTime</i>	UTC	Waktu pengamatan siklon tropis dengan interval observasi setiap tiga jam.
<i>LAT</i>	<i>Float</i>	Derajat (°)	Posisi lintang pusat siklon tropis. Nilai negatif menunjukkan wilayah Lintang Selatan.
<i>LON</i>	<i>Float</i>	Derajat (°)	Posisi bujur pusat siklon tropis pada wilayah Samudra Hindia.
<i>WMO_WIND</i>	<i>Numerik</i>	Knot	Kecepatan angin maksimum berkelanjutan berdasarkan standar (<i>WMO</i>).
<i>WMO_PRES</i>	<i>Numerik</i>	Milibar (mb)	Tekanan udara minimum pada pusat siklon tropis berdasarkan standar <i>WMO</i> .

Koordinat *LAT* dan *LON* merupakan variabel utama yang digunakan untuk merepresentasikan posisi siklon tropis pada setiap waktu pengamatan sekaligus menjadi target prediksi yang dihasilkan oleh model. Sementara itu, *WMO_WIND* dan *WMO_PRES* berfungsi sebagai variabel pendukung yang memberikan informasi mengenai kondisi meteorologi siklon selama proses pembelajaran model. Kombinasi informasi spasial dan meteorologi tersebut diharapkan mampu

membantu model dalam mempelajari pola pergerakan siklon secara lebih baik.

4.1.1.3 Wilayah Kajian

Wilayah penelitian mencakup dua basin siklon tropis di kawasan Samudra Hindia, yaitu *North Indian Ocean* dan *South Indian Ocean*. Kedua wilayah tersebut dipilih karena memiliki karakteristik geografis dan cakupan data yang berbeda, sehingga memberikan variasi pola lintasan yang dapat dimanfaatkan dalam proses pengembangan dan evaluasi model prediksi.

Tabel 4.3 Karakteristik Data

Karakteristik	<i>North Indian (NI)</i>	<i>South Indian (SI)</i>
Jumlah observasi	17.801	68.668
Jumlah siklon	458	903
Periode pengamatan	10 Oktober 1980 – 2 Desember 2025	1 Januari 1980 – 31 Desember 2025
Rentang lintang	0,70° hingga 31,00°	-59,70° hingga -1,90°
Rentang bujur	42,90° hingga 163,70°	11,30° hingga 179,70°
Cakupan lintang	30,30°	57,80°
Cakupan bujur	120,80°	168,40°
Belahan bumi	Utara	Selatan
Melintasi ekuator	Tidak	Tidak

Karakteristik masing-masing wilayah menunjukkan perbedaan, baik dari jumlah data maupun cakupan spasial. Wilayah *North Indian Ocean* terdiri atas 17.801 observasi yang berasal dari 458 siklon tropis, sedangkan wilayah *South Indian Ocean* memiliki 68.668 observasi yang berasal dari 903 siklon tropis. Perbedaan tersebut menunjukkan bahwa dataset pada wilayah *South Indian Ocean* memiliki jumlah observasi dan jumlah siklon yang lebih besar dibandingkan wilayah *North Indian Ocean*.

Selain jumlah data, kedua wilayah juga memiliki cakupan geografis yang berbeda. Wilayah *North Indian Ocean* berada pada belahan bumi utara dengan rentang lintang $0,70^{\circ}$ hingga $31,00^{\circ}$ dan rentang bujur $42,90^{\circ}$ hingga $163,70^{\circ}$. Sebaliknya, wilayah *South Indian Ocean* berada pada belahan bumi selatan dengan rentang lintang $-59,70^{\circ}$ hingga $-1,90^{\circ}$ dan rentang bujur $11,30^{\circ}$ hingga $179,70^{\circ}$. Meskipun berada pada belahan bumi yang berbeda, kedua wilayah tidak melintasi garis khatulistiwa sehingga setiap basin memiliki karakteristik pergerakan siklon yang relatif independen.

Perbedaan karakteristik spasial maupun jumlah observasi tersebut menjadi salah satu pertimbangan dalam penyusunan skenario penelitian. Oleh karena itu, selain dilakukan pelatihan secara terpisah pada masing-masing basin, penelitian ini juga menggunakan dataset gabungan untuk mengevaluasi pengaruh cakupan data terhadap performa model prediksi lintasan siklon tropis.

4.1.1.4 Karakteristik Dasar Dataset

Karakteristik dataset dianalisis untuk memperoleh gambaran mengenai kondisi data yang digunakan sebelum memasuki tahap pengolahan. Analisis ini meliputi karakteristik umum, karakteristik temporal, dan karakteristik spasial sehingga dapat diketahui cakupan data, distribusi pengamatan, serta batas wilayah observasi pada masing-masing skenario penelitian. Informasi tersebut menjadi dasar dalam menentukan tahapan pengolahan data dan penyusunan model prediksi lintasan siklon tropis.

Tabel 4.4 Karakteristik Umum Dataset Penelitian

Karakteristik	North Indian	South Indian	Gabungan
Jumlah atribut	6	6	6
Jumlah observasi	17.801	68.668	86.469
Jumlah siklon	458	903	1.361
Penggunaan memori	834,6 KB	3,2 MB	4,0 MB

Karakteristik umum menunjukkan bahwa ketiga skenario penelitian menggunakan enam atribut yang sama, sehingga perbedaan dataset hanya terletak pada jumlah observasi dan jumlah siklon yang dianalisis. Dataset *South Indian* memiliki jumlah observasi hampir empat kali lebih banyak dibandingkan dataset *North Indian*, sedangkan dataset gabungan merupakan hasil penggabungan kedua wilayah dengan total 86.469 observasi dan 1.361 siklon. Perbedaan jumlah data tersebut menunjukkan bahwa setiap skenario memiliki tingkat ketersediaan data yang berbeda, sehingga memungkinkan dilakukan evaluasi terhadap pengaruh ukuran dataset terhadap proses pembelajaran model. Selanjutnya dilakukan identifikasi terhadap karakteristik temporal untuk mengetahui rentang waktu pengamatan dan kepadatan observasi pada masing-masing skenario penelitian.

Tabel 4.5 Karakteristik Temporal Dataset

Karakteristik	North Indian	South Indian	Gabungan
Periode pengamatan	10 Okt 1980 – 2 Des 2025	1 Jan 1980 – 31 Des 2025	1 Jan 1980 – 31 Des 2025
Interval observasi	3 jam	3 jam	3 jam
Jumlah siklon	458	903	1.361
Rata-rata observasi/siklon	38,9	76,0	63,5

Karakteristik temporal memperlihatkan bahwa seluruh dataset menggunakan interval pengamatan yang seragam, yaitu setiap tiga jam. Keseragaman interval tersebut menghasilkan urutan data yang konsisten sehingga

sesuai untuk proses pembentukan data sekuens menggunakan metode *sliding window*. Selain itu, rata-rata jumlah observasi pada setiap siklon menunjukkan adanya perbedaan panjang lintasan yang terekam pada masing-masing wilayah. Dataset *South Indian* memiliki rata-rata observasi per siklon yang lebih tinggi dibandingkan *North Indian*, yang menunjukkan bahwa siklon pada wilayah tersebut umumnya memiliki rekaman pengamatan yang lebih panjang. Selain aspek temporal, dilakukan pula identifikasi terhadap cakupan spasial untuk mengetahui batas wilayah observasi pada masing-masing dataset.

Tabel 4.6 Karakteristik Spasial Dataset

Karakteristik	North Indian	South Indian	Gabungan
Rentang lintang	0,70° s.d. 31,00°	-59,70° s.d. - 1,90°	-59,70° s.d. 31,00°
Rentang bujur	42,90° s.d. 163,70°	11,30° s.d. 179,70°	11,30° s.d. 179,70°
Belahan bumi	Utara	Selatan	Utara dan Selatan
Melintasi ekuator	Tidak	Tidak	Tidak

Karakteristik spasial menunjukkan bahwa dataset *North Indian* dan *South Indian* berada pada belahan bumi yang berbeda dengan cakupan koordinat yang tidak saling tumpang tindih. Dataset gabungan mengakomodasi keseluruhan cakupan wilayah dari kedua basin sehingga memiliki rentang koordinat yang lebih luas. Meskipun demikian, seluruh observasi tetap berada pada wilayah masing-masing tanpa melintasi garis khatulistiwa. Perbedaan cakupan spasial tersebut memberikan variasi pola lintasan yang dapat dimanfaatkan untuk mengevaluasi kemampuan model dalam mempelajari karakteristik pergerakan siklon pada masing-masing wilayah maupun pada dataset gabungan.

4.1.1.5 Analisis Statistik Karakteristik Data

Analisis statistik dilakukan untuk mengidentifikasi karakteristik pergerakan siklon tropis pada wilayah *North Indian Ocean* dan *South Indian Ocean* serta mengetahui apakah terdapat perbedaan karakteristik di antara kedua basin tersebut. Pengujian dilakukan terhadap beberapa parameter yang merepresentasikan pola pergerakan siklon, yaitu distribusi arah pergerakan (*bearing*), kecepatan perpindahan, perubahan arah lintasan (*turning angle*), dan panjang lintasan. Hasil analisis ini memberikan gambaran mengenai tingkat kesamaan maupun perbedaan karakteristik data pada masing-masing wilayah penelitian.

1. Uji Kolmogorov-Smirnov

Uji Kolmogorov-Smirnov digunakan untuk membandingkan distribusi arah pergerakan (*bearing*) antara *North Indian Ocean* dan *South Indian Ocean*. Pengujian ini bertujuan untuk mengetahui apakah kedua kelompok data memiliki distribusi yang sama atau menunjukkan perbedaan secara statistik.

Tabel 4.7 Uji Kolmogorov-Smirnov Distribusi Bearing

Parameter	Nilai
Jumlah data <i>North Indian</i>	15.986
Jumlah data <i>South Indian</i>	65.058
<i>KS Statistic</i>	0,4802
<i>p-value</i>	$< 1 \times 10^{-16}$
Keputusan	Berbeda signifikan

Hasil pengujian menunjukkan nilai *KS Statistic* sebesar 0,4802 dengan *p-value* kurang dari 1×10^{-16} . Nilai *p-value* yang lebih kecil daripada taraf signifikansi 0,05 menunjukkan bahwa distribusi arah pergerakan (*bearing*)

siklon pada *North Indian Ocean* dan *South Indian Ocean* berbeda secara signifikan. Hasil ini menunjukkan bahwa kedua basin memiliki karakteristik arah pergerakan yang berbeda sehingga pola lintasan pada masing-masing wilayah juga menunjukkan perbedaan distribusi.

2. Uji Mann-Whitney U

Selain distribusi arah pergerakan, dilakukan pula pengujian terhadap karakteristik kecepatan perpindahan, *turning angle*, dan panjang lintasan menggunakan Uji Mann-Whitney U. Pengujian ini bertujuan untuk mengetahui apakah terdapat perbedaan karakteristik pada ketiga variabel tersebut antara *North Indian Ocean* dan *South Indian Ocean*.

Tabel 4.8 Uji Mann-Whitney U

Variabel	Median NI	Median SI	<i>p-value</i>	Keputusan
Kecepatan perpindahan (km/jam)	13,29	14,19	$1,64 \times 10^{-11}$	Berbeda signifikan
<i>Turning angle</i> (°)	10,44	10,06	0,8281	Tidak berbeda signifikan
Panjang lintasan (km)	1.334,98	3.048,97	$8,14 \times 10^{-68}$	Berbeda signifikan

Hasil pengujian menunjukkan bahwa kecepatan perpindahan siklon memiliki perbedaan yang signifikan antara kedua wilayah penelitian. Nilai median kecepatan perpindahan pada *South Indian Ocean* sebesar 14,19 km/jam, sedangkan pada *North Indian Ocean* sebesar 13,29 km/jam. Perbedaan tersebut diperkuat oleh nilai *p-value* sebesar $1,64 \times 10^{-11}$ yang berada di bawah taraf signifikansi 0,05. Berbeda dengan kecepatan perpindahan, variabel *turning angle* tidak menunjukkan perbedaan yang signifikan. Nilai *p-value* sebesar 0,8281 mengindikasikan bahwa perubahan arah lintasan siklon pada kedua basin memiliki karakteristik yang relatif

serupa. Meskipun kedua wilayah berada pada belahan bumi yang berbeda, pola perubahan arah lintasan yang terjadi tidak menunjukkan perbedaan yang bermakna secara statistik.

Perbedaan yang paling mencolok ditemukan pada panjang lintasan siklon. Median panjang lintasan pada *South Indian Ocean* mencapai 3.048,97 km, sedangkan pada *North Indian Ocean* sebesar 1.334,98 km. Nilai *p-value* sebesar $8,14 \times 10^{-68}$ menunjukkan bahwa perbedaan tersebut sangat signifikan. Hasil ini mengindikasikan bahwa siklon tropis di wilayah *South Indian Ocean* cenderung memiliki lintasan yang lebih panjang dibandingkan dengan siklon pada wilayah *North Indian Ocean*.

Secara keseluruhan, hasil uji statistik menunjukkan bahwa karakteristik pergerakan siklon pada kedua basin tidak sepenuhnya sama. Perbedaan yang signifikan ditemukan pada distribusi arah pergerakan, kecepatan perpindahan, dan panjang lintasan, sedangkan karakteristik perubahan arah lintasan (*turning angle*) menunjukkan pola yang relatif serupa. Temuan tersebut menunjukkan bahwa masing-masing wilayah memiliki karakteristik pergerakan yang berbeda, sehingga penggunaan tiga skenario dataset, yaitu *North Indian*, *South Indian*, dan gabungan, menjadi relevan untuk memperoleh gambaran yang lebih menyeluruh mengenai performa model dalam mempelajari pola lintasan siklon tropis.


4.1.1.6 Analisis Distribusi Data

Analisis distribusi data dilakukan untuk memahami pola penyebaran data penelitian berdasarkan karakteristik spasial, parameter meteorologi, dan distribusi temporal aktivitas siklon tropis. Tahap ini bertujuan untuk mengidentifikasi sebaran data pada masing-masing wilayah penelitian sehingga dapat memberikan gambaran

mengenai variasi karakteristik yang akan dipelajari oleh model *Long Short-Term Memory (LSTM)*. Analisis dilakukan terhadap distribusi koordinat geografis (*latitude* dan *longitude*), parameter meteorologi berupa kecepatan angin (*WMO_WIND*) dan tekanan udara minimum (*WMO_PRES*), serta distribusi aktivitas siklon berdasarkan bulan kejadian.

4.1.1.6.1 Distribusi Spasial dan Parameter Meteorologi


Distribusi data berdasarkan koordinat geografis dan parameter meteorologi digunakan untuk menggambarkan pola penyebaran observasi pada masing-masing basin. Visualisasi distribusi ditampilkan menggunakan histogram yang dilengkapi dengan kurva kepadatan sehingga bentuk distribusi data dapat diamati dengan lebih jelas



Gambar 4.2 Distribusi Frekuensi *Latitude* dan *Longitude*

Berdasarkan Gambar 4.2, distribusi *latitude* menunjukkan pemisahan yang jelas antara kedua wilayah penelitian. Seluruh data pada *North Indian Ocean* berada pada lintang utara dengan rentang sekitar 0° hingga 30°, sedangkan data pada *South Indian Ocean* berada pada lintang selatan dengan rentang sekitar -60° hingga 0°. Kondisi tersebut menunjukkan bahwa kedua basin memiliki cakupan geografis yang berbeda sehingga tidak terdapat tumpang tindih wilayah observasi.

Distribusi *longitude* memperlihatkan bahwa kedua wilayah memiliki rentang bujur yang relatif luas, meskipun terdapat beberapa bagian wilayah yang saling beririsan. Data pada *North Indian Ocean* terkonsentrasi pada kisaran 70°BT hingga 90°BT, sedangkan *South Indian Ocean* memiliki penyebaran yang lebih luas, mulai dari sekitar 40°BT hingga lebih dari 140°BT. Sebaran tersebut menunjukkan bahwa wilayah *South Indian Ocean* mencakup area observasi yang lebih luas dibandingkan *North Indian Ocean*. Selain distribusi spasial, dilakukan pula analisis terhadap parameter meteorologi yang digunakan sebagai variabel masukan pada proses pemodelan.




Gambar 4.3 Distribusi *WMO_WIND* dan *WMO_PRES*

Berdasarkan Gambar 4.3, distribusi kecepatan angin (*WMO_WIND*) pada kedua basin didominasi oleh siklon dengan intensitas rendah hingga sedang. Frekuensi observasi cenderung menurun seiring meningkatnya kecepatan angin, sehingga distribusi membentuk pola yang condong ke kanan (*right-skewed*). Meskipun demikian, *South Indian Ocean* memiliki jumlah observasi yang lebih besar pada hampir seluruh rentang kecepatan angin dibandingkan *North Indian Ocean*, sejalan dengan jumlah data yang lebih banyak pada wilayah tersebut. Distribusi tekanan udara minimum (*WMO_PRES*) menunjukkan pola yang berlawanan dengan distribusi kecepatan angin. Sebagian besar observasi

terkonsentrasi pada tekanan udara sekitar 990–1005 hPa, sedangkan observasi dengan tekanan yang sangat rendah memiliki frekuensi yang relatif sedikit. Pola tersebut menunjukkan bahwa sebagian besar siklon yang tercatat berada pada kategori dengan intensitas rendah hingga sedang, sementara kejadian siklon yang sangat intens hanya muncul pada sebagian kecil observasi.

4.1.1.6.2 Distribusi Aktivitas Siklon Berdasarkan Bulan

Selain distribusi spasial dan parameter meteorologi, dilakukan analisis terhadap distribusi aktivitas siklon berdasarkan bulan kejadian. Analisis ini bertujuan untuk mengetahui pola kemunculan siklon sepanjang tahun pada masing-masing basin penelitian.



Gambar 4.4 Distribusi Aktivitas Siklon Tropis Periode 1980–2025

Hasil analisis menunjukkan bahwa aktivitas siklon tropis pada kedua basin memiliki pola musiman yang berbeda. Aktivitas siklon pada *North Indian Ocean* cenderung meningkat pada periode Oktober hingga November, dengan jumlah kejadian tertinggi terjadi pada bulan Oktober. Sebaliknya, aktivitas siklon pada *South Indian Ocean* didominasi pada awal tahun, terutama pada bulan Januari hingga Maret, dengan puncak aktivitas terjadi pada bulan Februari. Perbedaan pola

tersebut dipengaruhi oleh karakteristik musim dan kondisi atmosfer yang berbeda pada masing-masing belahan bumi.

Tabel 4.9 Ringkasan Aktivitas Musiman Siklon Tropis

Karakteristik	<i>North Indian</i>	<i>South Indian</i>
Bulan aktivitas tertinggi	Oktober	Februari
Jumlah siklon tertinggi	102	261

Berdasarkan Tabel 4.9, puncak aktivitas siklon pada *North Indian Ocean* terjadi pada bulan Oktober dengan jumlah 102 siklon, sedangkan *South Indian Ocean* mencapai puncaknya pada bulan Februari dengan jumlah 261 siklon. Perbedaan waktu terjadinya puncak aktivitas menunjukkan bahwa kedua basin memiliki karakteristik musiman yang tidak sama. Variasi distribusi spasial, parameter meteorologi, dan pola temporal tersebut menghasilkan keragaman karakteristik data yang menjadi salah satu faktor penting dalam proses pembelajaran model prediksi lintasan siklon tropis.

4.1.1.7 Implikasi terhadap Perancangan Model

Hasil analisis data menunjukkan bahwa dataset penelitian memiliki karakteristik yang beragam baik dari aspek spasial, temporal, maupun parameter meteorologi. Perbedaan jumlah observasi, cakupan wilayah, distribusi variabel, serta karakteristik pergerakan siklon pada masing-masing basin menunjukkan bahwa data yang digunakan memiliki kompleksitas yang cukup tinggi. Kondisi tersebut menjadi pertimbangan utama dalam menentukan tahapan pengolahan data sebelum proses pembentukan model dilakukan.

Analisis statistik memperlihatkan bahwa terdapat perbedaan karakteristik yang signifikan antara *North Indian Ocean* dan *South Indian Ocean* pada distribusi

arah pergerakan (*bearing*), kecepatan perpindahan, dan panjang lintasan siklon. Selain itu, analisis distribusi data menunjukkan bahwa kedua basin memiliki pola spasial dan distribusi aktivitas musiman yang berbeda. Variasi karakteristik tersebut menunjukkan bahwa setiap wilayah memiliki pola lintasan yang tidak sepenuhnya sama sehingga diperlukan pendekatan yang mampu mempelajari hubungan antarobservasi secara berurutan.

Karakteristik dataset yang tersusun berdasarkan urutan waktu dengan interval pengamatan setiap tiga jam menunjukkan bahwa setiap observasi memiliki keterkaitan dengan observasi sebelumnya. Oleh karena itu, proses pengolahan data tidak dapat dilakukan secara acak (*random*), melainkan harus mempertahankan urutan temporal agar informasi mengenai perubahan posisi dan kondisi siklon tetap terjaga. Kondisi tersebut menjadi dasar dalam penerapan metode *sliding window* untuk membentuk data sekuens yang akan digunakan sebagai masukan model.

Selain mempertahankan urutan temporal, keberadaan variabel dengan skala yang berbeda juga menjadi pertimbangan dalam tahap pengolahan data. Variabel koordinat geografis, kecepatan angin, dan tekanan udara memiliki rentang nilai yang tidak sama sehingga diperlukan proses standardisasi agar seluruh variabel berada pada skala yang sebanding. Langkah tersebut diharapkan dapat membantu proses pembelajaran model menjadi lebih stabil dan mengurangi dominasi variabel yang memiliki rentang nilai lebih besar.

Berdasarkan hasil analisis yang telah dilakukan, proses perancangan model selanjutnya diawali dengan tahapan *preprocessing* yang meliputi penanganan *missing value*, rekayasa fitur, standardisasi data, pembagian dataset berdasarkan *SID*, serta pembentukan data sekuens menggunakan metode *sliding window*.

Tahapan tersebut menjadi dasar dalam proses pembangunan model prediksi lintasan siklon tropis menggunakan *Long Short-Term Memory (LSTM)*.

4.1.2 Analisis Proses

Setelah karakteristik dataset dianalisis, tahapan berikutnya adalah melakukan analisa terhadap proses pengolahan data sebelum digunakan pada proses pemodelan. Tahap ini bertujuan untuk menghasilkan dataset yang telah melalui serangkaian proses *preprocessing* sehingga memiliki struktur yang sesuai dengan kebutuhan model *Long Short-Term Memory (LSTM)*. Seluruh tahapan dilakukan secara berurutan untuk menjaga konsistensi data, mempertahankan hubungan temporal antarobservasi, serta menghasilkan data masukan yang representatif terhadap pola pergerakan siklon tropis.

Proses yang dilakukan meliputi penanganan *missing value*, rekayasa fitur, standardisasi data, pembagian dataset berdasarkan identitas siklon (*Storm Identifier* atau *SID*), pembentukan data sekuens menggunakan metode *sliding window*, perancangan arsitektur model *Long Short-Term Memory (LSTM)*, hingga evaluasi model. Setiap tahapan memiliki fungsi yang saling berkaitan sehingga hasil dari satu proses menjadi masukan bagi proses berikutnya. Alur pengolahan tersebut dirancang untuk memastikan bahwa informasi spasial, temporal, dan meteorologi yang terkandung dalam dataset tetap terjaga selama proses pembentukan model.

Melalui tahapan ini, data mentah yang diperoleh dari *International Best Track Archive for Climate Stewardship (IBTrACS)* diubah menjadi dataset terstruktur yang siap digunakan dalam proses pelatihan dan pengujian model prediksi lintasan siklon tropis. Pembahasan setiap tahapan proses pengolahan data dijelaskan pada subbab berikutnya.

4.1.2.1 Persiapan Data

Persiapan data dilakukan sebagai langkah awal untuk memahami struktur dataset yang akan digunakan dalam proses pengembangan model prediksi lintasan siklon tropis. Dataset penelitian berasal dari *International Best Track Archive for Climate Stewardship (IBTrACS)* versi 4r01 yang mencakup dua wilayah pengamatan, yaitu *North Indian Ocean (NI)* dan *South Indian Ocean (SI)*. Kedua dataset tersebut kemudian digabungkan menjadi satu dataset penelitian sehingga seluruh proses analisis dan pemodelan dilakukan pada sumber data yang sama.

Hasil identifikasi menunjukkan bahwa dataset gabungan terdiri atas 86.469 observasi dengan 174 atribut. Meskipun tersedia banyak variabel, penelitian ini hanya menggunakan atribut yang relevan terhadap proses prediksi lintasan siklon, yaitu SID sebagai identitas setiap siklon, SEASON sebagai tahun kejadian, BASIN sebagai wilayah pembentukan siklon, ISO_TIME sebagai waktu pengamatan, LAT dan LON sebagai koordinat geografis, serta WMO_WIND dan WMO_PRES yang merepresentasikan kecepatan angin maksimum dan tekanan udara minimum berdasarkan standar *World Meteorological Organization (WMO)*. Pemilihan atribut tersebut dilakukan karena mampu merepresentasikan informasi spasial, temporal, dan meteorologi yang diperlukan dalam pembentukan fitur pada tahap selanjutnya.

Identifikasi terhadap struktur dataset menunjukkan bahwa data telah memiliki informasi dasar yang diperlukan untuk proses pemodelan. Namun demikian, dataset masih memerlukan tahapan prapemrosesan agar dapat digunakan sebagai masukan model *Long Short-Term Memory (LSTM)*. Oleh karena itu, proses berikutnya difokuskan pada pemeriksaan kualitas data, penanganan *missing value*,

rekayasa fitur, standardisasi data, serta pembentukan data deret waktu menggunakan teknik *sliding window*.

4.1.2.2 Pembagian *Dataset* Berdasarkan *Storm Identifier* (SID)

Setelah proses prapemrosesan awal selesai, dataset dibagi menjadi tiga subset, yaitu data latih (*training set*), data validasi (*validation set*), dan data uji (*testing set*). Pembagian dataset dilakukan sebagai tahap awal sebelum proses pengolahan data dan pelatihan model sehingga setiap subset memiliki fungsi yang berbeda selama proses penelitian.

Tabel 4.10 Distribusi Data Train, Val, & Test

No	Dataset	Observasi	Jumlah <i>SID</i>
1	Train <i>North Indian</i>	12.616	320
2	Validation <i>North Indian</i>	2.442	68
3	Test <i>North Indian</i>	2.743	70
4	Train <i>South Indian</i>	47.851	632
5	Validation <i>South Indian</i>	9.972	135
6	Test <i>South Indian</i>	10.845	136
7	Train Gabungan	60.23	952
8	Validation Gabungan	13.46	204
9	Test Gabungan	12.779	205

Pada penelitian ini, pembagian dataset dilakukan berdasarkan *Storm Identifier* (*SID*), yaitu identitas unik yang dimiliki setiap siklon tropis. Seluruh observasi yang berasal dari satu *SID* ditempatkan pada subset yang sama sehingga rangkaian data setiap siklon tetap utuh dan tidak terbagi ke dalam subset lain. Pendekatan ini diterapkan untuk menjaga kesinambungan data deret waktu (*time series*) sekaligus menghindari terjadinya *data leakage* antara data latih, data validasi, dan data uji.

Pembagian dataset menggunakan proporsi 70% untuk data latih, 15% untuk data validasi, dan 15% untuk data uji. Proporsi tersebut diterapkan pada setiap skenario penelitian, yaitu *North Indian*, *South Indian*, dan dataset gabungan.

4.1.2.3 Penanganan *Missing Value*

Setelah dataset dibagi berdasarkan *Storm Identifier (SID)*, dilakukan penanganan *missing value* pada setiap subset secara terpisah. Langkah ini bertujuan untuk memastikan bahwa proses imputasi pada data latih tidak dipengaruhi oleh informasi yang berasal dari data validasi maupun data uji, sehingga potensi *data leakage* dapat dihindari, disajikan pada Tabel 4.11..

Tabel 4.11 Jumlah *Missing Value* pada Dataset

No	Dataset	Observasi	Missing Wind	Wind (%)	Missing Pres	Pres (%)
1	Train NI	12616	7460	59.13	7629	60.47
2	Validation NI	2442	1259	51.56	1265	51.8
3	Test NI	2743	1770	64.53	1820	66.35
4	Train SI	47851	27372	57.2	28007	58.53
5	Validation SI	9972	5775	57.91	5925	59.42
6	Test SI	10845	5995	55.28	6214	57.3
7	Train GAB	60230	34663	57.55	35549	59.02
8	Validation GAB	13460	7934	58.95	8101	60.19
9	Test GAB	12779	7034	55.04	7210	56.42

Berdasarkan Tabel 4.11, Pemeriksaan menunjukkan bahwa nilai yang hilang hanya terdapat pada atribut *WMO_WIND* dan *WMO_PRES*, sedangkan atribut *SID*, *ISO_TIME*, *LAT*, dan *LON* tidak memiliki *missing value*. Ringkasan jumlah *missing value* pada masing-masing subset dataset.

Persentase *missing value* pada atribut *WMO_WIND* dan *WMO_PRES* berada pada kisaran 51% hingga 66% pada seluruh subset dataset. Oleh karena itu, diperlukan proses imputasi agar seluruh observasi tetap dapat digunakan pada tahap

pemodelan. Untuk menentukan metode imputasi yang sesuai, dilakukan perbandingan antara metode *linear interpolation*, *forward fill/backward fill*, dan median. Hasil perbandingan ditunjukkan pada Tabel 4.11.

Tabel 4.12 Perbandingan Hasil Imputasi *Missing Value*

Dataset	Observasi	Original Wind	Linear Wind	Fwd/Bwd Wind	Median Wind	Original Pres	Linear Pres	Fwd/Bwd Pres	Median Pres
Train NI	12616	5156	2663	3532	1265	4987	2273	2947	2409
Validation NI	2442	1183	507	538	214	1177	483	365	417
Test NI	2743	973	606	937	227	923	486	786	548
Train SI	47851	20479	18212	5216	3944	19844	18447	5649	3911
Validation SI	9972	4197	3698	1212	865	4047	3806	1254	865
Test SI	10845	4850	4476	907	612	4631	4559	1043	612
Train GAB	60467	25635	20875	8748	5209	24831	20720	8596	6320
Validation GAB	12414	5380	4205	1750	1079	5224	4289	1619	1282
Test GAB	13588	5823	5082	1844	839	5554	5045	1829	1160

Berdasarkan Tabel 4.12, penelitian ini menggunakan metode *forward fill* dan *backward fill* untuk menangani *missing value*. Metode tersebut dipilih karena mampu mempertahankan urutan temporal setiap lintasan siklon tanpa membentuk nilai baru melalui proses interpolasi. Dataset hasil imputasi selanjutnya digunakan pada tahap normalisasi dan pembentukan fitur.

4.1.2.4 Rekayasa Fitur

Setelah proses penanganan *missing value* selesai dilakukan, tahap berikutnya adalah rekayasa fitur (*feature engineering*). Proses ini bertujuan untuk membentuk variabel yang dapat merepresentasikan karakteristik pergerakan siklon tropis secara lebih lengkap. Selain menggunakan variabel asli yang terdapat pada dataset *International Best Track Archive for Climate Stewardship (IBTrACS)*, penelitian ini juga menghasilkan beberapa fitur turunan yang dihitung berdasarkan hubungan antarobservasi pada setiap lintasan siklon. Seluruh variabel yang

digunakan setelah proses rekayasa fitur disajikan pada Tabel 4.13.

Tabel 4.13 Struktur Variabel Dataset Setelah Rekayasa Fitur

No	Nama Variabel	Tipe Data	Keterangan
1	<i>SID</i>	Object	Identitas unik setiap siklon tropis.
2	<i>ISO_TIME</i>	<i>Datetime</i>	Waktu pengamatan siklon dengan interval tiga jam.
3	<i>LAT</i>	Float	Posisi lintang pusat siklon tropis.
4	<i>LON</i>	Float	Posisi bujur pusat siklon tropis.
5	<i>WMO_WIND</i>	Float	Kecepatan angin maksimum berkelanjutan.
6	<i>WMO_PRES</i>	Float	Tekanan udara minimum pada pusat siklon.
7	<i>wind_was_missing</i>	Integer	Penanda observasi yang mengalami imputasi pada variabel <i>WMO_WIND</i> .
8	<i>pres_was_missing</i>	Integer	Penanda observasi yang mengalami imputasi pada variabel <i>WMO_PRES</i> .
9	<i>wind_imputation</i>	Object	Informasi metode imputasi yang digunakan pada <i>WMO_WIND</i> .
10	<i>pres_imputation</i>	Object	Informasi metode imputasi yang digunakan pada <i>WMO_PRES</i> .
11	<i>delta_lat</i>	Float	Perubahan nilai lintang terhadap observasi sebelumnya.
12	<i>delta_lon</i>	Float	Perubahan nilai bujur terhadap observasi sebelumnya.
13	<i>speed_kmh</i>	Float	Kecepatan perpindahan siklon berdasarkan jarak dan interval waktu pengamatan.
14	<i>bearing_rate</i>	Float	Arah perpindahan siklon antarobservasi.
15	<i>acceleration</i>	Float	Perubahan kecepatan perpindahan antarobservasi.
16	<i>sin_month</i>	Float	Representasi siklus bulan menggunakan transformasi sinus.
17	<i>cos_month</i>	Float	Representasi siklus bulan menggunakan transformasi cosinus.

Berdasarkan Tabel 4.13, proses rekayasa fitur menghasilkan 17 variabel yang terdiri atas variabel identitas, waktu pengamatan, posisi geografis, parameter meteorologi, informasi hasil imputasi, serta fitur turunan yang menggambarkan karakteristik pergerakan siklon. Fitur turunan seperti *delta_lat*, *delta_lon*,

speed_kmh, *bearing_rate*, *acceleration*, *sin_month*, dan *cos_month* dibentuk untuk memberikan informasi mengenai perubahan posisi, kecepatan, arah pergerakan, dan pola musiman yang tidak diperoleh secara langsung dari dataset asli.

Pada tahap selanjutnya, tidak seluruh variabel digunakan sebagai masukan model. Variabel *SID*, *ISO_TIME*, *wind_was_missing*, *pres_was_missing*, *wind_imputation*, dan *pres_imputation* berfungsi sebagai informasi pendukung selama proses pengolahan data. Sementara itu, variabel *LAT*, *LON*, *WMO_WIND*, *WMO_PRES*, *delta_lat*, *delta_lon*, *speed_kmh*, *bearing_rate*, *acceleration*, *sin_month*, dan *cos_month* digunakan sebagai masukan pada proses standardisasi data, pembentukan *sliding window*, dan pelatihan model *Long Short-Term Memory (LSTM)*.

4.1.2.5 Standardisasi Data

Setelah proses rekayasa fitur selesai dilakukan, tahap berikutnya adalah standardisasi data. Tahap ini bertujuan untuk menyamakan skala seluruh variabel numerik yang digunakan sebagai masukan model sehingga perbedaan rentang nilai antarvariabel tidak memengaruhi proses pembelajaran. Standardisasi menjadi tahap yang penting karena variabel pada penelitian ini memiliki karakteristik dan satuan yang berbeda, mulai dari kecepatan angin, tekanan udara, perubahan koordinat, hingga fitur turunan yang dihasilkan pada proses rekayasa fitur.

Pada penelitian ini, standardisasi dilakukan menggunakan metode *StandardScaler*. Parameter standardisasi dihitung hanya dari data latih (*training set*), kemudian diterapkan pada data validasi (*validation set*) dan data uji (*testing set*) menggunakan parameter yang sama. Pendekatan tersebut diterapkan untuk menghindari *data leakage* sehingga informasi dari data validasi maupun data uji

tidak memengaruhi proses pembentukan model.

Tabel 4.14 Hasil Standardisasi Data Menggunakan *Standard Scaler*

Variable	Mean	Std
WMO_WIND	1.28E-16	1.000042
WMO_PRES	3.04E-15	1.000042
delta_lat	-1.01E-17	1.000042
delta_lon	-2.85E-17	1.000042
speed_kmh	8.07E-17	1.000042
bearing_rate	1.33E-16	1.000042
acceleration	1.51E-17	1.000042
sin_month	-5.70E-17	1.000042
cos_month	4.86E-17	1.000042

Variabel yang melalui proses standardisasi meliputi *WMO_WIND*, *WMO_PRES*, *delta_lat*, *delta_lon*, *speed_kmh*, *bearing_rate*, *acceleration*, *sin_month*, dan *cos_month*. Sementara itu, variabel *LAT* dan *LON* digunakan sebagai variabel target sehingga proses standardisasinya dilakukan menggunakan *scaler* yang terpisah agar hasil prediksi dapat dikembalikan ke satuan koordinat geografis pada tahap evaluasi maupun implementasi aplikasi.

4.1.2.6 Pembentukan *Sliding Window*

Setelah proses standardisasi selesai, data disusun menjadi data deret waktu (*time series*) menggunakan metode *sliding window*. Tahap ini bertujuan membentuk urutan observasi sebagai data masukan (*input*) bagi model *Long Short-Term Memory* (LSTM). Pada penelitian ini digunakan empat variasi *window*, yaitu 8, 16, 24, dan 32 *timestep* dengan *forecast horizon* satu langkah waktu.

Tabel 4.15 Pembentukan *Sliding Window*

N o	Skenario	Window	Train	Validation	Test
0	NI	8	(9525, 8, 11)	(1785, 8, 11)	(2079, 8, 11)
1	NI	16	(7413, 16, 11)	(1330, 16, 11)	(1644, 16, 11)
2	NI	24	(5644, 24, 11)	(977, 24, 11)	(1268, 24, 11)
3	NI	32	(4214, 32, 11)	(709, 32, 11)	(951, 32, 11)
4	SI	8	(41540, 8, 11)	(8633, 8, 11)	(9485, 8, 11)
5	SI	16	(36596, 16, 11)	(7596, 16, 11)	(8405, 16, 11)
6	SI	24	(31786, 24, 11)	(6587, 24, 11)	(7369, 24, 11)
7	SI	32	(27168, 32, 11)	(5617, 32, 11)	(6375, 32, 11)
8	GAB	8	(51065, 8, 11)	(10418, 8, 11)	(11564, 8, 11)
9	GAB	16	(44009, 16, 11)	(8926, 16, 11)	(10049, 16, 11)
10	GAB	24	(37430, 24, 11)	(7564, 24, 11)	(8637, 24, 11)
11	GAB	32	(31382, 32, 11)	(6326, 32, 11)	(7326, 32, 11)

Berdasarkan Tabel 4.15, proses *sliding window* berhasil menghasilkan data masukan dalam bentuk tensor tiga dimensi dengan format (*jumlah sampel, timestep, jumlah fitur*). Seluruh skenario menggunakan 11 fitur masukan, sehingga perbedaan dimensi hanya terletak pada jumlah sampel dan panjang *timestep* yang digunakan.

Jumlah sampel pada setiap subset juga mengalami penurunan seiring bertambahnya panjang *window*. Pada skenario *North Indian Ocean* (NI), data latihan berkurang dari 9.525 sampel pada *window* 8 menjadi 4.214 sampel pada *window* 32. Pola yang sama juga terlihat pada skenario *South Indian Ocean* (SI) dan Gabungan (GAB). Kondisi ini terjadi karena setiap sampel memerlukan lebih banyak observasi historis untuk membentuk satu urutan data ketika panjang *window* semakin besar.

Data hasil pembentukan *sliding window* selanjutnya digunakan sebagai masukan pada proses pelatihan model *Long Short-Term Memory* (LSTM) untuk seluruh skenario dan variasi *window* yang telah ditentukan.

4.1.2.7 Proses Model Long Short-Term Memory (LSTM)

Dataset yang telah dibentuk menggunakan metode *sliding window* selanjutnya digunakan sebagai masukan pada proses pelatihan model *Long Short-Term Memory (LSTM)*. Model ini dipilih karena mampu mempelajari hubungan temporal pada data deret waktu melalui mekanisme memori (*memory cell*), sehingga sesuai untuk memodelkan pola pergerakan siklon tropis yang dipengaruhi oleh kondisi pada waktu-waktu sebelumnya. Penelitian ini menggunakan satu arsitektur model yang sama pada seluruh skenario eksperimen. Perbedaan antar model hanya terletak pada dataset yang digunakan (*North Indian Ocean*, *South Indian Ocean*, dan dataset gabungan) serta variasi *window size* sebesar 8, 16, 24, dan 32 *timestep*.

Tabel 4.16 Konfigurasi Arsitektur Model LSTM

Parameter	Nilai
Jenis model	<i>Long Short-Term Memory (LSTM)</i>
Jumlah lapisan LSTM	1
Unit LSTM	64
<i>Dense layer</i>	32 neuron
Fungsi aktivasi	<i>ReLU</i>
<i>Dropout</i>	0,2
Jumlah fitur masukan	11
Target keluaran	2 (<i>LAT</i> dan <i>LON</i>)

Arsitektur model terdiri atas satu lapisan *Long Short-Term Memory (LSTM)* dengan 64 unit sebagai lapisan utama untuk mempelajari pola temporal. Keluaran dari lapisan tersebut kemudian diteruskan ke lapisan *Dense* yang terdiri atas 32 neuron dengan fungsi aktivasi *Rectified Linear Unit (ReLU)*. Untuk mengurangi risiko *overfitting*, ditambahkan lapisan *Dropout* dengan nilai 0,2 sebelum menghasilkan keluaran akhir berupa prediksi koordinat lintang (*latitude*)

dan bujur (*longitude*).

Arsitektur model yang digunakan pada penelitian ini menghasilkan data masukan berbentuk tensor tiga dimensi dengan ukuran (*jumlah sampel, timestep, 11 fitur*). Selanjutnya, lapisan *LSTM* mengekstraksi hubungan temporal dari setiap urutan data, kemudian hasil pembelajaran diteruskan ke lapisan *Dense* sebelum menghasilkan prediksi koordinat lintang dan bujur pada lapisan keluaran.

Tabel 4.17 Konfigurasi Pelatihan Model

Parameter	Nilai
<i>Optimizer</i>	Adam
<i>Learning Rate</i>	0,001
Fungsi <i>Loss</i>	<i>Mean Squared Error (MSE)</i>
Metrik pelatihan	<i>Mean Absolute Error (MAE)</i>
<i>Epoch</i> maksimum	100
<i>Batch Size</i>	32
<i>Shuffle</i>	Tidak (<i>False</i>)
<i>Early Stopping</i>	Monitor = <i>val_loss</i> , <i>patience</i> = 10
<i>Restore Best Weights</i>	Ya
<i>ReduceLROnPlateau</i>	Monitor = <i>val_loss</i> , faktor = 0,5, <i>patience</i> = 5, <i>minimum learning rate</i> = 1×10^{-6}
<i>ModelCheckpoint</i>	Menyimpan model terbaik berdasarkan <i>validation loss</i>

Berdasarkan Tabel 4.17 Selama proses pelatihan, digunakan beberapa mekanisme *callback* untuk meningkatkan stabilitas pembelajaran model. *Early Stopping* digunakan untuk menghentikan proses pelatihan apabila nilai *validation loss* tidak mengalami perbaikan dalam sepuluh *epoch* berturut-turut, sedangkan *ReduceLROnPlateau* secara otomatis menurunkan *learning rate* ketika proses pembelajaran mulai mengalami stagnasi. Selain itu, *ModelCheckpoint* digunakan

untuk menyimpan model dengan performa terbaik sehingga model yang digunakan pada tahap evaluasi merupakan model dengan nilai *validation loss* paling optimal.

Dengan konfigurasi tersebut, penelitian ini menghasilkan 12 model yang berasal dari kombinasi tiga skenario dataset (*North Indian Ocean*, *South Indian Ocean*, dan gabungan) serta empat variasi *window size* (8, 16, 24, dan 32). Seluruh model kemudian dievaluasi menggunakan metrik yang telah ditentukan untuk memperoleh konfigurasi terbaik dalam memprediksi lintasan siklon tropis.

4.1.2.8 Evaluasi Model

Setelah proses pembentukan dan pelatihan model *Long Short-Term Memory* (LSTM) selesai dilakukan, tahap berikutnya adalah mengevaluasi kinerja model untuk mengetahui kemampuan model dalam memprediksi lintasan siklon tropis berdasarkan data historis IBTrACS. Evaluasi dilakukan menggunakan beberapa pendekatan yang bertujuan untuk mengukur tingkat akurasi prediksi, menganalisis pengaruh variasi *timesteps*, serta menentukan model yang paling sesuai untuk diimplementasikan pada aplikasi.

Tahap evaluasi diawali dengan pengujian terhadap *pipeline* pemodelan untuk memastikan setiap proses berjalan sesuai dengan rancangan. Selanjutnya, kinerja model dianalisis menggunakan metrik *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), *Mean Haversine Distance*, dan koefisien determinasi (R^2). Selain itu, dilakukan analisis terhadap pengaruh variasi ukuran *timesteps* pada setiap skenario pemodelan, kemudian dilanjutkan dengan pemilihan model terbaik berdasarkan hasil evaluasi yang diperoleh. Pada bagian akhir, ditampilkan hasil prediksi model *Long Short-Term Memory* (LSTM) sebagai bentuk visualisasi kemampuan model dalam memprediksi lintasan siklon tropis.

4.1.2.8.1 Pipeline Pemodelan

Pengujian pipeline pemodelan dilakukan untuk memastikan bahwa proses pembentukan model dapat dijalankan sesuai dengan tahapan yang telah dirancang. Pengujian meliputi pemuatan dataset, pembentukan data sekuens menggunakan teknik *sliding window*, penyusunan arsitektur *Long Short-Term Memory* (LSTM), serta pelaksanaan proses pelatihan model. Tahapan ini bertujuan untuk memastikan bahwa setiap skenario pemodelan dapat dieksekusi tanpa kesalahan sebelum dilakukan proses evaluasi.

```

=====
SCENARIO : GAB
WINDOW   : 8
=====

Dataset
Train : (51065, 8, 11)
Valid : (10418, 8, 11)
Test  : (11564, 8, 11)

Model
Model: "sequential_8"

```

Layer (type)	Output Shape	Param #
lstm (LSTM)	(None, 64)	19,456
dense_hidden (Dense)	(None, 32)	2,080
output (Dense)	(None, 2)	66

```

Total params: 21,602 (84.38 KB)
Trainable params: 21,602 (84.38 KB)
Non-trainable params: 0 (0.00 B)

Training Dimulai...
Epoch 1/100
1596/1596 — 0s 8ms/step - loss: 1013.1771 - mae: 17.1566
Epoch 1: val_loss improved from None to 44.19567, saving model to /content/drive/MyDrive/Skripsi/models/gab_window8.keras

```

Gambar 4.5 Proses Pelatihan Pemodelan

Proses pelatihan, sistem menampilkan informasi mengenai skenario yang digunakan, dimensi data latih, data validasi, dan data uji, serta arsitektur model yang dibangun. Informasi tersebut mencakup jumlah lapisan (*layer*), bentuk keluaran (*output shape*), jumlah parameter yang dilatih, serta perkembangan proses pelatihan pada setiap *epoch*. Tampilan hasil eksekusi salah satu skenario pemodelan.

proses pelatihan model pada skenario Gabungan (GAB) dengan *sliding window* 8 timesteps berhasil dijalankan tanpa kesalahan. Sistem menampilkan

konfigurasi dataset yang digunakan, arsitektur model LSTM, jumlah parameter yang dilatih, serta proses pelatihan yang berlangsung hingga model mulai menghasilkan nilai fungsi kerugian (*loss*) dan menyimpan model terbaik secara otomatis. Hasil tersebut menunjukkan bahwa pipeline pemodelan telah berjalan sesuai dengan rancangan dan siap digunakan pada tahap evaluasi performa model.

4.1.2.8.2 Metrik Evaluasi MAE, RMSE & *Haversine*

Pengujian performa model dilakukan untuk mengetahui tingkat akurasi model *Long Short-Term Memory* (LSTM) dalam memprediksi koordinat lintasan siklon tropis pada data uji. Pengujian dilakukan terhadap seluruh skenario penelitian yang terdiri atas tiga kelompok dataset, yaitu *North Indian Ocean* (NI), *South Indian Ocean* (SI), dan Gabungan (GAB), dengan variasi ukuran *sliding window* 8, 16, 24, dan 32 *timesteps*. Seluruh model dievaluasi menggunakan data uji yang sama dengan proses pelatihan sehingga hasil yang diperoleh dapat dibandingkan secara objektif.

Evaluasi dilakukan menggunakan tiga metrik, yaitu *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *Haversine Distance*. MAE digunakan untuk mengukur rata-rata kesalahan prediksi koordinat, RMSE digunakan untuk mengetahui besarnya kesalahan dengan memberikan penalti yang lebih besar terhadap nilai yang menyimpang, sedangkan *Haversine Distance* digunakan untuk menghitung jarak geografis antara koordinat hasil prediksi dan koordinat aktual dalam satuan kilometer. Secara umum, semakin kecil nilai MAE, RMSE, dan *Haversine Distance*, maka semakin tinggi tingkat akurasi model karena hasil prediksi semakin mendekati data aktual.

	Scenario	Window	Samples	MAE LAT	MAE LON	RMSE LAT	RMSE LON	MAE	RMSE	Mean Haversine (km)	Min Haversine (km)	Max Haversine (km)
0	GAB	8	11564	0.082099	0.103717	0.110720	0.144091	0.092908	0.127405	15.885000	0.085	163.556000
1	GAB	16	10049	0.084950	0.094648	0.122012	0.141861	0.089799	0.131936	15.255000	0.061	381.953003
2	GAB	24	8637	0.186403	0.155292	0.249917	0.224556	0.170847	0.237237	28.885000	0.179	515.791992
3	GAB	32	7326	0.089925	0.107259	0.141714	0.184674	0.098592	0.163194	16.704000	0.182	563.067993
4	NI	8	2079	0.123753	0.137177	0.188574	0.199689	0.130465	0.194131	22.450001	0.064	239.149994
5	NI	16	1644	0.108964	0.128730	0.151187	0.178852	0.118847	0.165020	20.399000	0.300	193.992004
6	NI	24	1268	0.151913	0.196916	0.207837	0.265791	0.174415	0.236814	29.732000	1.056	210.628006
7	NI	32	951	0.119177	0.129077	0.157320	0.182383	0.124127	0.169852	21.011999	0.907	157.460999
8	SI	8	9485	0.077210	0.089737	0.102988	0.131429	0.083474	0.117209	14.235000	0.133	265.431000
9	SI	16	8405	0.077613	0.091025	0.106318	0.137494	0.084319	0.121906	14.364000	0.094	311.846985
10	SI	24	7369	0.100437	0.097856	0.134079	0.143238	0.099146	0.138659	16.796000	0.151	280.127014
11	SI	32	6375	0.262773	0.237067	0.330792	0.337714	0.249920	0.334253	42.910000	0.282	543.349976

Gambar 4.6 Pengujian Performa Seluruh Skenario

Berdasarkan Gambar 4.6, seluruh model berhasil menghasilkan prediksi koordinat lintasan siklon tropis dengan tingkat kesalahan yang berbeda pada setiap skenario pengujian. Nilai MAE berada pada rentang 0,083474–0,249920, sedangkan RMSE berada pada rentang 0,117209–0,334253. Sementara itu, nilai Mean Haversine Distance berkisar antara 14,235 km hingga 42,910 km, dengan Maximum Haversine Distance sebesar 157,461 km hingga 563,068 km.

Perbedaan nilai pada setiap skenario menunjukkan bahwa kombinasi dataset dan ukuran *sliding window* memberikan hasil prediksi yang berbeda. Hasil pengujian ini menjadi dasar untuk menganalisis pengaruh variasi dataset dan ukuran *timesteps* terhadap performa model, yang akan dibahas pada subbab berikutnya.

4.1.2.8.3 Evaluasi Koefisien Determinasi (R^2)

Koefisien determinasi (*Coefficient of Determination* atau R^2) digunakan untuk mengukur kemampuan model dalam menjelaskan hubungan antara nilai prediksi dan nilai aktual. Semakin mendekati nilai 1, semakin baik kemampuan model dalam merepresentasikan pola data sehingga hasil prediksi yang dihasilkan semakin mendekati kondisi sebenarnya. Pada penelitian ini, nilai R^2 dihitung secara terpisah untuk koordinat lintang (*Latitude*) dan bujur (*Longitude*), kemudian dirata-

ratakan untuk memberikan gambaran performa model secara keseluruhan.

Tabel 4.18 Uji Akurasi Model (R^2)

No	Scenario	Window	Samples	R^2 Latitude	R^2 Longitude	R^2 Mean
0	GAB	8	11564	0.999934	0.999971	0.99995
1	GAB	16	10049	0.999917	0.999972	0.99994
2	GAB	24	8637	0.999637	0.999929	0.99978
3	GAB	32	7326	0.999877	0.999952	0.99992
4	NI	8	2079	0.99869	0.999885	0.99929
5	NI	16	1644	0.999119	0.999905	0.99951
6	NI	24	1268	0.998282	0.999784	0.99903
7	NI	32	951	0.998978	0.999896	0.99944
8	SI	8	9485	0.999688	0.999978	0.99983
9	SI	16	8405	0.999668	0.999976	0.99982
10	SI	24	7369	0.999477	0.999973	0.99973
11	SI	32	6375	0.996848	0.999852	0.99835

Berdasarkan Tabel 4.18, Seluruh model memperoleh nilai koefisien determinasi yang sangat tinggi, dengan nilai R^2 Mean berada pada rentang 0,998350 hingga 0,999833. Hasil tersebut menunjukkan bahwa model *Long Short-Term Memory* (LSTM) mampu mempelajari hubungan antara data masukan dan koordinat target menunjukkan bahwa variasi koordinat aktual dapat dijelaskan oleh model dengan tingkat kecocokan yang sangat tinggi.


Meskipun demikian, nilai R^2 yang tinggi tidak selalu menunjukkan bahwa model memiliki tingkat kesalahan prediksi geografis yang paling rendah. Oleh karena itu, penilaian performa model pada penelitian ini tidak hanya didasarkan pada nilai koefisien determinasi, tetapi juga mempertimbangkan nilai MAE, RMSE, dan *Haversine Distance* yang telah dibahas pada subbab sebelumnya. Pendekatan tersebut memberikan evaluasi yang lebih komprehensif terhadap kemampuan model dalam memprediksi lintasan siklon tropis.

Dengan demikian, hasil pengujian pada subbab ini melengkapi evaluasi performa model yang telah dilakukan menggunakan metrik kesalahan. Kombinasi kedua jenis evaluasi tersebut menjadi dasar untuk menganalisis perbedaan performa setiap skenario serta menentukan model yang paling sesuai untuk diimplementasikan pada aplikasi, yang akan dibahas pada subbab berikutnya.

4.1.2.8.4 Pengaruh Variasi Timesteps

Selain dipengaruhi oleh karakteristik dataset, performa model *Long Short-Term Memory* (LSTM) juga dipengaruhi oleh panjang urutan data (*timesteps*) yang digunakan sebagai masukan selama proses pelatihan. Pada penelitian ini, pengaruh tersebut dianalisis menggunakan empat variasi *sliding window*, yaitu 8, 16, 24, dan 32 *timesteps*. Perbandingan performa setiap model berdasarkan nilai *Mean Haversine Distance*.

Variasi ukuran *timesteps* memberikan pengaruh terhadap performa model pada setiap skenario penelitian. Pada dataset *North Indian Ocean* (NI), nilai *Mean Haversine Distance* terendah diperoleh pada *window* 16 sebesar 20,39 km, sedangkan nilai tertinggi terdapat pada *window* 24 sebesar 29,73 km. Pada dataset *South Indian Ocean* (SI), model dengan *window* 8 dan 16 menghasilkan nilai kesalahan yang relatif rendah, namun meningkat pada *window* 24 dan mengalami kenaikan yang signifikan pada *window* 32 hingga mencapai 42,91 km. Sementara itu, pada dataset Gabungan (GAB), model dengan *window* 8 dan 16 menunjukkan performa yang relatif stabil dibandingkan variasi *window*. disajikan pada Gambar 4.7.



Gambar 4.7 Perbandingan *Mean Haversine Distance* Seluruh Model

Hasil tersebut menunjukkan bahwa penambahan jumlah *timesteps* tidak selalu meningkatkan kemampuan model dalam memprediksi lintasan siklon tropis. Pada penelitian ini, penggunaan *window* 8 dan 16 secara umum menghasilkan nilai kesalahan yang lebih rendah dibandingkan *window* 24 dan 32. Temuan ini mengindikasikan bahwa panjang urutan data masukan memengaruhi proses pembelajaran model LSTM, sehingga pemilihan ukuran *timesteps* menjadi salah satu faktor penting dalam memperoleh performa prediksi yang optimal.

4.1.2.8.5 Evaluasi Model Gabungan

Hasil pengujian menunjukkan bahwa penggunaan dataset dari *basin* yang berbeda menghasilkan performa model yang berbeda pula. Perbedaan tersebut terlihat dari nilai *Mean Haversine Distance*, MAE, dan RMSE yang diperoleh pada setiap skenario. Secara umum, model yang dibangun menggunakan dataset *South Indian Ocean* (SI) menghasilkan nilai kesalahan rata-rata yang lebih rendah dibandingkan *North Indian Ocean* (NI), sedangkan model Gabungan (GAB) menunjukkan performa yang lebih stabil pada sebagian besar variasi *timesteps*. Hal ini menunjukkan bahwa karakteristik data pada masing-masing *basin* memengaruhi kemampuan model dalam mempelajari pola pergerakan siklon tropis. Untuk

menentukan model yang akan diimplementasikan pada aplikasi, dilakukan pemeringkatan terhadap seluruh model pada skenario Gabungan (GAB) berdasarkan hasil evaluasi. Hasil pemeringkatan tersebut disajikan pada Tabel 4.8.

	Rank GAB	Rank	Scenario	Window	Samples	MAE LAT	MAE LON	RMSE LAT	RMSE LON	MAE	RMSE	Mean Haversine (km)	Min Haversine (km)	Max Haversine (km)
0	1	3	GAB	16	10049	0.084950	0.094648	0.122012	0.141861	0.089799	0.131936	15.255	0.061	381.953003
1	2	4	GAB	8	11564	0.082099	0.103717	0.110720	0.144091	0.092908	0.127405	15.885	0.085	163.556000
2	3	5	GAB	32	7326	0.089925	0.107259	0.141714	0.184674	0.098592	0.163194	16.704	0.182	563.067993
3	4	10	GAB	24	8637	0.186403	0.155292	0.249917	0.224556	0.170847	0.237237	28.885	0.179	515.791992

Gambar 4.8 Kinerja Model Gabungan (GAB)

Berdasarkan Tabel 4.8, model GAB-16 memperoleh nilai *Mean Haversine Distance* terendah, yaitu 15,255 km, sehingga menjadi model terbaik apabila penilaian hanya didasarkan pada rata-rata kesalahan prediksi. Namun, model GAB-8 menghasilkan nilai RMSE yang lebih rendah serta memiliki *Maximum Haversine Distance* sebesar 163,556 km, jauh lebih kecil dibandingkan GAB-16 yang mencapai 381,953 km. Hal tersebut menunjukkan bahwa model GAB-8 memiliki penyimpangan prediksi maksimum yang lebih kecil sehingga menghasilkan performa yang lebih stabil pada berbagai lintasan siklon tropis.

Berdasarkan hasil tersebut, model GAB-8 dipilih sebagai model yang diimplementasikan pada aplikasi Streamlit. Meskipun memiliki nilai *Mean Haversine Distance* sedikit lebih tinggi dibandingkan GAB-16, model ini menunjukkan keseimbangan yang lebih baik antara tingkat akurasi dan kestabilan prediksi. Selain didukung oleh nilai RMSE yang lebih rendah, model GAB-8 juga menghasilkan nilai *Maximum Haversine Distance* terkecil di antara seluruh model GAB, sehingga dinilai lebih mampu memberikan prediksi yang konsisten pada berbagai kondisi lintasan siklon tropis.

4.1.3 Analisis Sistem

Analisa sistem dilakukan untuk memperoleh gambaran mengenai kebutuhan sistem yang akan diimplementasikan berdasarkan hasil pengolahan data dan model prediksi yang telah dibangun pada penelitian ini. Analisis ini bertujuan untuk memastikan bahwa seluruh komponen sistem mampu mendukung proses prediksi lintasan siklon tropis secara terintegrasi, mulai dari penyediaan data, proses prediksi, hingga penyajian hasil kepada pengguna melalui aplikasi berbasis *web*.

4.1.3.1 Analisis Kebutuhan Sistem

Berdasarkan hasil analisis, sistem yang dikembangkan terdiri atas empat komponen utama, yaitu sumber data siklon tropis, modul prapemrosesan, model *Long Short-Term Memory (LSTM)*, dan aplikasi berbasis *Streamlit*. Masing-masing komponen memiliki fungsi yang saling berkaitan sehingga membentuk satu alur kerja yang utuh dalam proses prediksi lintasan siklon tropis.

Data siklon tropis berfungsi sebagai sumber informasi yang digunakan oleh model. Modul prapemrosesan bertugas menyiapkan data melalui proses penanganan *missing value*, rekayasa fitur, standardisasi, serta pembentukan data deret waktu menggunakan metode *sliding window*. Data yang telah diproses kemudian digunakan oleh model *Long Short-Term Memory (LSTM)* untuk menghasilkan prediksi koordinat lintang dan bujur. Hasil prediksi selanjutnya ditampilkan melalui aplikasi berbasis *Streamlit* dalam bentuk visualisasi lintasan pada peta interaktif, informasi data observasi, serta hasil evaluasi model.

4.1.3.2 Lingkungan Pengembangan

Pengembangan sistem dilakukan menggunakan kombinasi perangkat keras dan perangkat lunak yang disesuaikan dengan kebutuhan pemodelan deep learning.

Proses penulisan program, pengolahan data awal, serta pengembangan antarmuka dilakukan pada komputer lokal, sedangkan pelatihan model dijalankan menggunakan layanan komputasi awan Google Colaboratory yang menyediakan akselerasi GPU.

Pemanfaatan GPU diperlukan karena penelitian ini melibatkan delapan skenario eksperimen dengan tiga kali pengulangan pada setiap skenario. Beban komputasi tersebut menyebabkan waktu pelatihan meningkat secara signifikan apabila hanya menggunakan prosesor utama (CPU). Oleh karena itu, proses pelatihan dilakukan menggunakan GPU agar waktu komputasi menjadi lebih efisien. Spesifikasi perangkat keras yang digunakan disajikan pada Tabel 4.21.

Tabel 4.19 Perangkat Keras

Jenis Perangkat	Spesifikasi	Kegunaan
Laptop pengembangan	Lenovo IdeaPad Slim 3, AMD Ryzen 5 7520U (4,3 GHz), RAM 8 GB, SSD 512 GB	Penulisan kode, pengolahan data awal, dan pengembangan dasbor Streamlit
Google Colaboratory	GPU NVIDIA T4	Pelatihan model LSTM untuk seluruh skenario eksperimen

Selain perangkat keras, penelitian ini juga memanfaatkan berbagai perangkat lunak pendukung yang meliputi sistem operasi, bahasa pemrograman, pustaka komputasi ilmiah, framework *deep learning*, perangkat visualisasi, serta platform pengembangan antarmuka. Perangkat lunak tersebut digunakan pada setiap tahapan penelitian, mulai dari pengolahan data, pembangunan dan pelatihan model LSTM, evaluasi hasil prediksi, hingga implementasi dashboard interaktif. Seluruh perangkat lunak yang digunakan bersifat *open source* sehingga proses penelitian dapat direproduksi oleh peneliti lain tanpa memerlukan lisensi tambahan.

Rincian perangkat lunak yang digunakan dalam penelitian ini disajikan pada Tabel 4.20.

Tabel 4.20 Perangkat Lunak

Perangkat Lunak	Versi/Jenis	Kegunaan
Windows 11	Sistem operasi	Pengembangan aplikasi pada komputer lokal
Linux (Google Colaboratory)	Sistem operasi	Pelatihan model di lingkungan komputasi awan
Python 3.11	Bahasa pemrograman	Implementasi seluruh proses penelitian
Pandas dan NumPy	Pustaka	Manipulasi dan pengolahan data
Scikit-learn	Pustaka	Normalisasi data dan evaluasi model
TensorFlow (Keras)	Versi 2.20	Membangun dan melatih model LSTM
Folium dan Matplotlib	Pustaka	Visualisasi lintasan siklon
Streamlit	Framework	Pengembangan dasbor interaktif
Format Keras (.keras)	Format penyimpanan	Menyimpan model

4.1.3.3 Strategi Pemecahan Masalah

Strategi pemecahan masalah disusun untuk mengatasi berbagai kendala dalam prediksi lintasan siklon tropis, mulai dari kualitas data, karakteristik pergerakan siklon, hingga pemilihan model yang akan diimplementasikan pada aplikasi. Pendekatan yang digunakan tidak hanya berfokus pada pembangunan model, tetapi juga memastikan bahwa setiap tahapan pengolahan data dilakukan secara konsisten sehingga menghasilkan model yang andal.

Permasalahan pertama berkaitan dengan keberadaan *missing value* pada beberapa atribut meteorologi. Untuk mengatasinya, dilakukan proses imputasi

setelah pembagian dataset sehingga data latih, data validasi, dan data uji diproses secara terpisah. Pendekatan ini diterapkan untuk mencegah *data leakage* dan menjaga objektivitas proses evaluasi.

Permasalahan berikutnya adalah karakteristik pergerakan siklon yang dipengaruhi oleh hubungan spasial dan temporal. Oleh karena itu, penelitian ini membentuk fitur turunan yang merepresentasikan perubahan posisi, kecepatan, arah pergerakan, percepatan, serta pola musiman. Selanjutnya, seluruh fitur numerik distandardisasi agar memiliki skala yang seragam sebelum dibentuk menjadi data deret waktu menggunakan metode *sliding window*.

Untuk memperoleh model dengan performa terbaik, penelitian ini menguji tiga skenario dataset, yaitu *North Indian Ocean* (NI), *South Indian Ocean* (SI), dan Gabungan (GAB), dengan variasi *sliding window* 8, 16, 24, dan 32 *timestep*. Setiap model dievaluasi menggunakan *Root Mean Squared Error* (RMSE), *Mean Absolute Error* (MAE), *Coefficient of Determination* (R^2), dan *Haversine Distance Error* sehingga dapat dibandingkan secara objektif.

Model dengan hasil evaluasi terbaik kemudian diimplementasikan ke dalam aplikasi berbasis Streamlit. Integrasi tersebut memungkinkan pengguna melakukan prediksi lintasan siklon, menampilkan visualisasi pada peta interaktif, mengakses data observasi, serta melihat informasi evaluasi model.

4.2 Perancangan

Tahap perancangan merupakan jembatan antara hasil analisis data dan implementasi teknis sistem ke dalam perangkat lunak. Perancangan ini dibagi menjadi dua bagian utama, yaitu perancangan model dan perancangan aplikasi,

Seluruh komponen logika, aliran data, dan interaksi visual dirancang secara sistematis guna memastikan sistem prediksi mampu bekerja secara optimal.

4.2.1 Perancangan Model LSTM

Perancangan model *Long Short-Term Memory (LSTM)* dilakukan untuk menentukan arsitektur jaringan, konfigurasi pelatihan, serta mekanisme pembelajaran yang digunakan dalam memprediksi lintasan siklon tropis. Model dirancang berdasarkan karakteristik data hasil prapemrosesan sehingga mampu mempelajari hubungan spasial dan temporal dari riwayat pergerakan siklon.


Data masukan berupa urutan observasi hasil pembentukan *sliding window* yang terdiri atas sebelas fitur, sedangkan keluaran model berupa prediksi koordinat *latitude* dan *longitude* pada waktu berikutnya. Proses pelatihan dilakukan pada tiga skenario dataset, yaitu *North Indian Ocean (NI)*, *South Indian Ocean (SI)*, dan dataset gabungan (GAB). Setiap skenario diuji menggunakan empat variasi *window size*, yaitu 8, 16, 24, dan 32 *timestep*, sehingga diperoleh beberapa konfigurasi model yang dapat dibandingkan berdasarkan hasil evaluasi.

Perancangan model mencakup penyusunan arsitektur jaringan, konfigurasi parameter pelatihan, mekanisme pembelajaran, serta proses pemilihan model terbaik sebelum diimplementasikan ke dalam aplikasi. Pembahasan mekanisme tersebut disajikan pada subbab berikut.

4.2.1.1 Diagram Pelatihan Model

Pelatihan model dilakukan menggunakan data deret waktu yang telah dibentuk melalui metode *sliding window*. Setiap skenario dataset diproses secara terpisah agar model dapat mempelajari karakteristik pergerakan siklon pada

masing-masing wilayah penelitian maupun pada dataset gabungan. Selama proses pelatihan, data dibagi menjadi *training set*, *validation set*, dan *testing set*. Data latih digunakan untuk memperbarui bobot jaringan, data validasi digunakan untuk memantau kemampuan generalisasi model selama proses pembelajaran, sedangkan data uji digunakan untuk mengevaluasi performa model setelah pelatihan selesai.



Gambar 4.9 Diagram Pelatihan Model *Long Short-Term Memory* (LSTM)

Berdasarkan Gambar 4.9, proses pelatihan diawali dengan pemilihan dataset sesuai skenario penelitian dan variasi *window size* yang digunakan. Model kemudian dilatih menggunakan data latih dengan memanfaatkan data validasi sebagai dasar pemantauan performa selama proses optimasi. Untuk menjaga stabilitas pembelajaran dan mengurangi risiko *overfitting*, diterapkan tiga mekanisme, yaitu *Early Stopping* untuk menghentikan pelatihan ketika *validation loss* tidak lagi mengalami perbaikan, *ReduceLROnPlateau* untuk menyesuaikan *learning rate* secara otomatis ketika proses optimasi mulai stagnan, serta

ModelCheckpoint untuk menyimpan model dengan nilai *validation loss* terbaik.

Kombinasi tiga skenario dataset dan empat variasi *window size* menghasilkan dua belas model *Long Short-Term Memory (LSTM)*. Masing-masing model selanjutnya dievaluasi menggunakan *Mean Absolute Error (MAE)*, *Root Mean Squared Error (RMSE)*, dan *Mean Haversine Distance* pada data uji. Hasil evaluasi tersebut digunakan untuk membandingkan performa setiap konfigurasi sehingga diperoleh model dengan kemampuan prediksi terbaik.

Model yang terpilih kemudian disimpan dalam format *.keras* dan diintegrasikan ke dalam aplikasi berbasis *Streamlit*. Model tersebut menjadi komponen utama pada proses prediksi lintasan siklon tropis, sedangkan aplikasi berfungsi sebagai antarmuka untuk mengelola data masukan, menjalankan prediksi, menampilkan visualisasi lintasan pada peta interaktif, serta menyajikan hasil evaluasi dan informasi pendukung kepada pengguna.

4.2.2 Perancangan Aplikasi

Perancangan aplikasi dilakukan untuk menggambarkan struktur sistem yang akan diimplementasikan sebagai media prediksi lintasan siklon tropis berbasis *web*. Aplikasi dikembangkan menggunakan *Streamlit* sebagai antarmuka pengguna (*user interface*) yang terintegrasi dengan model *Long Short-Term Memory (LSTM)* hasil pelatihan. Melalui aplikasi ini, pengguna dapat melakukan prediksi lintasan siklon tropis, melihat visualisasi lintasan pada peta interaktif, mengakses data historis siklon, serta melihat informasi mengenai hasil evaluasi model.


Perancangan aplikasi disusun menggunakan pendekatan *Unified Modeling Language (UML)* untuk menggambarkan kebutuhan fungsional, alur aktivitas, struktur kelas, interaksi antarobjek, perubahan keadaan sistem, hingga arsitektur

implementasi. Penggunaan UML bertujuan memberikan gambaran yang sistematis mengenai proses kerja aplikasi sehingga memudahkan proses implementasi dan pengembangan sistem.

Perancangan aplikasi pada penelitian ini terdiri atas *Use Case Diagram*, *Activity Diagram*, *Class Diagram*, *Sequence Diagram*, *Collaboration Diagram*, *State Chart Diagram*, *Deployment Diagram*, serta perancangan antarmuka (*user interface*). Masing-masing diagram menjelaskan aspek yang berbeda dari sistem sehingga keseluruhan rancangan mampu menggambarkan cara kerja aplikasi secara menyeluruh.

4.2.2.1 Use Case Diagram

Use case diagram digunakan untuk menggambarkan kebutuhan fungsional aplikasi serta interaksi antara pengguna dengan sistem. Diagram ini menunjukkan layanan yang dapat diakses oleh pengguna selama menggunakan aplikasi prediksi lintasan siklon tropis, sehingga menjadi dasar dalam perancangan fungsi-fungsi yang akan diimplementasikan.



Gambar 4.10 Use Case Diagram Prediksi Siklon

Berdasarkan Gambar 4.11, Aplikasi memiliki satu aktor, yaitu pengguna, yang berinteraksi dengan enam fungsi utama. Fungsi tersebut meliputi akses ke halaman Beranda, Dashboard Prediksi, Prediksi Siklon, Data Observasi, Evaluasi Akurasi Model, dan Tentang Model. Setiap fungsi dirancang untuk mendukung kebutuhan pengguna dalam memperoleh informasi mengenai prediksi lintasan siklon tropis, data historis, hasil evaluasi model, serta informasi umum mengenai model yang digunakan.

Relasi *include* digunakan untuk menunjukkan bahwa setiap fungsi utama akan menjalankan proses pendukung secara otomatis. Halaman Dashboard Prediksi menyajikan peta yang menampilkan lintasan aktual dan hasil prediksi siklon. Halaman Prediksi Siklon menampilkan hasil prediksi menggunakan model Long Short-Term Memory (LSTM) yang telah dilatih. Halaman Data Observasi menyajikan data yang telah melalui tahap prapemrosesan, sedangkan halaman Evaluasi Akurasi Model menampilkan statistik hasil evaluasi model. Adapun halaman Tentang Model menyajikan informasi mengenai model yang digunakan beserta ringkasan hasil evaluasinya.

4.2.2.2 Activity Diagram


Activity diagram digunakan untuk menggambarkan alur aktivitas pengguna saat berinteraksi dengan aplikasi prediksi lintasan siklon tropis. Diagram ini menunjukkan urutan proses yang berlangsung sejak aplikasi dijalankan hingga sistem menampilkan informasi sesuai dengan menu yang dipilih oleh pengguna.

Proses diawali ketika pengguna membuka aplikasi, kemudian sistem menampilkan halaman Beranda sebagai tampilan awal. Selanjutnya, pengguna memilih salah satu menu yang tersedia pada aplikasi untuk mengakses fungsi yang

diinginkan. Setiap pilihan menu akan mengarahkan sistem pada aktivitas yang berbeda sesuai dengan fungsinya.

Apabila pengguna memilih menu Dashboard, sistem menampilkan peta yang memuat lintasan aktual dan hasil prediksi siklon tropis. Pada menu Prediksi Siklon, pengguna memilih data siklon yang akan diprediksi, kemudian sistem menjalankan model *Long Short-Term Memory* (LSTM) yang telah disimpan dalam format *.keras* untuk menghasilkan prediksi dan menampilkan kepada pengguna.

Menu Data Observasi digunakan untuk menampilkan data observasi yang telah melalui tahap prapemrosesan sebelum digunakan dalam proses pemodelan. Sementara itu, menu Evaluasi Akurasi menyajikan statistik hasil evaluasi performa model berdasarkan metrik yang digunakan pada penelitian. Adapun menu Tentang Model menampilkan informasi mengenai model yang diimplementasikan beserta ringkasan hasil evaluasinya.



Gambar 4.11 Activity Diagram Prediksi Siklon


Berdasarkan Gambar 4.12, Setelah informasi pada menu yang dipilih berhasil ditampilkan, proses interaksi dinyatakan selesai. Rangkaian aktivitas tersebut menggambarkan alur penggunaan aplikasi secara keseluruhan dan menjadi

dasar dalam implementasi setiap fungsi pada aplikasi prediksi lintasan siklon tropis.

4.2.2.3 Class Diagram

Class diagram digunakan untuk menggambarkan struktur statis aplikasi beserta hubungan antar kelas yang membentuk sistem. Melalui diagram ini, setiap kelas dapat diidentifikasi berdasarkan fungsi dan tanggung jawabnya sehingga mempermudah proses pengembangan serta implementasi aplikasi prediksi lintasan siklon tropis.

Aplikasi dirancang menggunakan beberapa kelas utama yang saling berinteraksi dalam menjalankan setiap fungsi. Kelas *MainApp* berperan sebagai pengendali utama yang mengatur jalannya aplikasi dan menghubungkan seluruh halaman yang tersedia. Sementara itu, kelas *DashboardPage*, *PredictionPage*, *ObservationPage*, *EvaluationPage*, dan *AboutPage* merepresentasikan halaman-halaman yang dapat diakses oleh pengguna sesuai dengan menu pada aplikasi.



Gambar 4.12 Diagram Kelas Aplikasi Prediksi Siklon

Kelas *PredictionService* bertanggung jawab memuat model *Long Short-Term Memory* (LSTM) yang telah disimpan dalam format *.keras* serta menjalankan proses prediksi berdasarkan data masukan dari pengguna. Selanjutnya, kelas

DataLoader berfungsi memuat dataset dan data observasi yang digunakan pada beberapa halaman aplikasi, sedangkan kelas *MapVisualizer* digunakan untuk membangun visualisasi peta interaktif yang menampilkan lintasan aktual dan hasil prediksi siklon tropis.

Hubungan antar kelas menunjukkan bahwa *MainApp* menjadi pusat pengendali yang menghubungkan seluruh halaman aplikasi. Setiap halaman kemudian memanfaatkan kelas pendukung sesuai dengan kebutuhannya. Halaman Dashboard menggunakan *DataLoader* untuk memuat data dan *MapVisualizer* untuk menyajikan visualisasi peta. Halaman Prediksi memanfaatkan *PredictionService* untuk menghasilkan prediksi serta *MapVisualizer* untuk menampilkan hasil prediksi pada peta. Adapun halaman Data Observasi, Evaluasi Akurasi, dan Tentang Model menggunakan *DataLoader* untuk memperoleh data dan informasi yang ditampilkan kepada pengguna.

Struktur tersebut menunjukkan bahwa setiap kelas memiliki tanggung jawab yang berbeda namun saling terintegrasi dalam menjalankan fungsi aplikasi. Pembagian tanggung jawab ini menjadikan pengelolaan kode lebih terstruktur, memudahkan proses pengembangan, serta mempermudah pemeliharaan aplikasi apabila dilakukan pengembangan pada tahap berikutnya


4.2.2.4 Sequence Diagram

Sequence diagram digunakan untuk memodelkan urutan interaksi antar komponen dalam aplikasi prediksi lintasan siklon tropis. Secara visual, diagram ini memetakan alur komunikasi yang terjadi antara pengguna dengan komponen antarmuka, serta berbagai modul pendukung seperti *DataLoader*, *PredictionEngine*, dan *MapVisualizer*. Pada sistem yang dibangun, secara

keseluruhan terdapat empat skenario utama yang dijabarkan dalam bentuk sequence diagram untuk memudahkan pemahaman terhadap alur kerja aplikasi. Keempat skenario tersebut mencakup tahapan visualisasi data siklon, proses prediksi, evaluasi akurasi model, serta penyajian hasil prediksi, sehingga alur keseluruhan sistem dapat dipahami dengan lebih terstruktur.

4.2.2.4.1 Sequence Diagram Dashboard

Proses visualisasi data siklon diawali dengan interaksi pengguna yang membuka halaman Data Siklon pada *dashboard*. Sistem kemudian merespons permintaan tersebut dengan melakukan pemuatan dataset observasi siklon yang tersimpan dalam format CSV atau IBTrACS. Permintaan pemuatan data ini dikirimkan oleh *Dashboard* kepada komponen CSVLoader untuk mengambil data observasi yang dibutuhkan, yang mencakup informasi koordinat lintang dan bujur, kecepatan angin, tekanan, serta status siklon.




Gambar 4.13 Sequence Diagram Dashboard

Setelah data observasi berhasil diakses, *CSVLoader* akan mengembalikannya kembali ke *Dashboard* untuk dilanjutkan ke tahap penyajian. *Dashboard* kemudian mengirimkan data observasi tersebut kepada komponen *TableView* agar di-*render* menjadi bentuk tabel yang rapi dan informatif.

Komponen *TableView* memproses data tersebut, lalu menampilkan representasi tabelnya kembali ke *Dashboard*. Akhirnya, *Dashboard* menampilkan tabel data observasi siklon kepada pengguna sebagai antarmuka awal untuk mengidentifikasi serta memilih data siklon yang akan digunakan pada proses prediksi selanjutnya.

4.2.2.4.2 Sequence Diagram Prediksi Siklon

Proses inti dari aplikasi ini adalah melakukan prediksi lintasan siklon berdasarkan data observasi yang telah tersedia. Urutan interaksi pada skenario ini dimulai saat pengguna memasukkan data observasi yang relevan, meliputi koordinat lintang dan bujur, kecepatan angin, tekanan, serta tanggal dan waktu ke dalam antarmuka *PredictionPage*. Data tersebut kemudian dikirimkan oleh *PredictionPage* kepada komponen *PredictionEngine* untuk diproses lebih lanjut. Alur komunikasi antara pengguna, antarmuka, dan mesin prediksi.




Gambar 4.14 Sequence Diagram Prediksi Siklon

Setelah menerima data observasi, *PredictionEngine* menjalankan serangkaian proses prediksi secara internal. Proses ini mencakup normalisasi data menggunakan *scaler*, menjalankan proses inferensi pada *model Long Short-Term Memory (LSTM)* yang telah dilatih, hingga melakukan *inverse transform* untuk mengembalikan data ke dalam satuan koordinat dan kecepatan yang sesungguhnya.

Hasil prediksi yang mencakup koordinat prediksi dan kecepatan angin pada *step* waktu berikutnya kemudian dikembalikan oleh *PredictionEngine* ke *PredictionPage* untuk ditampilkan kepada pengguna. kemudian berkoordinasi dengan *TableView* untuk merender tabel interaktif dan *MapVisualizer* untuk membangun peta lintasan siklon. Setelah kedua komponen tersebut selesai memproses visualisasi, *PredictionPage* menampilkan tabel numerik dan peta interaktif kepada pengguna sebagai luaran akhir dari proses prediksi.

4.2.2.4.3 Sequence Diagram Data Siklon

Skenario visualisasi data siklon diawali ketika pengguna mengakses halaman *ObeservationPage* melalui antarmuka aplikasi. Saat halaman terbuka, *ObeservationPage* menginisiasi proses pemuatan seluruh dataset observasi siklon yang bersumber dari CSV dengan berinteraksi langsung melalui komponen *CSVLoader*.




Gambar 4.15 Sequence Diagram Data Siklon

Setelah keseluruhan data observasi berhasil dimuat dan dikembalikan ke halaman, pengguna diberikan opsi untuk memilih ID siklon tertentu yang ingin

ditelusuri lebih lanjut. ID siklon yang telah dipilih oleh pengguna selanjutnya diteruskan ke *FilterService* untuk melakukan penyaringan data spesifik sesuai dengan ID tersebut. Data hasil filter yang mencakup koordinat lintang dan bujur, kecepatan angin, tekanan, serta status siklon kemudian dikirimkan ke komponen *TableView* untuk di-*render* menjadi format tabel yang informatif. Proses visualisasi diakhiri dengan *DataSiklonPage* yang menggabungkan dan menampilkan luaran tabel data siklon terpilih beserta peta lintasan kepada pengguna sebagai hasil akhir interaksi.

4.2.2.4 Sequence Diagram Evaluasi Akurasi Model

Proses evaluasi akurasi model diawali ketika pengguna membuka halaman Evaluasi Akurasi pada antarmuka aplikasi. Saat halaman diakses, *EvaluationPage* segera memuat dataset hasil prediksi melalui komponen *CSVLoader* untuk memperoleh data seluruh siklon yang tersimpan dalam format CSV.



Gambar 4.16 Sequence Diagram Evaluasi Akurasi


seluruh data hasil prediksi berhasil dimuat, pengguna dapat melakukan pemilihan terhadap kasus siklon spesifik berdasarkan ID siklon yang akan dianalisis. Alur interaksi antar komponen pada tahapan evaluasi ini secara lengkap

ditampilkan pada pengguna diteruskan ke *FilterService* untuk memisahkan data prediksi yang sesuai, dan hasilnya dikirimkan ke *StatsCalculator* guna menghitung metrik akurasi yang meliputi MAE, RMSE, serta error minimum dan maksimum. Secara paralel, *EvaluationPage* mengirimkan data terpilih dan hasil statistik kepada *TableView* untuk dirender menjadi tabel interaktif yang membandingkan koordinat aktual dan prediksi beserta error pada setiap titiknya, serta kepada *ChartVisualizer* untuk membangun grafik deviasi jarak dan distribusi error. Semua komponen visualisasi tersebut mengembalikan keluarannya ke *EvaluationPage*, yang kemudian menampilkan seluruh informasi mulai dari tabel, grafik, hingga metrik akurasi secara lengkap kepada pengguna sebagai luaran akhir proses evaluasi.

4.2.2.5 State Chart Diagram

Statechart diagram digunakan untuk menggambarkan perubahan keadaan (*state*) aplikasi selama proses prediksi lintasan siklon tropis. Diagram ini menunjukkan bagaimana sistem berpindah dari satu keadaan ke keadaan berikutnya berdasarkan masukan yang diberikan oleh pengguna hingga hasil prediksi berhasil ditampilkan.

Pada keadaan awal, aplikasi berada pada *state* Input Data. Pada tahap ini, pengguna memasukkan nilai koordinat lintang (*LAT*), bujur (*LON*), kecepatan angin (*WMO_WIND*), dan tekanan udara (*WMO_PRES*). Koordinat dapat dimasukkan secara langsung melalui formulir maupun dengan memilih lokasi pada peta



Gambar 4.17 State Chart Diagram Prediksi Siklon

Setelah seluruh data masukan tersedia, sistem berpindah ke *state* Proses Prediksi. Pada tahap ini, model *Long Short-Term Memory* (LSTM) yang telah disimpan dalam format *.keras* melakukan proses inferensi untuk menghasilkan koordinat prediksi berdasarkan data yang diberikan oleh pengguna.

Apabila proses inferensi berhasil diselesaikan, sistem berpindah ke *state* Hasil Prediksi. Pada keadaan ini, aplikasi menampilkan koordinat hasil prediksi beserta visualisasi lintasan pada peta interaktif sehingga pengguna dapat melihat hasil prediksi secara langsung.


Berdasarkan diagram tersebut, perubahan *state* berlangsung secara berurutan mulai dari Input Data, Proses Prediksi, hingga Hasil Prediksi. Setiap perpindahan *state* dipicu oleh aksi pengguna atau respons sistem, sehingga alur prediksi dapat berjalan secara sistematis sesuai dengan proses yang diimplementasikan pada aplikasi.

4.2.2.6 Deployment Diagram

Deployment diagram digunakan untuk menggambarkan arsitektur fisik aplikasi serta penempatan komponen perangkat lunak pada lingkungan eksekusi. Diagram ini menunjukkan hubungan antara perangkat klien, *server* aplikasi, dan media penyimpanan yang mendukung proses prediksi lintasan siklon tropis.

Sistem terdiri atas dua *node* utama, yaitu Perangkat *Klien* dan *Server Aplikasi* (Python *Environment*). Perangkat *Klien* menggunakan *web browser* untuk mengakses antarmuka aplikasi Streamlit. Sementara itu, *Server Aplikasi* menjalankan komponen utama yang terdiri atas *Data Loader*, Aplikasi Streamlit, dan *Prediction Service*. Selain ketiga komponen tersebut, *server* juga terhubung

dengan penyimpanan lokal yang menyimpan dataset IBTrACS dalam format .csv dan model *Long Short-Term Memory* (LSTM) dalam format .keras.



Gambar 4.18 Deployment Diagram Prediksi Siklon

Berdasarkan Gambar 4.18, antarmuka Streamlit pada *web browser* berkomunikasi dengan Aplikasi Streamlit yang berjalan pada Server Aplikasi. Aplikasi Streamlit kemudian berinteraksi dengan komponen *Data Loader* untuk mengakses dataset IBTrACS dan dengan *Prediction Service* untuk menjalankan proses prediksi.

Komponen *Data Loader* mengambil data observasi dari penyimpanan lokal yang berisi dataset IBTrACS, sedangkan *Prediction Service* memuat model LSTM dalam format .keras dari lokasi penyimpanan yang sama. Setelah seluruh data dan model tersedia, hasil pemrosesan dikembalikan ke Aplikasi Streamlit untuk ditampilkan kepada pengguna melalui antarmuka pada *web browser*.

Arsitektur tersebut menunjukkan bahwa setiap komponen memiliki fungsi yang berbeda namun saling terintegrasi. Aplikasi Streamlit berperan sebagai penghubung antara antarmuka pengguna, pengelolaan data oleh *Data Loader*, dan layanan prediksi yang dijalankan oleh *Prediction Service*. Pemisahan fungsi ini membuat proses pengambilan data, pelaksanaan prediksi, dan penyajian hasil dapat berlangsung secara terstruktur sesuai dengan rancangan sistem.

4.2.2.7 Perancangan *Interface*

Perancangan antarmuka dilakukan untuk menyediakan media interaksi antara pengguna dengan sistem prediksi lintasan siklon tropis. Antarmuka dirancang dengan mengutamakan kemudahan penggunaan, kejelasan penyajian informasi, dan konsistensi tata letak sehingga pengguna dapat mengakses fungsi-fungsi utama sistem secara lebih efisien. Selain berperan sebagai sarana visualisasi hasil prediksi, antarmuka juga menyajikan informasi pendukung yang membantu pengguna memahami data observasi, hasil evaluasi model, serta ringkasan penelitian.


Pada penelitian ini, antarmuka dikembangkan menggunakan *framework* Streamlit dan terdiri atas empat halaman utama, yaitu *Dashboard*, Data Observasi Siklon, Evaluasi Akurasi Prediksi, dan Tentang. Setiap halaman memiliki fungsi yang berbeda namun saling terintegrasi. Halaman *Dashboard* digunakan untuk menampilkan visualisasi lintasan aktual dan hasil prediksi pada peta interaktif. Halaman Data Observasi Siklon menyajikan data pengamatan yang digunakan sebagai masukan model. Halaman Evaluasi Akurasi Prediksi menampilkan hasil evaluasi model melalui tabel dan grafik, sedangkan halaman Tentang memuat ringkasan penelitian, informasi model, serta hasil evaluasi secara umum. Rancangan antarmuka tersebut diharapkan dapat mendukung penyajian informasi secara jelas, terstruktur, dan mudah dipahami oleh pengguna.

4.2.2.7.1 Tampilan Halaman Beranda

Halaman Beranda dirancang sebagai halaman pertama yang ditampilkan ketika aplikasi sistem prediksi lintasan siklon tropis dijalankan. Halaman ini berfungsi sebagai media pengenalan aplikasi dengan menyajikan informasi umum mengenai tujuan pengembangan sistem serta menyediakan akses menuju seluruh

fitur yang tersedia. Perancangan antarmuka dilakukan dengan mengutamakan kemudahan navigasi dan penyajian informasi yang ringkas sehingga pengguna dapat memahami fungsi aplikasi sebelum mengakses halaman-halaman lain yang berkaitan dengan proses prediksi maupun evaluasi.

Selain itu, halaman Beranda juga dirancang sebagai pusat navigasi yang menghubungkan pengguna dengan setiap menu pada aplikasi. Melalui halaman ini, pengguna dapat berpindah ke halaman *Dashboard* Prediksi, Prediksi Siklon, Data Observasi, Evaluasi Akurasi, maupun Tentang Model secara mudah. Dengan demikian, pengguna memperoleh gambaran awal mengenai fungsi dan alur penggunaan aplikasi sebelum memanfaatkan fitur-fitur yang tersedia.




Gambar 4.19 Desain Tampilan Halaman Beranda

Gambar 4.19 menunjukkan rancangan tampilan halaman Beranda yang terdiri atas panel navigasi di sisi kiri dan area konten utama di sisi kanan. Panel navigasi menyediakan menu Beranda Utama, Dashboard Prediksi, Prediksi Siklon, Data Observasi, Evaluasi Akurasi, dan Tentang Model, sehingga pengguna dapat berpindah ke setiap halaman sesuai kebutuhan. Pada area konten utama ditampilkan ucapan selamat datang, deskripsi singkat mengenai aplikasi, serta beberapa kartu

informasi yang menjelaskan fungsi utama setiap halaman yang tersedia dalam sistem.

4.2.2.7.2 Tampilan Halaman Dashboard

Halaman dashboard merupakan antarmuka pertama yang ditampilkan ketika aplikasi dijalankan. Halaman ini menjadi pusat interaksi pengguna untuk mengakses seluruh fungsi yang tersedia pada sistem prediksi lintasan siklon tropis. Tata letaknya terdiri atas tiga bagian utama, yaitu panel navigasi di sisi kiri, area judul pada bagian atas, dan area konten yang menampilkan peta interaktif beserta informasi hasil prediksi. Panel navigasi menyediakan menu Dashboard, Data Siklon, Evaluasi, dan Tentang sebagai sarana perpindahan antarhalaman.



Gambar 4.20 Desain Tampilan Halaman *Dashboard*

Gambar 4.20 menunjukkan rancangan halaman dashboard utama yang digunakan untuk menampilkan hasil prediksi lintasan siklon. Peta interaktif menjadi komponen utama karena menyajikan perbandingan antara lintasan aktual dan lintasan hasil prediksi dalam satu tampilan. Lintasan aktual ditampilkan

menggunakan garis hitam, sedangkan lintasan hasil prediksi ditampilkan menggunakan garis biru putus-putus. Setiap titik pada kedua lintasan merepresentasikan posisi pusat siklon pada interval pengamatan tiga jam sehingga perubahan arah pergerakan dapat diamati secara bertahap.

Selain visualisasi lintasan, halaman ini juga menampilkan nilai *Root Mean Squared Error* (RMSE) dan *Mean Absolute Error* (MAE) dalam satuan kilometer pada bagian bawah peta. Kedua metrik tersebut memberikan informasi mengenai tingkat kesalahan prediksi yang dihasilkan oleh model sehingga pengguna dapat membandingkan hasil visual dengan nilai evaluasi kuantitatif secara bersamaan. Penyajian informasi spasial dan metrik evaluasi dalam satu halaman mendukung interpretasi hasil prediksi secara lebih mudah dan efisien.

4.2.2.7.3 Tampilan Halaman Prediksi Siklon

Halaman Prediksi Siklon dirancang sebagai antarmuka utama yang digunakan pengguna untuk melakukan prediksi posisi siklon tropis berdasarkan data observasi yang dimasukkan secara manual. Halaman ini mengintegrasikan proses pengisian data masukan, pelaksanaan inferensi menggunakan model *Long Short-Term Memory* (LSTM), serta visualisasi hasil prediksi dalam satu tampilan. Dengan rancangan tersebut, pengguna dapat melakukan proses prediksi secara terstruktur tanpa harus berinteraksi langsung dengan kode program maupun proses komputasi yang berjalan di belakang sistem. halaman Prediksi Siklon yang terbagi menjadi dua bagian utama. Bagian kiri digunakan sebagai area Input Koordinat, yang menyediakan kolom tanggal awal observasi serta tabel pengisian koordinat lintang (LAT) dan bujur (LON) untuk delapan titik pengamatan terakhir dengan interval observasi tiga jam.

SISTEM PREDIKSI SIKLON TROPIS UNTUK MITIGASI RISIKO BENCANA DI SUMATERA BARAT

MENU NAVIGASI

[Beranda Utama](#)
[Dashboard Prediksi](#)
[Prediksi Siklon](#)
[Data Observasi](#)
[Evaluasi Akurasi](#)
[Tentang Model](#)

[Model LSTM Sliding Window 8](#)

Prediksi Posisi 3 Jam Berikutnya

Masukkan delapan posisi siklon secara berurutan, dari observasi paling lama ke yang terbaru. Sistem menghitung proyeksi geodesik berbasis fisika dengan interval observasi tiga jam.

Input Koordinat

Urutkan dari titik paling lama ke paling baru. Interval tiap titik adalah 3 jam, proyeksi dibatasi maksimal 180 km per 3 jam.

Tanggal awal observasi

DD/MM/YYYY 99:99

No	LAT (°)	LON (°)
1	999.99	999.99
2	Z	Z
3	Z	Z
4	Z	Z
5	Z	Z
6	Z	Z
7	Z	Z
8	Z	Z
9	999.99	999.99

[Prediksi 3 Jam](#)
[Bersihkan](#)

Peta Lintasan


Klik peta untuk mengisi titik kosong berikutnya pada tabel koordinat.

Gambar 4.21 Desain Tampilan Halaman Prediksi Siklon

Pada Gambar 4.21 menunjukkan rancangan Data tersebut menjadi masukan bagi model LSTM untuk memprediksi posisi siklon pada tiga jam berikutnya. Pada bagian bawah tersedia tombol Prediksi 3 Jam untuk menjalankan proses prediksi dan tombol Bersihkan untuk menghapus seluruh data masukan sehingga pengguna dapat melakukan prediksi baru dengan lebih mudah.

4.2.2.7.4 Tampilan Halaman Data Observasi Siklon

Halaman Data Observasi Siklon menampilkan data pengamatan yang digunakan sebagai masukan dalam proses pemodelan. Informasi pada halaman ini disusun dalam tiga bagian utama. Bagian atas menampilkan identitas siklon yang dipilih, meliputi ID siklon, nama siklon, periode pengamatan, durasi, dan interval pencatatan data. Bagian tengah menyajikan data observasi dalam bentuk tabel deret waktu (*time series*) yang terdiri atas waktu pengamatan, koordinat lintang (*LAT*), koordinat bujur (*LON*), kecepatan angin (*Wind*), dan tekanan udara (*Pressure*). Pada bagian bawah ditampilkan informasi mengenai sumber data yang digunakan.

SISTEM PREDIKSI SIKLON TROPIS UNTUK MITIGASI RISIKO BENCANA DI SUMATERA BARAT																																	
MENU NAVIGASI Beranda Utama Dashboard Prediksi Prediksi Siklon Data Observasi Evaluasi Akurasi Tentang Model		DATA OBSERVASI SIKLON TERPILIH ID Siklon : 999999 Nama : xxxxxx Interval : 3 Jam Periode : dd/mm/yyyy - dd/mm/yyyy Durasi : 999x Jam																															
	<table border="1"> <thead> <tr> <th>Waktu</th> <th>LAT (°)</th> <th>LON (°)</th> <th>Wind (knot)</th> <th>Pressure (hPa)</th> </tr> </thead> <tbody> <tr><td>99:99</td><td>99.999°</td><td>99.999°</td><td>99</td><td>999</td></tr> <tr><td>99:99</td><td>99.999°</td><td>99.999°</td><td>99</td><td>999</td></tr> <tr><td>99:99</td><td>99.999°</td><td>99.999°</td><td>99</td><td>999</td></tr> <tr><td>99:99</td><td>99.999°</td><td>99.999°</td><td>99</td><td>999</td></tr> <tr><td>...</td><td>...</td><td>...</td><td>...</td><td>...</td></tr> </tbody> </table>	Waktu	LAT (°)	LON (°)	Wind (knot)	Pressure (hPa)	99:99	99.999°	99.999°	99	999	99:99	99.999°	99.999°	99	999	99:99	99.999°	99.999°	99	999	99:99	99.999°	99.999°	99	999	...	...	...	...	...	[Sumber Data Pemodelan] Data di atas adalah input mentah yang dipakai model LSTM. Model belajar mengenali pola pergerakan siklon berdasarkan posisi geografis (LAT/LON), kecepatan angin, dan tekanan udara yang tercatat setiap 3 jam. Seluruh data telah diperiksa dan dirapikan untuk memastikan tidak ada data yang hilang atau kosong saat diproses. 	
Waktu	LAT (°)	LON (°)	Wind (knot)	Pressure (hPa)																													
99:99	99.999°	99.999°	99	999																													
99:99	99.999°	99.999°	99	999																													
99:99	99.999°	99.999°	99	999																													
99:99	99.999°	99.999°	99	999																													
...	...	...	...	...																													
Model LSTM Sliding Window 8																																	

Gambar 4.22 Desain Tampilan Halaman Data Siklon


Pada Gambar 4.22 memperlihatkan halaman yang digunakan untuk menampilkan data observasi setiap siklon secara rinci. Informasi identitas pada bagian atas membantu pengguna memastikan bahwa data yang ditampilkan sesuai dengan siklon yang dipilih. Tabel observasi di bagian tengah menyajikan urutan data berdasarkan waktu pengamatan dengan interval tiga jam sehingga perkembangan posisi dan perubahan intensitas siklon dapat diamati secara kronologis.

Bagian bawah halaman memuat informasi mengenai sumber data pemodelan yang berasal dari dataset IBTrACS. Informasi tersebut memberikan keterangan bahwa data yang ditampilkan merupakan hasil pengolahan sesuai dengan tahapan prapemrosesan yang dijelaskan pada bab sebelumnya sebelum digunakan sebagai masukan model LSTM. Penyajian data observasi secara terbuka mendukung transparansi proses pemodelan karena pengguna dapat menelusuri data yang menjadi dasar pembentukan hasil prediksi.

4.2.2.7.5 Tampilan Halaman Evaluasi Akurasi Prediksi

Halaman Evaluasi Akurasi Prediksi digunakan untuk menampilkan hasil evaluasi kinerja model berdasarkan perbandingan antara lintasan aktual dan lintasan hasil prediksi. Informasi pada halaman ini disajikan dalam tiga bagian, yaitu tabel perbandingan koordinat, grafik deviasi prediksi, dan ringkasan hasil evaluasi. Susunan tersebut memberikan informasi kuantitatif dan visual mengenai tingkat ketepatan prediksi yang dihasilkan oleh model LSTM.

Halaman evaluasi yang menampilkan hasil prediksi secara rinci. Tabel pada bagian atas menyajikan koordinat lintang dan bujur aktual beserta koordinat hasil prediksi untuk setiap waktu pengamatan. Melalui tabel tersebut, pengguna dapat membandingkan posisi aktual dan posisi prediksi pada setiap interval waktu serta mengamati besarnya perbedaan koordinat yang terjadi.



Gambar 4.23 Desain Tampilan Halaman Evaluasi

Gambar 4.23, Memperlihatkan Bagian bawah halaman menampilkan grafik deviasi yang menggambarkan perubahan jarak kesalahan prediksi terhadap waktu. Sumbu horizontal menunjukkan urutan waktu pengamatan, sedangkan sumbu

vertikal menunjukkan besarnya kesalahan prediksi dalam satuan kilometer. Visualisasi ini membantu pengguna mengenali pola perubahan kesalahan sepanjang lintasan tanpa harus menelaah seluruh data numerik pada tabel. Ringkasan evaluasi yang disajikan pada bagian akhir memberikan penjelasan singkat mengenai hasil yang ditampilkan sehingga informasi dapat dipahami dengan lebih mudah oleh berbagai kelompok pengguna, termasuk pihak yang memanfaatkan hasil prediksi sebagai bahan pendukung dalam kegiatan mitigasi bencana.

4.2.2.7.6 Tampilan Halaman Tentang

Halaman Tentang menyediakan informasi umum mengenai penelitian dan aplikasi yang dikembangkan. Halaman ini menyajikan ringkasan penelitian, karakteristik data, hasil evaluasi model, serta informasi mengenai kontribusi sistem. Seluruh informasi disusun dalam beberapa blok sehingga pengguna dapat memperoleh gambaran mengenai tujuan penelitian, metode yang digunakan, dan hasil yang diperoleh tanpa harus membaca keseluruhan laporan penelitian.

SISTEM PREDIKSI SIKLON TROPIS UNTUK MITIGASI RISIKO BENCANA DI SUMATERA BARAT

MENU NAVIGASI

Beranda Utama

Dashboard Prediksi

Prediksi Siklon

Data Observasi

Evaluasi Akurasi

Tentang Model

Model LSTM
Sliding Window 8

INFORMASI PENELITIAN & RINGKASAN HASIL

[RINGKASAN PENELITIAN]

Metode : Deep Learning (LSTM Stacked 2 Lapis)

Sumber Data : IBTrACS (NI & SI Basin)

Wilayah perairan : Samudra Hindia Timur - Pesisir Sumatera

Preprocessing : Interpolasi, Z-Score, Sliding Window

[TEMUAN UTAMA]

Model Terbaik : Timesteps X

RMSE Terbaik : 99.9 km

MAE Terbaik : 99.9 km

[KARAKTERISTIK DATA]

1. Wilayah perairan NI: Rotasi X
2. Wilayah perairan SI: Rotasi X
3. Data SI lebih kompleks

[PERBANDINGAN KINERJA WILAYAH PERAIRAN]

	NI	SI	Gabungan (NI+SI)
RMSE:	99.9 km	99.9 km	99.9 km
MAE :	99.9 km	99.9 km	99.9 km

[KONTRIBUSI & KEGUNAAN ALAT]

Purwarupa dasbor ini berfungsi menampilkan perbandingan antara lintasan aktual dan hasil prediksi dalam bentuk peta interaktif, tabel data, serta grafik deviasi. Alat ini bertujuan memudahkan interpretasi pola pergerakan siklon yang dihasilkan oleh model LSTM.

Gambar 4.24 Desain Halaman tentang

Gambar 4.24 memperlihatkan Halaman Tentang yang terdiri atas beberapa bagian informasi. Bagian pertama memuat ringkasan penelitian yang mencakup metode pemodelan, sumber data, wilayah penelitian, dan tahapan prapemrosesan. Bagian berikutnya menampilkan hasil evaluasi model, termasuk konfigurasi terbaik beserta nilai *Root Mean Squared Error* (RMSE) dan *Mean Absolute Error* (MAE) yang diperoleh selama proses pengujian. Halaman ini juga menyajikan tabel perbandingan kinerja model pada skenario *North Indian Ocean* (NI), *South Indian Ocean* (SI), dan data gabungan sehingga pengguna dapat melihat perbedaan hasil evaluasi untuk setiap skenario penelitian.

Selain informasi hasil evaluasi, halaman ini memuat ringkasan karakteristik data serta uraian mengenai kontribusi dan kegunaan aplikasi. Penyajian informasi tersebut memberikan konteks terhadap hasil prediksi yang ditampilkan pada halaman lain sekaligus membantu pengguna memahami ruang lingkup penelitian, sumber data yang digunakan, dan kinerja model secara ringkas dalam satu halaman.

BAB V

IMPLEMENTASI DAN PENGUJIAN

5.1 Implementasi

Bagian ini menjelaskan implementasi sistem prediksi lintasan siklon tropis berdasarkan rancangan yang telah dibahas pada bab sebelumnya. Pembahasan meliputi spesifikasi perangkat keras dan perangkat lunak yang digunakan selama proses pengembangan, batasan yang diterapkan dalam implementasi, serta alur kerja sistem mulai dari pengolahan data hingga menghasilkan prediksi lintasan. Selain itu, bagian ini juga menjelaskan implementasi pipeline data yang mencakup tahap *preprocessing*, *feature engineering*, serta penerapan arsitektur model *Long Short-Term Memory (LSTM)* pada lingkungan pengembangan yang digunakan dalam penelitian.

5.1.1 Lingkungan Implementasi

Lingkungan implementasi pada penelitian ini terdiri atas perangkat keras dan perangkat lunak yang digunakan selama proses pengembangan sistem, pelatihan model, dan implementasi aplikasi. Pengembangan antarmuka aplikasi dilakukan pada komputer lokal, sedangkan proses pelatihan model *deep learning* memanfaatkan layanan komputasi berbasis awan untuk mendukung kebutuhan komputasi yang lebih tinggi, khususnya pada proses pelatihan model LSTM yang memerlukan sumber daya komputasi dan waktu pemrosesan yang relatif besar. Penggunaan kedua lingkungan tersebut memungkinkan proses pengembangan dan pelatihan model dilakukan secara efisien sesuai dengan kebutuhan masing-masing tahapan penelitian.

5.1.1.1 Perangkat Keras

Penelitian ini menggunakan kombinasi perangkat keras lokal dan layanan komputasi awan untuk mendukung proses pengembangan sistem serta pelatihan model. Komputer lokal digunakan untuk penulisan kode, pengolahan data awal, dan pengembangan antarmuka dashboard. Sementara itu, proses pelatihan model *Long Short-Term Memory (LSTM)* dilakukan menggunakan layanan komputasi awan yang menyediakan akselerasi *GPU* agar proses pelatihan dapat berjalan lebih efisien. Spesifikasi perangkat keras yang digunakan dalam penelitian ini disajikan pada Tabel 5.1.

Tabel 5.1 Spesifikasi Perangkat Keras yang Digunakan

Jenis Perangkat	Spesifikasi	Kegunaan
Laptop Pengembangan	Lenovo IdeaPad Slim 3, AMD Ryzen 5 7520U (hingga 4,3 GHz), RAM 8 GB, SSD 512 GB	Penulisan kode, pengolahan data awal, dan pengembangan antarmuka dashboard
Komputasi Awan	Google Colaboratory dengan GPU NVIDIA T4	Pelatihan model LSTM dan pelaksanaan eksperimen

5.1.1.2 Perangkat Lunak dan Library

Penelitian ini menggunakan berbagai perangkat lunak dan *library* untuk mendukung proses pengolahan data, pelatihan model, evaluasi, visualisasi, serta pengembangan aplikasi. Pengembangan sistem dilakukan pada sistem operasi Windows 11, sedangkan proses pelatihan model memanfaatkan lingkungan Linux yang tersedia pada Google Colaboratory. Seluruh proses pemrograman diimplementasikan dengan dukungan beberapa *library* sesuai kebutuhan penelitian. Rincian perangkat lunak dan *library* yang digunakan disajikan pada Tabel 5.2.

Tabel 5.2 Spesifikasi Perangkat Lunak dan *Library*

Perangkat Lunak / Library	Versi / Jenis	Kegunaan
Sistem Operasi (Lokal)	Windows 11	Pengembangan aplikasi dan antarmuka pengguna
Sistem Operasi (Awan)	Linux (Google Colaboratory)	Lingkungan pelatihan model dan pemrosesan data
Bahasa Pemrograman	Python 3.11	Implementasi seluruh proses penelitian
Data Handling	Pandas, NumPy	Pengolahan data, transformasi, dan operasi numerik
Deep Learning Framework	TensorFlow 2.20	Membangun dan melatih model LSTM
Machine Learning Utilities	Scikit-learn	Normalisasi Z-Score dan perhitungan metrik evaluasi (RMSE dan MAE)
Visualization & Geospatial	Matplotlib, Folium	Pembuatan grafik dan visualisasi peta interaktif
Dashboard & App Framework	Streamlit	Pengembangan dashboard berbasis web
Model Serialization	Keras (.keras)	Penyimpanan model LSTM yang telah dilatih
Pendukung	Git, Github, Microsoft Edge, Microsoft Office	Kontrol versi, akses Google Colaboratory, dan penyusunan dokumentasi

Perangkat lunak dan *library* tersebut saling mendukung dalam setiap tahapan penelitian, mulai dari pengolahan data, pelatihan dan evaluasi model, hingga pengembangan Aplikasi untuk menampilkan hasil prediksi lintasan siklon tropis.

5.1.2 Batasan Implementasi

Dalam proses implementasi, penelitian ini memiliki beberapa batasan yang disesuaikan dengan tujuan penelitian, ketersediaan data, serta sumber daya komputasi yang digunakan. Batasan tersebut diperlukan agar proses pengembangan sistem tetap terfokus dan hasil yang diperoleh sesuai dengan ruang lingkup penelitian. Oleh karena itu, implementasi sistem dibatasi pada aspek arsitektur model, cakupan data, serta pengembangan dashboard yang digunakan untuk menampilkan hasil prediksi.

Dari sisi arsitektur model, penelitian ini menggunakan model *Long Short-Term Memory* (LSTM) dengan satu lapis (*single-layer*) yang terdiri atas 64 unit tersembunyi. Konfigurasi tersebut dipilih berdasarkan hasil eksperimen yang telah dilakukan selama proses pelatihan model. Selain menghasilkan proses pelatihan yang lebih stabil, konfigurasi ini juga mampu memberikan kemampuan generalisasi yang lebih baik sehingga digunakan sebagai model akhir dalam penelitian.

Dari sisi data, penelitian ini menggunakan dataset *IBTrACS* periode 1980 hingga 2025 yang mencakup wilayah *North Indian Ocean* (NI) dan *South Indian Ocean* (SI). Seluruh data diproses menggunakan tahapan *preprocessing* yang sama, mulai dari pembersihan data, pembentukan fitur, hingga proses normalisasi. Dengan perlakuan yang konsisten pada setiap skenario, hasil evaluasi yang diperoleh dapat dibandingkan secara lebih objektif karena tidak dipengaruhi oleh perbedaan proses pengolahan data.

Selain itu, Aplikasi yang dikembangkan menggunakan Streamlit berfungsi sebagai prototipe untuk menampilkan hasil prediksi lintasan siklon tropis secara interaktif. *Dashboard* ini digunakan sebagai media visualisasi dan demonstrasi


hasil penelitian sehingga difokuskan pada penyajian informasi dan kemudahan penggunaan. Oleh karena itu, sistem belum dirancang sebagai aplikasi yang siap digunakan pada lingkungan produksi, baik dari sisi keamanan, manajemen pengguna, maupun infrastruktur *deployment*.

5.2 Pengujian

Implementasi aplikasi dilakukan menggunakan *framework* Streamlit sebagai antarmuka yang menghubungkan pengguna dengan model prediksi yang telah dikembangkan. aplikasi dirancang agar proses prediksi, visualisasi data, dan evaluasi hasil dapat dilakukan melalui antarmuka yang mudah digunakan. Setiap halaman memiliki fungsi yang berbeda namun saling terhubung sehingga pengguna dapat mengakses seluruh fitur sistem secara berurutan.

5.2.1 Pengujian Halaman Beranda

Halaman Beranda merupakan tampilan awal aplikasi yang berfungsi sebagai pusat navigasi menuju seluruh fitur yang tersedia. Pada halaman ini, pengguna dapat melihat menu utama serta informasi model LSTM yang digunakan sebelum mengakses proses prediksi maupun evaluasi.




Gambar 5.1 Tampilan Halaman Beranda.

Pada Gambar 5.1, sisi kiri terdapat panel navigasi yang memuat menu Beranda Utama, Dashboard Prediksi, Data Observasi, Evaluasi Akurasi, dan Tentang Model, serta informasi model LSTM yang sedang aktif. Susunan menu tersebut memudahkan pengguna berpindah ke setiap halaman sesuai kebutuhan.

Area utama menampilkan informasi singkat mengenai tujuan aplikasi beserta ringkasan fitur yang tersedia untuk mengakses dashboard, data observasi, evaluasi, dan informasi model. Selain itu, terdapat ilustrasi citra satelit siklon tropis sebagai pendukung visual sehingga tampilan halaman lebih informatif dan mudah dipahami.

5.2.2 Pengujian Halaman Dashboard Prediksi

Halaman Dashboard Prediksi berperan sebagai antarmuka utama untuk memantau hasil prediksi lintasan siklon tropis. Di dalamnya, sistem mengintegrasikan hasil olah model LSTM dengan tampilan peta interaktif. Hal ini memungkinkan pengguna untuk mengamati secara langsung bagaimana model memproyeksikan jalur pergerakan siklon. Selain sebagai penampil visual, halaman ini juga dilengkapi sejumlah kontrol interaktif yang memudahkan pengguna dalam menyaring data sesuai dengan kebutuhan analisis.



Gambar 5.2 Halaman Dashboard Prediksi

Pada Gambar 5.2, bagian atas halaman, terdapat kolom filter yang dapat digunakan untuk mempersempit data berdasarkan radius jarak terhadap wilayah Sumatera Barat. Pengguna bebas menggeser *slider* untuk menentukan jarak, lalu memilih salah satu siklon yang ada melalui daftar *dropdown*. Saat satu siklon dipilih, sistem akan menampilkan keterangan detail siklon tersebut, meliputi ID siklon, nama, interval waktu, durasi, dan jumlah titik pantau. Visualisasi lintasan yang terpilih kemudian diproyeksikan secara langsung ke dalam peta digital interaktif yang dibangun menggunakan *library* Folium. Peta ini memperlihatkan perbandingan antara titik koordinat aktual (observasi) dan titik koordinat hasil prediksi. Agar interpretasi visual lebih mudah, peta dilengkapi legenda yang membedakan lintasan aktual, lintasan prediksi, titik awal (*Start*), dan titik akhir (*End*). Halaman ini juga memiliki keunggulan praktis karena pengguna dapat menelusuri berbagai siklon yang telah diproses sebelumnya tanpa harus menjalankan ulang pelatihan model, sehingga cukup digunakan sebagai media visualisasi dan analisis akhir.

5.2.2.1 Tabel Perbandingan Koordinat dan Metrik Akurasi

Halaman ini digunakan untuk menyajikan hasil evaluasi prediksi secara kuantitatif melalui perbandingan antara koordinat aktual dan koordinat hasil prediksi. Informasi tersebut disajikan dalam bentuk metrik akurasi dan tabel perbandingan sehingga pengguna dapat menilai tingkat ketelitian model pada setiap waktu pengamatan secara lebih rinci. Selain menampilkan nilai kesalahan prediksi, halaman ini juga membantu pengguna mengidentifikasi perbedaan posisi antara hasil prediksi dan data aktual, sehingga kinerja model dapat dievaluasi secara lebih objektif.

SISTEM PREDIKSI SIKLON TROPIS UNTUK MITIGASI RISIKO BENCANA DI SUMATERA BARAT

Metrik Akurasi

RMSE (KM)

12.07

MAE (KM)

10.00

Tabel Perbandingan Koordinat

Waktu	LAT Aktual	LON Aktual	LAT Prediksi	LON Prediksi	Error (km)
19/11/2005 12:00	-7.1000°	94.0000°	-7.1291°	93.8766°	14.00
19/11/2005 15:00	-7.2000°	93.9000°	-7.3931°	93.9338°	21.79
19/11/2005 18:00	-7.4000°	94.0000°	-7.3657°	93.8175°	20.48
19/11/2005 21:00	-7.5000°	94.0000°	-7.6113°	94.0426°	13.24
20/11/2005 00:00	-7.6000°	93.9000°	-7.6533°	94.0271°	15.21
20/11/2005 03:00	-7.8000°	93.9000°	-7.7171°	93.8026°	14.15
20/11/2005 06:00	-8.0000°	93.8000°	-8.0218°	93.8899°	10.39
20/11/2005 09:00	-8.2000°	93.7000°	-8.2159°	93.7078°	1.96
20/11/2005 12:00	-8.4000°	93.6000°	-8.4003°	93.6051°	0.56
20/11/2005 15:00	-8.5000°	93.4000°	-8.6061°	93.5134°	12.48
20/11/2005 18:00	-8.7000°	93.3000°	-8.7962°	93.2144°	14.25
20/11/2005 21:00	-8.9000°	93.1000°	-8.8321°	93.2104°	14.29
21/11/2005 00:00	-9.0000°	92.8000°	-9.0767°	92.9179°	15.50


Gambar 5.3 Tampilan Tabel Perbandingan Koordinat

Pada Gambar 5.3 bagian paling atas dari tampilan ini, disediakan dua kotak metrik akurasi, yaitu RMSE (*Root Mean Squared Error*) dan MAE (*Mean Absolute Error*). Nilai yang terpampang di dalam kotak menunjukkan tingkat kesalahan rata-rata prediksi dalam satuan kilometer. Sementara itu, di bawah kotak metrik tersebut, terdapat tabel rinci yang memuat data pergerakan siklon dari waktu ke waktu. Tabel ini menyajikan kolom waktu, bujur dan lintang aktual, bujur dan lintang prediksi, serta besarnya nilai *error* atau selisih jarak pada setiap titik waktu dalam satuan kilometer. Melalui tabel ini, pengguna bisa menilai pada waktu-waktu tertentu apakah model cenderung memiliki deviasi yang kecil atau justru besar dibandingkan dengan jalur aktual.

5.2.3 Pengujian Halaman Prediksi Siklon

Halaman Prediksi Siklon digunakan untuk menguji proses prediksi lintasan siklon tropis menggunakan model LSTM yang telah diimplementasikan. Pada halaman ini, pengguna dapat memperbarui data observasi, menjalankan prediksi, dan melihat hasilnya secara langsung melalui tampilan visual maupun informasi

numeri



Gambar 5.4 Halaman Prediksi Siklon

Pada Gambar 5.4, Halaman Prediksi Siklon terdiri atas dua bagian, yaitu area pengelolaan data dan area visualisasi hasil prediksi. Pada sisi kiri tersedia Editor Observasi untuk memperbarui data koordinat, kecepatan angin, dan tekanan udara yang secara otomatis ditampilkan pada Tabel Observasi sebagai masukan bagi model LSTM. Setelah proses prediksi dilakukan, hasilnya ditampilkan pada Visualisasi Jalur dalam bentuk peta interaktif yang memperlihatkan lintasan observasi dan hasil prediksi dengan penanda yang berbeda. Selain itu, sistem menyajikan Hasil Prediksi berupa koordinat estimasi, kecepatan angin, dan tekanan udara sehingga keluaran model dapat diamati secara visual maupun numerik.

5.2.3.1 Laporan Prediksi dalam Bentuk Cetak

Fitur pencetakan laporan dalam sistem disediakan untuk mengonversi hasil inferensi model menjadi dokumen siap arsip. Laporan cetak yang dihasilkan memiliki struktur yang sistematis dengan tiga komponen utama, yakni metadata pelaporan, rangkuman data observasi historis sebagai masukan model, dan visualisasi lintasan prediksi.



Gambar 5.5 Tampilan Cetak Laporan

Pada Gambar 5.5, Metadata laporan mencakup informasi identitas siklon seperti ID dan nama siklon, waktu pelaksanaan prediksi, horizon prediksi, hingga versi model LSTM yang digunakan. Selanjutnya, laporan menyajikan tabel data historis observasi berupa delapan titik waktu (*sliding window*) yang menjadi input bagi model, lengkap dengan nilai koordinat geografis, kecepatan angin, dan tekanan udara. Pada bagian akhir, hasil prediksi ditampilkan dalam grafik dua dimensi; garis biru merepresentasikan jalur observasi historis, sedangkan garis merah putus-putus menunjukkan proyeksi lintasan model. Untuk memberikan konteks keruangan, titik segitiga hijau digunakan sebagai penanda lokasi wilayah Sumatera Barat pada peta grafik.

5.2.4 Pengujian Halaman Data Observasi

Halaman Data Observasi dikembangkan sebagai media peninjauan data mentah siklon tropis yang menjadi fondasi bagi pelatihan dan inferensi model LSTM. Pada bagian puncak halaman, pengguna dimudahkan dengan kolom

pencarian berdasarkan *Storm Identifier* (SID), baik melalui pemasukan langsung ID siklon maupun pemilihan dari daftar *dropdown* yang tersedia. Setelah satu siklon terpilih, sistem akan langsung menampilkan ringkasan informasi umum, seperti ID siklon, interval waktu pengamatan, periode, durasi, dan jumlah titik observasi, sehingga pengguna mendapatkan gambaran awal mengenai karakteristik data yang akan dianalisis.


Waktu	LAT (°)	LOK (°)	Wind (km/h)	Metode Imputasi Angin	Pressure (hPa)	Metode Imputasi Tekanan	Status Angin	Status Tekanan
01/01/1980 12:00	-15.2000°	80.5000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
01/01/1980 15:00	-15.0000°	80.3000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
01/01/1980 18:00	-14.8000°	80.2000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
01/01/1980 21:00	-14.6000°	80.1000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
02/01/1980 00:00	-14.0000°	80.0000°	29.00	Original	1000.0	Original	Asli	Asli
02/01/1980 03:00	-13.8000°	79.7000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
02/01/1980 06:00	-13.8000°	79.3000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
02/01/1980 09:00	-13.8000°	78.9000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
02/01/1980 12:00	-14.0000°	78.4000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
02/01/1980 15:00	-14.3000°	78.0000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
02/01/1980 18:00	-14.8000°	77.6000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
02/01/1980 21:00	-14.8000°	77.3000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan
03/01/1980 00:00	-15.0000°	77.0000°	29.00	Forward/Backward	1000.0	Forward/Backward	Perbaikan	Perbaikan

Gambar 5.6 Halaman Data Observasi

Pada Gambar 5.6, bagian bawah, data observasi dijabarkan dalam tabel rinci yang tidak hanya memuat koordinat lintang dan bujur, kecepatan angin, serta tekanan udara, tetapi juga menyajikan status kelengkapan setiap variabel. Terdapat kolom *Metode Imputasi Angin* dan *Metode Imputasi Tekanan* yang memungkinkan pengguna mengetahui apakah suatu titik data berasal dari nilai asli (*Original*) atau hasil pengisian celah data (*Forward/Backward*). Kehadiran label status dan tombol *Edit* pada baris data turut memfasilitasi verifikasi bahwa seluruh rangkaian titik observasi telah melalui proses *preprocessing* sebelum akhirnya digunakan sebagai masukan oleh model. Dengan demikian, halaman ini tidak hanya berfungsi untuk menelusuri karakteristik historis siklon, tetapi juga menjamin integritas dan kualitas data observasi yang digunakan dalam sistem prediksi.

5.2.5 Pengujian Halaman Evaluasi Akurasi

Halaman Evaluasi Akurasi dirancang untuk meninjau performa model LSTM secara spesifik berdasarkan setiap kasus lintasan siklon yang telah diprediksi. Pada bagian atas, tersedia kolom pencarian berdasarkan *Storm Identifier* (SID) dan daftar *dropdown* yang memudahkan pengguna memilih siklon target. Setelah satu siklon dipilih, sistem segera memperbarui informasi identitas meliputi nama siklon, interval waktu, periode kejadian, durasi, serta jumlah titik observasi yang menjadi fokus evaluasi.



Gambar 5.7 Halaman Evaluasi Akurasi

Pada Gambar 5.7, sistem menyajikan empat metrik evaluasi yang ditampilkan dalam kotak terpisah, yaitu MAE, RMSE, Error Minimum, dan Error Maksimum. Pencapaian metrik tersebut kemudian dirangkum dalam status prediksi akurasi secara langsung, seperti yang terlihat pada label "ERROR RENDAH" yang menandakan kinerja model cukup baik. Untuk analisis yang lebih mendalam, tersedia dua visualisasi pendukung. Grafik deviasi jarak sepanjang waktu menampilkan fluktuasi penyimpangan prediksi di setiap titik pengamatan, sedangkan diagram batang distribusi frekuensi error memberikan gambaran mengenai sebaran besaran kesalahan yang terjadi. Kedua visualisasi ini membantu

pengguna mengidentifikasi segmen waktu tertentu di mana prediksi model sangat akurat maupun mengalami deviasi yang cukup besar.

5.2.5.1 Perbandingan Koordinat dan Ringkasan Evaluasi Spasial

Halaman ini menyajikan perbandingan koordinat aktual dan hasil prediksi dalam bentuk tabel untuk membantu mengevaluasi ketelitian model pada setiap waktu pengamatan. Informasi yang ditampilkan meliputi waktu observasi, koordinat aktual, koordinat prediksi, serta nilai kesalahan (*error*) dalam kilometer. Pengguna juga dapat mengunduh data tersebut melalui tombol Unduh CSV untuk keperluan analisis lebih lanjut.

SISTEM PREDIKSI SIKLON TROPIS UNTUK MITIGASI RISIKO BENCANA DI SUMATERA BARAT

Tabel Perbandingan Koordinat Unduh CSV

Waktu	LAT Aktual (°)	LON Aktual (°)	LAT Pred (°)	LON Pred (°)	Error (km)
11/01/1980 12:00	-20.3000°	49.0000°	-20.3570°	48.9502°	8.19
11/01/1980 15:00	-20.3000°	49.4000°	-20.3475°	49.3542°	7.13
11/01/1980 18:00	-20.3000°	49.7000°	-20.3547°	49.7784°	10.27
11/01/1980 21:00	-20.3000°	50.0000°	-20.3469°	49.9696°	6.10
12/01/1980 00:00	-20.3000°	50.3000°	-20.3483°	50.2764°	5.91
12/01/1980 03:00	-20.3000°	50.6000°	-20.3519°	50.1896°	5.87
12/01/1980 06:00	-20.3000°	51.0000°	-20.3491°	50.8789°	13.79
12/01/1980 09:00	-20.2000°	51.5000°	-20.3600°	51.3719°	22.25
12/01/1980 12:00	-19.9000°	52.0000°	-20.1861°	51.9862°	31.85
12/01/1980 15:00	-19.5000°	52.5000°	-19.8938°	52.4630°	21.89
12/01/1980 18:00	-18.9000°	52.8000°	-19.1905°	52.9234°	34.81
12/01/1980 21:00	-18.2000°	53.0000°	-18.4163°	53.0906°	29.89
13/01/1980 00:00	-17.5000°	53.1000°	-17.6002°	53.1493°	12.31
13/01/1980 03:00	-16.8000°	53.1000°	-16.9021°	53.2094°	16.26
13/01/1980 06:00	-16.0000°	53.0000°	-16.1959°	53.1139°	24.95

[RINGKASAN EVALUASI SPASIAL]
 Halaman ini menyajikan tingkat akurasi model LSTM dengan membandingkan posisi aktual (data BTHACS) dan posisi hasil prediksi pada setiap titik waktu. Statistik MAE dan RMSE memberikan gambaran kesalahan rata-rata dalam kilometer. Grafik dekomposisi membantu mengidentifikasi apakah model memiliki bias khusus pada sumbu Lintang (Utara-Selatan) atau Bujur (Barat-Timur).

Gambar 5.8 Tampilan Tabel Evaluasi Akurasi


Pada Gambar 5.8, Tabel perbandingan memudahkan pengguna mengamati perbedaan antara lintasan aktual dan hasil prediksi pada setiap titik pengamatan. Melalui penyajian tersebut, penyimpangan model dapat dikenali dengan lebih mudah sehingga proses evaluasi menjadi lebih terarah.

Di bawah tabel tersedia Ringkasan Evaluasi Spasial yang menyajikan interpretasi terhadap hasil evaluasi model berdasarkan nilai MAE, RMSE, serta kecenderungan kesalahan pada sumbu lintang dan bujur. Informasi ini membantu

pengguna memahami karakteristik kesalahan prediksi sehingga kinerja model dapat dinilai tidak hanya dari nilai numerik, tetapi juga dari pola penyebaran kesalahan secara spasial.

5.2.6 Pengujian Halaman Tentang Model

Halaman Tentang Model berfungsi sebagai pusat informasi yang merangkum latar belakang penelitian, metodologi, serta hasil eksperimen yang mendasari pengembangan aplikasi ini. Pada bagian awal, pengguna disambut dengan kotak pengantar yang memuat tujuan utama sistem prediksi lintasan siklon tropis menggunakan arsitektur *Deep Learning Long Short-Term Memory* (LSTM). Ringkasan tersebut juga menegaskan bahwa model dilatih menggunakan data historis dari dataset *International Best Track Archive for Climate Stewardship* (IBTrACS) periode 1980–2025 untuk memprediksi koordinat posisi siklon pada langkah waktu berikutnya.



Gambar 5.9 Halaman Tentang

Pada Gambar 5.9, Ringkasan penelitian, sistem menyajikan visualisasi diagram batang berjudul *Perbandingan Kinerja Haversine Seluruh Model*. Grafik ini menampilkan nilai rata-rata jarak *Haversine* dalam satuan kilometer untuk

berbagai skenario model eksperimen (seperti GAB8, GAB16, NI, dan SI). Dalam konteks evaluasi ini, semakin rendah nilai yang terpampang pada batang grafik, maka semakin baik tingkat akurasi spasial yang dihasilkan model dalam memprediksi lintasan. Visualisasi ini sangat membantu pengguna dalam membandingkan kualitas antar-varian model dan memberikan dasar objektif mengenai alasan model tertentu akhirnya dipilih sebagai model operasional utama pada aplikasi.

BAB VI

PENUTUP

6.1 Kesimpulan

Berdasarkan hasil implementasi, pengujian, dan analisis yang telah dilakukan, penelitian ini berhasil mencapai tujuan yang telah ditetapkan. Model *Long Short-Term Memory* (LSTM) berhasil dikembangkan untuk memprediksi lintasan siklon tropis menggunakan data historis IBTrACS, serta diimplementasikan ke dalam aplikasi visualisasi berbasis web menggunakan *framework* Streamlit. Adapun kesimpulan yang diperoleh dari penelitian ini adalah sebagai berikut.

1. Model *Long Short-Term Memory* (LSTM) berhasil digunakan untuk memprediksi lintasan siklon tropis menggunakan data historis IBTrACS pada Perairan *North Indian Ocean* (NI) dan *South Indian Ocean* (SI). Berdasarkan hasil evaluasi terhadap 12 skenario pemodelan, seluruh model mampu menghasilkan nilai koefisien determinasi (R^2), dengan nilai berkisar antara 0,998350 - 0,999833. Selain itu, model *South Indian Ocean* (SI) dengan *sliding window 8 timesteps* memperoleh performa terbaik berdasarkan nilai MAE, RMSE, dan Mean *Haversine Distance*, sehingga menunjukkan bahwa model LSTM mampu mempelajari pola pergerakan siklon tropis dengan tingkat akurasi yang baik.
2. Perbedaan karakteristik statistik, temporal, dan spasial antar *basin*, serta variasi ukuran *timesteps*, berpengaruh terhadap kemampuan model *Long Short-Term Memory* (LSTM) dalam memprediksi lintasan siklon tropis. Hasil penelitian menunjukkan bahwa penggunaan *sliding window* yang

lebih panjang tidak selalu menghasilkan performa yang lebih baik. Pada sebagian besar skenario, *sliding window* 8 dan 16 menghasilkan tingkat kesalahan yang lebih rendah dibandingkan *sliding window* 24 dan 32. Pada *dataset North Indian Ocean* (NI), performa terbaik diperoleh pada *sliding window* 16 dengan *Mean Haversine Distance* sebesar 20,39 km, sedangkan model yang dibangun menggunakan *dataset South Indian Ocean* (SI) menghasilkan akurasi rata-rata 14,23km. Sementara itu, model Gabungan (GAB) menunjukkan performa yang lebih stabil. Berdasarkan pertimbangan tersebut, model GAB dengan *sliding window* 8 *timesteps* dipilih sebagai model implementasi karena memberikan keseimbangan yang baik antara akurasi dan kestabilan prediksi.

3. Aplikasi visualisasi berbasis Python menggunakan *framework* Streamlit berhasil dirancang dan diimplementasikan untuk menampilkan hasil prediksi lintasan siklon tropis secara interaktif. Aplikasi yang dikembangkan mampu menampilkan data observasi, hasil prediksi koordinat, visualisasi lintasan pada peta digital, serta informasi evaluasi model. Berdasarkan hasil pengujian fungsional, seluruh fitur utama aplikasi berjalan sesuai dengan rancangan sehingga dapat digunakan sebagai media visualisasi hasil prediksi lintasan siklon tropis.

6.2 Keterbatasan Sistem

Keterbatasan dalam penelitian ini tidak terlepas dari ruang lingkup yang telah ditetapkan sejak awal. Pembatasan tersebut dilakukan agar penelitian tetap berfokus pada tujuan yang ingin dicapai. Dengan demikian, beberapa aspek berikut masih berada di luar cakupan penelitian.

1. Model dikembangkan menggunakan data lintasan siklon tropis dari dataset IBTrACS yang mencakup perairan *North Indian Ocean* (NI) dan *South Indian Ocean* (SI). Variabel yang digunakan terbatas pada atribut yang tersedia di dalam dataset sehingga belum melibatkan parameter meteorologi maupun oseanografi lainnya.
2. Kajian penelitian difokuskan pada pengaruh perbedaan karakteristik statistik, temporal, dan spasial antara basin NI dan SI serta variasi ukuran *sliding window* terhadap kinerja model *Long Short-Term Memory* (LSTM). Perbandingan dengan arsitektur lain maupun eksplorasi *hyperparameter tuning* yang lebih luas belum dilakukan.
3. Implementasi sistem dibatasi pada aplikasi visualisasi berbasis Python menggunakan *framework* Streamlit. Aplikasi yang dikembangkan berfungsi untuk menampilkan hasil prediksi pada peta digital interaktif dan belum mendukung pembaruan data secara *real-time* maupun fitur *early warning system*.

6.3 Saran

Berdasarkan hasil penelitian yang telah dilakukan, masih terdapat beberapa keterbatasan yang dapat menjadi perhatian pada penelitian selanjutnya. Keterbatasan tersebut berkaitan dengan cakupan data yang digunakan, pendekatan pemodelan, serta implementasi sistem. Oleh karena itu, beberapa saran yang dapat dipertimbangkan adalah sebagai berikut.

1. Pemodelan pada penelitian ini masih menggunakan satu *arsitektur Long Short-Term Memory* (LSTM) dengan variasi ukuran *sliding window* sebagai fokus eksperimen. Oleh karena itu, penelitian selanjutnya dapat

mengevaluasi arsitektur maupun konfigurasi model lainnya untuk mengetahui pendekatan yang memberikan performa lebih baik pada prediksi lintasan siklon tropis.

2. Penelitian ini hanya memanfaatkan data historis dari dua basin, yaitu *North Indian* (NI) dan *South Indian* (SI), serta menggunakan variabel yang tersedia pada dataset IBTrACS. Penelitian selanjutnya dapat memperluas cakupan data dengan menambahkan basin lain maupun variabel meteorologi dan oseanografi, seperti *Sea Surface Temperature* (SST), tekanan atmosfer, kelembapan, dan kecepatan angin, sehingga informasi yang digunakan dalam proses prediksi menjadi lebih lengkap.
3. Dashboard yang dikembangkan pada penelitian ini masih difokuskan pada visualisasi hasil prediksi. Pengembangan lebih lanjut dapat diarahkan pada penambahan fitur analisis dan integrasi data terbaru sehingga dashboard tidak hanya berfungsi sebagai media visualisasi, tetapi juga sebagai sarana pendukung analisis prediksi lintasan siklon tropis.

DAFTAR PUSTAKA

- Alsabagh, A. S., Alawi, O. A., Kamar, H. M., Nafea, A. A., Al-Ani, M. M., Mohammed, H. A., Kazi, S. N., Oudah, A. Y., & Yaseen, Z. M. (2025). Deep learning framework for hourly air pollutants forecasting using encoding cyclical features across multiple monitoring sites in Beijing. *Scientific Reports*, *15*, 22247. <https://doi.org/10.1038/s41598-025-05472-5>
- Al-Selwi, S. M., Hassan, M. F., Abdulkadir, S. J., Muneer, A., Sumiea, E. H., Alqushaibi, A., & Ragab, M. G. (2024). RNN-LSTM: From applications to modeling techniques and beyond—Systematic review. *Journal of King Saud University - Computer and Information Sciences*, *36*(5), 102068. <https://doi.org/10.1016/j.jksuci.2024.102068>
- Alvarado, R., & Zhang, Y. (2023). The 4+1 model of data science. *arXiv*. <https://doi.org/10.48550/arXiv.2311.09287>
- Awada, A., Chen, J., & Liu, Q. (2024). Deep learning approaches in predicting tropical cyclone tracks: An analysis focused on the Northwest Pacific Region. *Ocean Modelling*, *192*, 102444. <https://doi.org/10.1016/j.ocemod.2024.102444>
- Emlaw, G. N., & Kim, D. (2024). The role of precursor disturbances on the modulation of Western Pacific tropical cyclogenesis by the Madden–Julian oscillation. *Geophysical Research Letters*, *51*(12), Article e2023GL108102. <https://doi.org/10.1029/2023GL108102>
- Evans, C., Wood, K. M., Aberson, S. D., Archambault, H. M., Milrad, S. M., Bosart, L. F., Corbosiero, K. L., Davis, C. A., Galarneau Jr., T. J., Keyser, D., Keller, J. H., & Ritchie, E. A. (2024). The extratropical transition of tropical cyclones. Part I: Cyclone evolution and direct impacts. *Monthly Weather Review*, *152*(8), 1785–1807. <https://doi.org/10.1175/MWR-D-17-0027.1>
- Goh, K. H., Wang, L., Yeow, A. Y. K., Poh, H., Li, K., Yeow, J. J. L., & Tan, G. Y. H. (2021). Artificial intelligence in sepsis early prediction and diagnosis using unstructured data in healthcare. *Nature Communications*, *12*, 711. <https://doi.org/10.1038/s41467-021-20910-4>
- Gorja, M. M. K., Vissa, N. K., & Viswanadhapalli, Y. (2024). Untangling the role of convective and circulation features on multi-scales in modulating tracks of tropical cyclones formed over the Bay of Bengal. *Journal of Atmospheric and Solar-Terrestrial Physics*, *261*, 106291. <https://doi.org/10.1016/j.jastp.2024.106291>

- Guo, R., Yu, R., Yang, M., Chen, G., Chen, C., Chen, P., Huang, X., & Zhang, X. (2024). Analysis of characteristics and evaluation of forecast accuracy for Super Typhoon Doksuri (2023). *Tropical Cyclone Research and Review*, *13*(3), 219–229. <https://doi.org/10.1016/j.tcr.2024.09.001>
- Hao, X., Zhang, G., & Ma, S. (2024). Deep learning for time series forecasting: A survey and an application to meteorology. *International Journal of Forecasting*, *40*(2), 752–773. <https://doi.org/10.1016/j.ijforecast.2023.07.001>
- Hassani, H., Marvian, L., Yarmohammadi, M., & Yeganegi, M. R. (2024). Unraveling time series dynamics: Evaluating partial autocorrelation function distribution and its implications. *Mathematical and Computational Applications*, *29*(4), 58. <https://doi.org/10.3390/mca29040058>
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, *9*(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Kong, Y., Wang, Z., Nie, Y., Zhou, T., Zohren, S., Liang, Y., Sun, P., & Wen, Q. (2024). Unlocking the power of LSTM for long term time series forecasting. *arXiv*. <https://arxiv.org/abs/2405.04717>
- Koldasbayeva, D., Tregubova, P., Gasanov, M., Zaytsev, A., Petrovskaia, A., & Burnaev, E. (2024). Challenges in data-driven geospatial modeling for environmental research and practice. *Nature Communications*, *15*(1), 10700. <https://doi.org/10.1038/s41467-024-55240-8>
- Le, C. H., & Liou, Y.-A. (2026). Quantifying typhoon track curvature: Introducing the Normalized Difference Sinuosity Index. *Global and Planetary Change*, *263*, 105494. <https://doi.org/10.1016/j.gloplacha.2026.105494>
- Loi, C. L., Tseng, K. C., & Wu, C. C. (2025). Predictability of tropical cyclone track density in S2S reforecast. *npj Climate and Atmospheric Science*, *8*, 24. <https://doi.org/10.1038/s41612-025-00909-0>
- Luangmaneeerote, S., & Thasana, W. (2025). Boosting medium-size reservoir water level predictions using cyclical encoding. *Engineering, Technology & Applied Science Research*, *15*(3), 23672–23677. <https://doi.org/10.48084/etasr.10595>
- National Oceanic and Atmospheric Administration. (2024). *Saffir-Simpson hurricane wind scale*. Retrieved June 13, 2026, from <https://www.nhc.noaa.gov/aboutsshws.php>
- Ogu, H. A., Liu, L., & Lin, Y.-L. (2026). Comparative evaluation of machine learning and deep learning models for tropical cyclone track and intensity

- forecasting in the North Atlantic Basin. *Atmosphere*, *17*(4), 418. <https://doi.org/10.3390/atmos17040418>
- Rahman, M. A., Hasan, M. S., & Islam, M. N. (2025). Tropical cyclone track prediction harnessing deep learning algorithms: A comparative study on the Northern Indian Ocean. *Results in Engineering*, *26*, 105009. <https://doi.org/10.1016/j.rineng.2025.105009>
- Rehman, A., Ullah, S., & Khan, M. (2025). A comparative analysis of a global and a regional model on the tropical cyclone track forecast. *Natural Hazards*, *121*, 5947–5991. <https://doi.org/10.1007/s11069-024-07035-9>
- Shi, Y., Hu, R., Wu, N., Zhang, H., Liu, X., Zeng, Z., Zhu, J., Han, P., Luo, C., Zhang, H., He, J., & Shi, X. (2025). Comparison of AI and NWP models in operational severe weather forecasting: A study on tropical cyclone predictions. *Journal of Geophysical Research: Machine Learning and Computation*, *2*(2), e2024JH000481. <https://doi.org/10.1029/2024JH000481>
- Siswono, G. O., Lina, Y. A., & Pricila, V. (2023). The application of the Long-Short Term Memory (LSTM) forecasting method on the impact of tropical cyclones in Indonesia. *Jurnal Matematika, Statistika, & Komputasi*, *20*(1), 294–300. <https://doi.org/10.20956/j.v20i1.27151>
- Tridaiana, S., & Marzuki, M. (2023). Exploring the complex dynamics of tropical cyclone activity in the Southern Indian Ocean: A multidecade analysis. *Jurnal Penelitian Pendidikan IPA*, *9*(11), 9440–9452. <https://doi.org/10.29303/jppipa.v9i11.5601>
- Tridaiana, S., & Marzuki, M. (2024). Exploring ENSO and IOD effects on Southern Indian Ocean cyclones from 1970 to 2022. *AIP Conference Proceedings*, *3116*(1), Article 040002. <https://doi.org/10.1063/5.0210159>
- Venna, S. R. K. R., Tavanaei, A., Gottumukkala, R., Raghavan, V., Maida, A., & Nichols, S. (2018). A novel data-driven model for real-time influenza forecasting. *IEEE Access*, *7*, 7691–7701. <https://doi.org/10.1109/ACCESS.2018.2888585>
- Ventura, F., Sander, N., Catry, P., Wakefield, E., De Pascalis, F., Richardson, P. L., Granadeiro, J. P., Silva, M. C., & Ummenhofer, C. C. (2024). Oceanic seabirds chase tropical cyclones. *Current Biology*, *34*(15), 3551–3552. <https://doi.org/10.1016/j.cub.2024.06.022>
- Villegas-Camacho, O., Francisco-Valencia, I., Alejo-Eleuterio, R., Granda-Gutiérrez, E. E., Martínez-Gallegos, S., & Villanueva-Vásquez, D. (2025). FTIR-based microplastic classification: A comprehensive study on

- normalization and ML techniques. *Recycling*, *10*(2), 46. <https://doi.org/10.3390/recycling1002046>
- Wagner, S., et al. (2024). Drivers of global irrigation expansion: the role of discrete global grid choice. *Hydrology and Earth System Sciences*, *28*, 5049–5068. <https://doi.org/10.5194/hess-28-5049-2024>
- Wang, S., Toumi, R., & Hodges, K. (2024). A global analysis of tropical cyclone eye and eyewall characteristics. *Geophysical Research Letters*, *51*, e2023GL107082. <https://doi.org/10.1029/2023GL107082>
- Weng, Y., & Gori, A. (2026). Climatological benchmarking of AI-generated tropical cyclones. *Journal of Geophysical Research: Atmospheres*, *131*(2), e2025JD044753. <https://doi.org/10.1029/2025JD044753>
- World Meteorological Organization. (2025). *Aviation hazards: Tropical cyclones*. Retrieved June 13, 2026, from <https://wmo.int/media/news/tropical-cyclone-gezani-hits-madagascar-and-threatens-mozambique>
- Yadav, H., & Thakkar, A. (2023). NOA-LSTM: An efficient LSTM cell architecture for time series forecasting. *Expert Systems with Applications*, *235*, 122333. <https://doi.org/10.1016/j.eswa.2023.122333>
- Yeasin, M., Paul, R. K., & Shankar, S. V. (2024). Ensemble machine learning models for forecasting tropical cyclones in North Indian region. *Earth Science Informatics*, *17*(4), 3705–3714. <https://doi.org/10.1007/s12145-024-01345-x>
- Yun, J. (2024). ZNorm: Z-score gradient normalization accelerating skip-connected network training without architectural modification. *arXiv*. <https://arxiv.org/abs/2408.01215>
- Yunita, A., Pratama, M. I., Almuzakki, M. Z., Ramadhan, H., Akhir, E. A. P., Mansur, A. B. F., & Basori, A. H. (2025). Performance analysis of neural network architectures for time series forecasting: A comparative study of RNN, LSTM, GRU, and hybrid models. *MethodsX*, *15*, 103462. <https://doi.org/10.1016/j.mex.2025.103462>

LAMPIRAN
CURICULUM VITAE
DAFTAR RIWAYAT HIDUP

Data Pribadi / *Personal Details*

Nama / <i>Name</i>	: Ikhwan Ramadhan
Jenis Kelamin / <i>Gender</i>	: Laki-Laki
Tempat Tanggal Lahir / <i>Data Of Birth</i>	: Padang, Sumatera Barat
Warga Negara / <i>Nationality</i>	: Indonesia
Status Marital / <i>Marital Status</i>	: Belum Menikah
Agama / <i>Religion</i>	: Islam
Alamat / <i>Address</i>	: Padang Sumatera Barat,
Nomor Telepon / <i>Phone</i>	: 082386473410

Riwayat Pendidikan

Tahun 2010-2016	: SDN 18 Kampung Baru
Tahun 2016 – 2019	: SMPN 21 PADANG
Tahun 2019 – 2022	: SMAN 14 PADANG
Tahun 2022 – 2026	: Universitas Putra Indonesia “YPTK” Padang

Demikian daftar riwayat hidup ini saya buat dengan sebenarnya.

BUKTI ACC JUDUL SKRIPSI

Home
 >
 [Judul yang sudah ACC](#)

PENGAJUAN #1

Diajukan 08 April 2026 17:41:19 WIB

Judul #1 : ANALISIS DAN PREDIKSI DATA TIME SERIES B

PREDIKSI JALUR SIKLON TROPIS DI SAMUDRA HINDIA MENGGUNAKAN MODEL LONG SHORT-TERM MEMORY (LSTM) UNTUK MITIGASI RISIKO BENCANA DI SUMATERA BARAT

Penelitian menggunakan dataset IBTIACS (NOAA) untuk data sik

Kalimat judul Pak perbaiki sedikit tapi tidak merubah maksud dari judul yang diajukan. Silahkan gunakan judul yang sudah Pak perbaiki ini.

Dosen Pembimbing 1

Prof. Dr. Yuhandri, S.Kom, M.Kom

Minta dulu surat Pengantar ke Dekanat, setelah itu baru menghubungi Dosen Pembimbing 1

Dosen Pembimbing 2

Devia Kartika, S.Kom, M.Kom



Minta dulu surat Pengantar ke Dekanat, setelah itu baru menghubungi Dosen Pembimbing 2

KARTU BIMBINGAN SKRIPSI DOSEN PEMBIMBING 1

 UPI YPTK LEMBAGA PENJAMINAN MUTU INTERNAL (LPMI)	UNIVERSITAS PUTRA INDONESIA "YPTK"	No. Dokumen
	LEMBAGA PENJAMINAN MUTU INTERNAL (LPMI)	FM-LPMI- UPI-YPTK-031
FORMULIR KARTU BIMBINGAN SKRIPSI		Revisi 2025

Nama Mahasiswa : <u>IKHWAN RAMADHAN</u> NOBP : <u>22101152630411</u> Program Studi : <u>TEKNIK INFORMATIKA</u> Fakultas : <u>ILMU KOMPUTER</u> Jenjang Pendidikan : <u>* D3/S1/S2/S3</u> Judul Skripsi : <u>PERBAIKI JALUR SIKLON TROPIS DI SAMUDRA HINDA MENGGUNAKAN MODEL LONG SHORT-TERM MEMORY (LSTM) UNTUK MITIGASI BAIKO BEYAKAYA DI KOTA BANGKALAY</u>	Pas Photo 3x4
Dosen Pembimbing I : <u>PROF. DR. YUHANDRI, S.kom, M.kom</u> Dosen Pembimbing II : <u>DEVIA KARTIKA, S.kom, M.kom</u>	

CATATAN KONSULTASI BIMBINGAN SKRIPSI

No.	Tgl	Topik	Rencana Tindak Lanjut	Paraf Dosen
1	27/4-2026	I, II, III	Perbaiki penulisan, ikuti pedoman penulisan	
2	4/5-2026	I, II	Tidak ikut aturan penulisan, lihat Petunjuk	
3	10/5-2026	I, II, III	Perbaiki cara penulisan	
4	25/5-2026	I, II, III	Perbaiki kesalahan, lanjut Bab berikutnya	
5	10/6-2026	IV	perbaiki penulisan tambahan dan lain	
6	22/6-2026	Bab IV	- pahami apa yang dibuat. - Data karena diambil dari internet harus disitasi	
7	1/7-2026	Bab IV	di lampirkan Bab IV	
8	6/7-2026	Bab V	Gambar frontpage harus jelas, lampirkan Bab VI lengkap Buat print book, lampirkan program	
9	13/7-2026	- print book - program	perbaiki: ts mark size Berikan dan. prediksi mana?	
10	27/7-2026	- Skripsi: di - program: di - kelengkapan: kirim ke email		








(*Catatan :
 1. Mahasiswa wajib melakukan bimbingan minimal 6 (enam) kali secara aktif dan rutin dan setiap bimbingan harus di paraf oleh dosen pembimbing.
 2. Mahasiswa wajib mengikuti arahan, masukan, dan revisi yang diberikan oleh dosen pembimbing dan serta dilarang menyalahgunakan data bimbingan.
 3. Dosen pembimbing berhak menunda persetujuan ujian apabila naskah belum memenuhi standar akademik.

KARTU BIMBINGAN SKRIPSI DOSEN PEMBIMBING 2

	UNIVERSITAS PUTRA INDONESIA "YPTK" LEMBAGA PENJAMINAN MUTU INTERNAL (LPMI)	No. Dokumen FM-LPMI- UPI-YPTK-031
	FORMULIR KARTU BIMBINGAN SKRIPSI	Revisi 2025

Nama Mahasiswa : IKHWAN RAMADHAN NOBP : 22101152630111 Program Studi : TEKNIK INFORMATIKA Fakultas : ILMU KOMPUTER Jenjang Pendidikan : * D3/S1/S2/S3 Judul Skripsi : Prediksi Jalur Siklon Tropis di Sumatera Hindia menggunakan model long short-term memory (LSTM) untuk mitigasi Risiko Bencana di Sumatera Barat	Pas Photo 3x4
Dosen Pembimbing I : Prof. Dr. Yuhandri S.kom, M.kom Dosen Pembimbing II : Deva Kartika S.kom, M.kom	

CATATAN KONSULTASI BIMBINGAN SKRIPSI

No.	Tgl	Topik	Rencana Tindak Lanjut	Paraf Dosen
1.	4 Juni 2026	Bab I	Perbaiki Bab I	
2.	12 Juni 2026	Bab I	Perbaiki Bab I	
3	23 Juni 2026	Bab I	Perbaiki Bab I Lampirkan Bab II	
4.	4 Juli 2026	Bab I	ACC Bab I Perbaiki Bab II	
5	7 Juli 2026		Perbaiki Bab II Lampirkan Bab III	
6	20 Juli 2026	Bab II & III	ACC Bab II Perbaiki Bab III	
7.	29 Juli 2026	III & IV	Perbaiki Bab III Lampirkan Bab IV	
9	30 Juli 2026		ACC Bab III Perbaiki Bab IV	
10	3 Agus 2026		Lampirkan seluruh Bab + Draft Print Bersih ACC Print Bersih	

(*Catatan :

- Mahasiswa wajib melakukan bimbingan minimal 6 (enam) kali secara aktif dan rutin dan setiap bimbingan harus di paraf oleh dosen pembimbing.
- Mahasiswa wajib mengikuti arahan, masukan, dan revisi yang diberikan oleh dosen pembimbing dan serta dilarang menyalahgunakan data bimbingan.
- Dosen pembimbing berhak menunda persetujuan ujian apabila naskah belum memenuhi standar akademik.